

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه صنعتی اصفهان
دانشکده مهندسی برق و کامپیوتر

پیش‌بینی اولین رکورد شیردهی دام با بهره‌گیری از الگوریتم‌های یادگیری ماشین و داده‌های تاریخی

گزارش پروژه کارشناسی - مهندسی کامپیوتر

سپهر عبادی

استاد راهنما

دکتر هدی صفائی پور

تیرماه ۱۴۰۴

تشکر و قدردانی

پروردگار منّان را سپاسگزارم که به من قدرت بخشید تا بتوانم در این دوره همانند بقیه عمر، به طلب علم پردازم. همچنین از خانواده‌ام که مرا در این راه یاری نمودند و پشتیبانی کردند بسیار قدردانم.

فهرست مطالب

عنوان	صفحه
فهرست مطالب	پنج
فهرست شکل ها	هشت
فهرست جدول ها	نه
چکیده	۱
فصل اول : مقدمه	۳
۱-۱ انگیزه و اهمیت تحقیق	۳
۲-۱ تعریف مسئله	۴
۳-۱ اهداف تحقیق	۵
۴-۱ ساختار گزارش	۵
فصل دوم : پیش زمینه نظری	۶
۱-۲ مقدمه	۶
۲-۲ تقسیم بندی داده ها	۷
۳-۲ مقیاس بندی داده ها	۷
۴-۲ بیش برآزش و کم برآزش	۸
۵-۲ اعتبارسنجی مقاطع	۹
۶-۲ روش نزول گرادیان	۹
۲-۶-۱ تابع هزینه چیست؟	۹
۲-۶-۲ نزول گرادیان چیست؟	۹
۲-۶-۳ نحوه کار نزول گرادیان چگونه است؟	۹
۲-۶-۴ آلفا - نرخ یادگیری	۱۰
۲-۶-۵ کمینه های محلی	۱۱
۲-۶-۶ مزایا و معایب	۱۱
۲-۷ ناخالصی جینی	۱۲
۲-۸ اطلاعات کسب شده	۱۳
۲-۹ مدل های مورد استفاده	۱۳
۲-۹-۱ رگرسیون ريج	۱۴

۱۵	۲-۹-۲ درخت تصمیم
۱۷	۳-۹-۲ جنگل تصادفی
۱۸	۴-۹-۲ رگرسیون بردار پشتیبان
۲۲	۵-۹-۲ افزایش گرادیان افراطی
۲۴	۶-۹-۲ تقویت دسته‌ای
۲۶	۷-۹-۲ شبکه عصبی چندلایه
۳۳	۸-۹-۲ شبکه عصبی عمیق
۳۹	۱۰-۲ معیارهای ارزیابی مدل‌ها

فصل سوم: مروری بر پژوهش‌های پیشین

۴۱	۱-۳ مقدمه
۴۲	۲-۳ دوره انتقال و اهمیت پایش آن در گاوهای شیری
۴۲	۱-۲-۳ شاخص دوره انتقال و محدودیت‌های آن
۴۳	۲-۲-۳ چالش پایش دوره انتقال در تلیسه‌ها
۴۳	۳-۳ روش‌های پیش‌بینی عملکرد شیر
۴۳	۱-۳-۳ روش‌های سنتی و آماری
۴۴	۲-۳-۳ کاربرد یادگیری ماشین در پیش‌بینی عملکرد شیر
۴۶	۴-۳ عوامل تأثیرگذار بر عملکرد شیر در اوایل شیردهی و دوره انتقال
۴۷	۵-۳ چالش‌ها، محدودیت‌ها و پژوهش‌های آتی
۴۸	۶-۳ نتیجه‌گیری

فصل چهارم: توسعه مدل

۵۰	۱-۴ مقدمه
۵۰	۲-۴ تحلیل داده‌های دامداری رحمت‌آباد
۵۱	۱-۲-۴ شاخص دوره انتقال در ماه‌های مختلف سال
۵۲	۲-۲-۴ روند تغییرات شاخص دوره انتقال
۵۳	۳-۲-۴ هیستوگرام شاخص دوره انتقال برای گاوهای تازه‌زا
۵۴	۴-۲-۴ روند تغییرات نسبت چربی به پروتئین
۵۶	۵-۲-۴ تعداد ریزش داده خام
۵۷	۶-۲-۴ گاوهای تازه‌زا با شاخص دوره انتقال کمتر از ۸-
۵۸	۳-۴ پیش‌پردازش داده‌ها
۵۸	۱-۳-۴ مجموعه داده
۵۹	۲-۳-۴ نمایش توزیع متغیرها
۶۲	۳-۳-۴ تحلیل ماتریس همبستگی
۶۳	۴-۳-۴ مدیریت داده‌های گمشده
۶۳	۵-۳-۴ تقسیم‌بندی داده‌ها و نرمال‌سازی

۶۴	مدل‌های آموزش داده‌شده
۶۴	۴-۴-۱ مدل رگرسیون ریج
۶۶	۴-۴-۲ مدل جنگل تصادفی
۷۱	۴-۴-۳ مدل رگرسیون بردار پشتیبان
۷۴	۴-۴-۴ مدل افزایش گرادیان افراطی
۷۶	۴-۴-۵ مدل تقویت دسته‌ای
۷۸	۴-۴-۶ مدل شبکه عصبی چندلایه
۸۰	۴-۴-۷ مدل شبکه عصبی عمیق
۸۱	۴-۵ جمع‌بندی و نتیجه‌گیری

۸۳ فصل پنجم: ارزیابی و نتایج

۸۳	۵-۱ مقدمه
۸۴	۵-۲ تحلیل داده‌ها و نتایج مدل‌ها
۸۵	۵-۳ مقایسه و انتخاب مدل بهینه
۸۷	۵-۴ تحلیل تفصیلی مدل بهینه
۸۷	۵-۴-۱ عملکرد کمی مدل
۸۷	۵-۴-۲ تحلیل کیفی و ویژگی‌های مؤثر
۸۸	۵-۴-۳ محدودیت‌ها و نقاط قوت مدل
۸۸	۵-۵ چالش‌ها و محدودیت‌ها
۸۹	۵-۶ نتیجه‌گیری
۹۰	مراجع

فهرست شکل‌ها

۱-۲	نمودار کم‌برازش در مقابل تعادل و بیش‌برازش	۸
۲-۲	نحوه کار نزول گرادیان در بهینه‌سازی	۱۰
۳-۲	تأثیر نرخ یادگیری بر فرآیند بهینه‌سازی	۱۰
۴-۲	کمینه‌های محلی در تابع هزینه	۱۱
۵-۲	تفاوت رگرسیون بردار پشتیبان و ماشین بردار پشتیبان	۱۹
۶-۲	مدل ریاضی و نمودار رگرسیون بردار پشتیبان	۲۰
۷-۲	مدل ریاضی و نمودار رگرسیون بردار پشتیبان با متغیرهای افزایشی	۲۱
۸-۲	کارکر مد افزایش گرادیان افراطی	۲۴
۹-۲	مدل تقویت دسته‌ای	۲۶
۱۰-۲	شبکه عصبی مصنوعی در مقابل شبکه عصبی بیولوژیکی	۲۸
۱۱-۲	ساختار شبکه‌های عصبی چندلایه	۳۲
۱۲-۲	شبکه‌های عصبی و شبکه‌های عصبی عمیق	۳۴
۱-۴	نمودار پراکندگی شاخص دوره انتقال در طول زمان نسبت به زایش	۵۲
۲-۴	هیستوگرام شاخص دوره انتقال برای گاوهای تازه‌زا	۵۳
۳-۴	روند تغییرات نسبت چربی به پروتئین در طول ماه‌های مختلف	۵۵
۵-۴	هیستوگرام متغیر روز رکورد گیری اولین رکورد شیر	۶۰
۴-۴	هیستوگرام متغیر اولین رکورد شیر	۶۰
۷-۴	هیستوگرام متغیر طول دوره خشکی	۶۰
۶-۴	هیستوگرام متغیر طول دوره آبستنی	۶۰
۹-۴	هیستوگرام متغیر گروه	۶۰
۸-۴	هیستوگرام متغیر طول دوره شیردهی	۶۰
۱۱-۴	هیستوگرام متغیر شیرتجمعی ۳۰۵ روز گذشته	۶۱
۱۰-۴	هیستوگرام متغیر شیرتجمعی ۳۰۵ روز	۶۱
۱۳-۴	هیستوگرام متغیر سلول‌های سوماتیک ۳۰۵ روز	۶۱
۱۲-۴	هیستوگرام متغیر اولین رکورد شیر دوره قبلی	۶۱
۱۴-۴	ماتریس همبستگی بین متغیرها	۶۲

فهرست جدول‌ها

۱-۲	مقایسه انواع روش‌های نزول گرادیان	۱۲
۲-۲	مقایسه انواع تابع‌های هسته در رگرسیون بردار پشتیبان	۲۲
۱-۴	شاخص دوره انتقال برای گروه‌های مختلف در ماه‌های مختلف	۵۱
۲-۴	تعداد ریزش داده‌ها به ازای متغیرهای کلیدی در هر ماه رکورد	۵۶
۳-۴	گاوهای تازه‌زا با شاخص دوره انتقال کمتر از ۸-	۵۷
۴-۴	تعداد داده‌های گمشده در ستون‌ها	۶۳
۵-۴	ویژگی‌های استفاده‌شده در مدل رگرسیون ریح	۶۴
۶-۴	نتایج ارزیابی مدل اولیه رگرسیون ریح بر روی مجموعه آزمون	۶۵
۷-۴	نتایج ارزیابی مدل نهایی رگرسیون ریح بر روی مجموعه آزمون	۶۶
۸-۴	ویژگی‌های استفاده‌شده در مدل جنگل تصادفی بدون متغیر گروه	۶۷
۹-۴	ویژگی‌های استفاده‌شده در مدل جنگل تصادفی با متغیر گروه	۶۷
۱۰-۴	نتایج ارزیابی مدل اولیه جنگل تصادفی	۶۷
۱۱-۴	نتایج ارزیابی مدل نهایی جنگل تصادفی	۶۸
۱۲-۴	ارزیابی نهایی مدل جنگل تصادفی با اعتبارسنجی متقاطع	۶۹
۱۳-۴	نتایج مدل اولیه جنگل تصادفی با گروه	۷۰
۱۴-۴	نتایج مدل نهایی جنگل تصادفی با گروه	۷۰
۱۵-۴	مدل نهایی جنگل تصادفی با گروه و اعتبارسنجی متقاطع	۷۰
۱۶-۴	ویژگی‌های استفاده‌شده در مدل رگرسیون بردار پشتیبان	۷۲
۱۷-۴	نتایج ارزیابی مدل اولیه رگرسیون بردار پشتیبان (هسته خطی) بر روی مجموعه آزمون	۷۲
۱۸-۴	نتایج ارزیابی مدل اولیه رگرسیون بردار پشتیبان (هسته چندجمله‌ای) بر روی مجموعه آزمون	۷۳
۱۹-۴	نتایج ارزیابی مدل اولیه رگرسیون بردار پشتیبان (هسته شعاعی) بر روی مجموعه آزمون	۷۳
۲۰-۴	نتایج ارزیابی مدل رگرسیون بردار پشتیبان (با هسته شعاعی و مقیاس‌بندی مقاوم) بر روی مجموعه آزمون	۷۴
۲۱-۴	ویژگی‌های استفاده‌شده در مدل افزایش گرادیان افراطی	۷۴
۲۲-۴	نتایج ارزیابی مدل اولیه افزایش گرادیان افراطی بر روی مجموعه آزمون	۷۵
۲۳-۴	نتایج ارزیابی مدل بهینه‌شده افزایش گرادیان افراطی بر روی مجموعه آزمون	۷۶
۲۴-۴	ویژگی‌های استفاده‌شده در مدل تقویت دسته‌ای	۷۶
۲۵-۴	نتایج ارزیابی مدل اولیه تقویت دسته‌ای بر روی مجموعه آزمون	۷۷

۷۸	۴-۲۶ نتایج ارزیابی مدل بهینه‌شده تقویت دسته‌ای بر روی مجموعه آزمون
۷۸	۴-۲۷ نتایج ارزیابی مدل تقویت دسته‌ای (با پر کردن داده‌های ناقص و مقیاس‌دهی استاندارد) بر روی مجموعه آزمون
۷۹	۴-۲۸ ویژگی‌های استفاده‌شده در مدل شبکه عصبی چندلایه
۷۹	۴-۲۹ نتایج ارزیابی مدل اولیه شبکه عصبی چندلایه بر روی مجموعه آزمون
۸۰	۴-۳۰ ویژگی‌های استفاده‌شده در مدل شبکه عصبی عمیق
۸۱	۴-۳۱ نتایج ارزیابی مدل اولیه شبکه عصبی عمیق بر روی مجموعه آزمون
۸۵	۵-۱ مقایسه عملکرد مدل‌ها بر اساس معیارهای ارزیابی
۸۶	۵-۲ درصد بهبود مدل بهینه (تقویت دسته‌ای اولیه) نسبت به سایر مدل‌ها

چکیده

یادگیری ماشین^۱ به عنوان یکی از شاخه های برجسته هوش مصنوعی، در دهه های اخیر با رشد چشمگیری در صنایع مختلف از جمله کشاورزی، سلامت، و تولید مواجه شده است. این فناوری با بهره گیری از الگوریتم های پیشرفته، امکان تحلیل داده های پیچیده را فراهم کرده و تصمیم گیری های مبتنی بر داده را بهبود بخشیده است. در صنعت دامداری، داده و استفاده از روابط داده ها نقش کلیدی در بهینه سازی تولید و مدیریت گله ها ایفا می کند و با افزایش حجم داده های ثبت شده، روند استفاده از این روش ها از مدل های آماری سنتی به سمت روش های هوشمند مبتنی بر یادگیری ماشین سوق یافته است.

دوره انتقال^۲، شامل سه هفته پیش و سه هفته پس از زایش گاوهای شیری، دوره ای حساس است که تغییرات فیزیولوژیکی و متابولیکی گسترده ای را به همراه دارد. این تغییرات می توانند بر سلامت گاو و موفقیت دوره شیردهی تأثیر بگذارند. در این میان، شاخص دوره انتقال^۳ به عنوان ابزاری برای ارزیابی غیرمستقیم مدیریت گله در دوره انتقال معرفی شده است. این شاخص از تفاوت مقدارهای پیش بینی شده و مقدار واقعی برای اولین رکورد شیردهی به دست می آید و انحراف به دست آمده به عنوان معیاری برای کیفیت مدیریت در این دوره بحرانی به کار می رود. با این حال، روش های مستقیم مانند پروفایل خونی گاو نیز وجود دارند؛ اما به دلیل خطاهایی که ممکن است داشته باشند و هزینه های بالای آن ها، استفاده از این روش ها محدود شده است. هدف این پژوهش، توسعه و مقایسه مدل های پیش بینی برای تخمین اولین رکورد شیردهی گاو ها با استفاده از داده های دوره های شیردهی پیشین^۴ و داده های روزهای تست^۵ است. این کار به منظور ارائه ابزاری نوین برای ارزیابی مدیریت دوره انتقال انجام شده است. برای این منظور، مجموعه ای جامع از داده های واقعی مربوط به دامداری های کل کشور جمع آوری و سازماندهی شده است. این داده ها از طریق همکاری با تعاونی دامداران وحدت استان اصفهان، به عنوان یک مرکز داده ملی، گردآوری شده اند. این مجموعه داده شامل اطلاعات ۳۴۵،۶۷۶ رأس گاو و ۹۹ گله است که از سال ۱۳۹۰ تا ۱۴۰۱ جمع آوری شده اند.

مدل های پیش بینی شامل رگرسیون ریدج اولیه^۶، رگرسیون ریدج بهینه شده، جنگل تصادفی اولیه^۷، جنگل تصادفی بهینه شده، جنگل تصادفی با اعتبارسنجی متقاطع نهایی، جنگل تصادفی اولیه با استفاده از گروه بندی، جنگل تصادفی بهینه شده با استفاده از گروه بندی، جنگل تصادفی با استفاده از گروه بندی و اعتبارسنجی متقاطع نهایی، رگرسیون بردار پشتیبانی^۸ با هسته^۹ خطی^{۱۰}، رگرسیون بردار پشتیبانی با هسته چندجمله ای^{۱۱}، رگرسیون بردار پشتیبانی با هسته شعاعی^{۱۲}، رگرسیون بردار پشتیبانی با هسته شعاعی و با مقیاس پذیری مقاوم داده ها، افزایش گرادیدان افراطی^{۱۳}، افزایش گرادیدان افراطی بهینه شده، تقویت دسته ای اولیه^{۱۴}، تقویت دسته ای بهینه شده، تقویت دسته ای با مقیاس پذیری استاندارد داده ها، شبکه عصبی چندلایه^{۱۵}، و شبکه عصبی عمیق^{۱۶} هستند که برای پیش بینی اولین رکورد شیردهی به کار گرفته شده اند. عملکرد این مدل ها با استفاده از معیارهای ضریب تعیین^{۱۷}، میانگین قدرمطلق خطا^{۱۸}، ریشه میانگین مربع خطا^{۱۹}، درصد خطای میانگین^{۲۰}، میانگین قدرمطلق درصد خطای متقارن^{۲۱}، و انحراف

¹Machine Learning

²Transition period

³Transition Cow Index (TCI)

⁴Previous Lactation

⁵Test Days

⁶Ridge Regression

⁷Random Forest

⁸Support Vector Regression(SVR)

⁹Kernel

¹⁰Linear

¹¹Polynomial

¹²RBF

¹³XGBoost

¹⁴CatBoost

¹⁵MultiLayer Perceptron(MLP)

¹⁶Deep Neural Network(DNN)

¹⁷R-squared (R²)

¹⁸Mean Absolute Error (MAE)

¹⁹Root Mean Squared Error (RMSE)

²⁰Mean Percentage Error (MPE)

²¹Symmetric Mean Absolute Percentage Error (sMAPE)

استاندارد نسبی^۱ ارزیابی شده‌اند.

نتایج نشان داد که مدل تقویت دسته‌ای اولیه، بهترین عملکرد را با ضریب تعیین ۰/۴۰۱۵ و میانگین قدرمطلق خطا ۶/۴۳۸۲ داشته است. عملکرد و دقت مدل تقویت دسته‌ای اولیه با ضریب تعیین و میانگین قدرمطلق خطا، نسبت به مدل فعلی مورد استفاده در تعاونی وحدت استان اصفهان که ضریب تعیین حدود ۰/۳۰ دارد، تقریباً ۱۰ درصد بهبود در دقت پیش‌بینی را نشان می‌دهد. همچنین، این مدل در مقایسه با سایر مدل‌های ارزیابی‌شده، بهترین عملکرد را داشته است. برای مثال، نسبت به مدل شبکه عصبی چندلایه با ضریب تعیین ۰/۳۷، حدود ۳/۱۴ درصد بهبود در ضریب تعیین دارد. در مقایسه با مدل جنگل تصادفی بهینه‌شده با ۰/۳۵۷۵، بهبود حدود ۴/۱۴ درصد، و نسبت به رگرسیون بردار پشتیبانی با هسته شعاعی با ۰/۳۶۴۳، بهبود حدود ۳/۷۲ درصد مشاهده می‌شود. این مدل همچنین نسبت به مدل افزایش گرادیان افراطی بهینه‌شده با ۰/۳۷۳، حدود ۲/۸۵ درصد عملکرد بهتری ارائه می‌دهد. این نتایج نشان‌دهنده برتری قابل‌توجه مدل تقویت دسته‌ای اولیه نسبت به سایر مدل‌های بررسی‌شده و مدل فعلی تعاونی وحدت استان اصفهان است.

برای تحقیقات آینده، پیشنهاد می‌شود تمرکز بر استفاده و بهینه‌سازی الگوریتم‌های پیشرفته‌تر شبکه‌های عصبی مصنوعی، مانند مدل‌های عمیق‌تر، باشد تا دقت پیش‌بینی و انعطاف‌پذیری مدل‌ها در شرایط مختلف بهبود یابد.

کلمات کلیدی: دوره انتقال، مدیریت دامداری، یادگیری ماشین، پیش‌بینی شیر، اولین رکورد شیردهی^۱

¹Standard Deviation Ratio (SDR)

¹First Test Day Milk Yield

فصل اول

مقدمه

۱-۱ انگیزه و اهمیت تحقیق

دوره انتقال، شامل سه هفته پیش از زایش تا سه هفته پس از آن، به عنوان یکی از حساس ترین مراحل چرخه تولید در دامداری های صنعتی شناخته می شود، زیرا تغییرات فیزیولوژیکی شدید و وقوع بیماری های متابولیک و عفونی (مانند کتوز و جابه جایی شکمبه) می تواند سلامت دام و موفقیت دوره شیردهی را به خطر اندازد [۱، ۲، ۸]. این چالش ها نه تنها بر تولید شیر تأثیر منفی می گذارند، بلکه با افزایش نرخ حذف دام ها و کاهش شاخص های اقتصادی، بار مالی قابل توجهی بر دامداری ها تحمیل می کنند. پیش بینی دقیق عملکرد شیر در اولین روز تست پس از زایش، ابزاری کلیدی برای ارزیابی موفقیت برنامه های مدیریت دوره انتقال و شناسایی زود هنگام مشکلات سلامتی است. با افزایش حجم داده های جمع آوری شده از دامداری ها، استفاده از الگوریتم های یادگیری ماشین برای تحلیل این داده ها و پیش بینی عملکرد شیر اهمیت روزافزونی یافته است [۵].

برای ارزیابی کیفیت مدیریت در این دوره، شاخص دوره انتقال به عنوان ابزاری غیرمستقیم و مبتنی بر عملکرد تولیدی معرفی شده است که با مقایسه مقدار پیش بینی شده و واقعی اولین رکورد شیردهی، انحرافات ناشی از مدیریت نادرست را نشان می دهد [۳]. با این حال، روش های سنتی مانند تحلیل متابولیک خون، به دلیل هزینه بالا و خطاهای احتمالی، کارایی محدودی دارند [۴]. در مقابل، پیشرفت در جمع آوری داده های تاریخی و

استفاده از تکنیک‌های یادگیری ماشین، امکان توسعه ابزارهای خودکار و دقیق برای پایش سلامت و پیش‌بینی تولید را فراهم کرده است [۶]. این ابزارها نه تنها به بهبود مدیریت گله کمک می‌کنند، بلکه می‌توانند در طراحی استراتژی‌های ژنتیکی، بهینه‌سازی تغذیه، و تصمیم‌گیری‌های کلان در صنعت دامداری نقش اساسی ایفا کنند [۷].

پژوهش حاضر با بهره‌گیری از داده‌های تاریخی و الگوریتم‌های نوین یادگیری ماشین، به دنبال ارائه مدلی برای پیش‌بینی اولین رکورد شیردهی گاوها است. این تلاش با توجه به تنوع عوامل مؤثر مانند شرایط محیطی و تولید دوره‌های پیشین، و نیاز به کنترل نویزهای غیرمدیریتی، از اهمیت ویژه‌ای برخوردار است و می‌تواند گامی مؤثر در جهت پایداری اقتصادی و سلامتی دام‌ها باشد.

۱-۲ تعریف مسئله

دوره انتقال، به دلیل پیچیدگی‌های زیستی و مدیریتی، یکی از چالش‌برانگیزترین مراحل در تولید شیر گاوهای شیری محسوب می‌شود. پیش‌بینی دقیق اولین رکورد شیردهی پس از زایمان، به عنوان ورودی کلیدی شاخص دوره انتقال، نیازمند مدلی است که بتواند داده‌های تاریخی، از جمله روزهای تست^۱ و دوره‌های شیردهی پیشین، را با دقت تحلیل کند و تأثیر عوامل غیرمدیریتی (مانند فصل زایش، تعداد شکم زایش، و تولید دوره‌های قبلی) را از انحرافات ناشی از مدیریت تفکیک نماید [۸، ۹، ۱۰]. روش‌های سنتی، مانند استفاده از منحنی‌های دوره شیردهی (لاکتاسیون) مانند مدل وود یا تحلیل متابولیک، به دلیل وابستگی به داده‌های محدود اولیه، هزینه‌های بالای آزمایشگاهی، و ناتوانی در در نظر گرفتن الگوهای فردی، اغلب ناکارآمد هستند [۶، ۱۱].

در این پژوهش، مسئله اصلی توسعه الگویی داده‌محور است که با بهره‌گیری از داده‌های گسترده تاریخی روزهای تست و دوره‌های شیردهی پیشین، مقدار واقعی اولین رکورد شیردهی را پیش‌بینی کند. این مدل می‌تواند با استفاده از تکنیک‌های پیشرفته یادگیری ماشین، از جمله یادگیری عمیق، الگوهای پنهان در داده‌ها را استخراج کرده و به پیش‌بینی دقیق‌تر کمک کند [۱۰]. تفاوت میان مقدار پیش‌بینی شده و واقعی، به عنوان شاخصی برای ارزیابی کیفیت مدیریت در سطح گله به کار می‌رود، به ویژه با میانگین‌گیری که نویزهای فردی را کاهش می‌دهد [۳]. با این حال، چالش‌هایی مانند کمبود داده در هفته‌های اولیه لاکتاسیون، تأثیر متغیرهای محیطی پیچیده، و نیاز به مدیریت نویزهای غیرمدیریتی، دقت مدل‌ها را تحت الشعاع قرار می‌دهد. بنابراین، استفاده از الگوریتم‌های انعطاف‌پذیر و قدرتمند، مانند شبکه‌های عصبی کانولوشنی، جنگل‌های تصادفی، و الگوریتم‌های مبتنی بر روش تقویت (مانند افزایش گرادیان افراطی و تقویت دسته‌ای)، که قادر به پردازش این پیچیدگی‌ها و بهبود پیش‌بینی‌ها

^۱ Test Day Records - TDRs

باشند، ضروری به نظر می‌رسد [۵، ۸].

۳-۱ اهداف تحقیق

این پژوهش با هدف‌های زیر طراحی و اجرا شده است: ابتدا، انجام تحلیل و بررسی داده‌های یک دامداری با استفاده از ابزارهای آماری و ترسیم نمودارهای تحلیلی برای شناسایی الگوها و ویژگی‌های کلیدی داده‌ها، به‌منظور پشتیبانی از تصمیم‌گیری‌های مدیریتی انجام می‌شود. سپس، توسعه الگوریتم‌های مبتنی بر یادگیری ماشین، شامل رگرسیون ريج، جنگل‌های تصادفی، رگرسیون بردار پشتیبانی، افزایش گرادیان افراطی، تقویت دسته‌ای، و شبکه‌های عصبی، برای پیش‌بینی دقیق اولین رکورد شیردهی گاوهای شیری با بهره‌گیری از داده‌های دوره‌های شیردهی پیشین و روزهای آزمایش دنبال می‌شود. در نهایت، مقایسه عملکرد این مدل‌ها با استفاده از شش معیار ارزیابی، شامل ضریب تعیین، میانگین قدرمطلق خطا، ریشه میانگین مربع خطا، درصد خطای میانگین، میانگین قدرمطلق درصد خطای متقارن، و انحراف استاندارد نسبی، انجام می‌شود تا بهترین مدل برای پیش‌بینی انتخاب گردد. این فرآیند، علاوه بر بهبود دقت پیش‌بینی، به‌عنوان ابزاری برای ارزیابی غیرمستقیم کیفیت مدیریت دوره انتقال در سطح گله نیز به کار می‌رود.

۴-۱ ساختار گزارش

در فصل اول به بیان انگیزه، تعریف مسئله، اهداف، و ساختار کلی گزارش پرداخته می‌شود. در فصل دوم، مفاهیم پایه و کلیدی یادگیری ماشین، از جمله بیش‌برازش، کم‌برازش، و اعتبارسنجی متقاطع، و ... به همراه توضیحات کامل مدل‌های به‌کاررفته در پژوهش، شامل رگرسیون ريج، جنگل‌های تصادفی، رگرسیون بردار پشتیبانی، افزایش گرادیان افراطی، تقویت دسته‌ای، شبکه‌های عصبی چندلایه، و شبکه‌های عصبی عمیق، ارائه می‌شود. همچنین، شش معیار ارزیابی شامل ضریب تعیین، میانگین قدرمطلق خطا، ریشه میانگین مربع خطا، درصد خطای میانگین، میانگین قدرمطلق درصد خطای متقارن، و انحراف استاندارد نسبی به همراه فرمول‌های مربوطه توضیح داده می‌شود. در ادامه، فصل سوم به بررسی مقالات مرتبط و رویکردهای موجود در پیش‌بینی تولید شیر اختصاص دارد. سپس، فصل چهارم ابتدا به تحلیل داده‌های یک دامداری با هدف آشنایی بهتر با مفهوم شاخص دوره انتقال می‌پردازد. پس از آن، مراحل آماده‌سازی داده‌ها، از جمله پاک‌سازی و سازمان‌دهی، و فرآیند آموزش و تنظیم پارامترهای مدل‌ها شرح داده می‌شود. در نهایت، فصل پنجم به مقایسه نتایج مدل‌ها با استفاده از معیارهای ارزیابی، تحلیل کمی و کیفی عملکرد آن‌ها، می‌پردازد.

فصل دوم

پیش‌زمینه نظری

۱-۲ مقدمه

در این فصل، مفاهیم پایه‌ای مرتبط با یادگیری ماشین، به‌ویژه در زمینه مدل‌سازی پیش‌بینی معرفی می‌شوند. درک این مفاهیم برای تحلیل داده‌ها، انتخاب و پیاده‌سازی مدل‌های مناسب، و تفسیر نتایج در پژوهش حاضر ضروری است. مباحثی همچون تقسیم‌بندی داده‌ها^۱، مقیاس‌بندی^۲، بیش‌برازش^۳ و کم‌برازش^۴، اعتبارسنجی متقاطع^۵، بهینه‌سازی با استفاده از نزول گرادینت^۶، ناخالصی جینی^۷، اطلاعات کسب شده^۸، مدل‌های یادگیری ماشین، و معیارهای ارزیابی عملکرد مدل، از جمله موضوعاتی هستند که در ادامه به آن‌ها پرداخته می‌شود.

^۱Data Splitting

^۲Scaling

^۳Overfit

^۴Underfit

^۵Cross-Validation

^۶Gradient descent

^۷Gini Impurity

^۸Information Gain

۲-۲ تقسیم‌بندی داده‌ها

یادگیری ماشین به شاخه‌ای از هوش مصنوعی اطلاق می‌شود که در آن سیستم‌ها با استفاده از داده‌ها، الگوهایی را می‌آموزند و از آن‌ها برای پیش‌بینی یا تصمیم‌گیری بهره می‌برند. در این تحقیق، تمرکز بر یادگیری تحت نظارت^۱ است، که در آن هر نمونه آموزشی شامل ورودی و خروجی متناظر است. برای آموزش و ارزیابی مدل‌ها، داده‌ها معمولاً به سه مجموعه تقسیم می‌شوند:

۱. داده‌های آموزشی: برای یادگیری پارامترهای مدل

۲. داده‌های اعتبارسنجی: برای تنظیم پارامترهای قابل تنظیم

۳. داده‌های آزمون: برای ارزیابی نهایی مدل

تقسیم‌بندی مناسب داده‌ها از اهمیت بالایی برخوردار است و نقش کلیدی در جلوگیری از بیش‌برازش ایفا می‌کند.

۳-۲ مقیاس‌بندی داده‌ها

مقیاس‌بندی داده‌ها در بسیاری از الگوریتم‌های یادگیری مانند رگرسیون و ماشین بردار پشتیبانی، برای بهبود همگرایی و دقت مدل ضروری است. سه روش متداول برای مقیاس‌بندی عبارت‌اند از:

۱. مقیاس‌بندی استاندارد^۲

در این روش، مقدار هر ویژگی با کم کردن میانگین و تقسیم بر انحراف معیار، به داده‌ای با میانگین ۰ و انحراف معیار ۱ تبدیل می‌شود:

$$x' = \frac{x - \mu}{\sigma}$$

که در آن μ میانگین و σ انحراف معیار داده است.

۲. مقیاس‌بندی مین‌مکس^۳

در این روش، داده‌ها به بازه $[0, 1]$ نگاشت می‌شوند:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

که در آن $x_{\min}$ و $x_{\max}$ به ترتیب کمینه و بیشینه مقدار ویژگی هستند.

¹Supervised Learning

²Standard Scaling

³Min-Max Scaling

۳. مقیاس‌بندی مقاوم^۱

در این روش که به‌ویژه در برابر داده‌های پرت مقاوم است، از میانه و فاصله بین چارک اول و سوم استفاده می‌شود:


$$x' = \frac{x - \text{Median}}{IQR}$$

که $IQR = Q3 - Q1$ فاصله بین چارک سوم و اول داده است.

۴-۲ بیش‌برازش و کم‌برازش

یکی از چالش‌های اصلی در یادگیری ماشین، مدیریت پدیده‌های بیش‌برازش و کم‌برازش است که بر عملکرد و تعمیم‌پذیری مدل‌ها تأثیر می‌گذارند. این دو مفهوم به رفتار مدل در برابر داده‌های آموزشی و داده‌های نادیده (داده‌های آزمایشی) مربوط می‌شوند.

- **بیش‌برازش:** این پدیده زمانی رخ می‌دهد که مدل بیش از حد به داده‌های آموزشی وابسته شود و الگوهای نویزی یا خاص آن‌ها را به‌عنوان الگوهای کلی بیاموزد. نتیجه این امر، کاهش توانایی مدل در تعمیم‌پذیری به داده‌های جدید است. به عنوان مثال، اگر مدل پیچیدگی بالایی داشته باشد (مانند شبکه‌های عصبی با لایه‌های زیاد)، ممکن است به جای یادگیری ساختار اصلی داده‌ها، به جزئیات بی‌اهمیت توجه کند.
- **کم‌برازش:** این حالت زمانی رخ می‌دهد که مدل بیش از حد ساده باشد و نتواند ساختار یا الگوهای موجود در داده‌ها را به‌خوبی یاد بگیرد. در این شرایط، مدل نه تنها روی داده‌های آزمایشی، بلکه حتی روی داده‌های آموزشی نیز عملکرد ضعیفی دارد. برای مثال، استفاده از یک مدل خطی برای داده‌های غیرخطی می‌تواند منجر به کم‌برازش شود.



شکل ۲-۱: نمودار کم‌برازش در مقابل تعادل و بیش‌برازش

^۱ Robust Scaling

برای کنترل این پدیده‌ها، می‌توان از روش‌هایی مانند استفاده از داده‌های اعتبارسنجی برای ارزیابی تعمیم‌پذیری، اعمال منظم‌سازی (مانند منظم‌سازی $L2$ در رگرسیون ريج) برای کاهش پیچیدگی مدل، و انتخاب بهینه پیچیدگی مدل با تکنیک‌هایی مانند اعتبارسنجی متقاطع استفاده کرد. این رویکردها به تعادل بین دقت و تعمیم‌پذیری کمک می‌کنند و از افت عملکرد مدل در شرایط واقعی جلوگیری می‌نمایند.

۲-۵ اعتبارسنجی متقاطع

برای ارزیابی پایدار مدل‌ها، از روش اعتبارسنجی متقاطع استفاده می‌شود. در اعتبارسنجی k -بخشی، داده‌ها به k بخش مساوی تقسیم شده و هر بار یک بخش برای آزمون و باقی برای آموزش استفاده می‌شوند. میانگین عملکرد تمام تکرارها به عنوان عملکرد نهایی مدل گزارش می‌شود.

۲-۶ روش نزول گرادیان

۲-۶-۱ تابع هزینه^۱ چیست؟

تابع هزینه معیاری است که اختلاف بین خروجی پیش‌بینی شده توسط مدل و مقدار واقعی داده‌ها را اندازه‌گیری می‌کند. هدف اصلی، کمینه کردن این تابع است تا پارامترهای بهینه یافت شوند. برای رگرسیون خطی، تابع هزینه معمولاً میانگین مربعات خطاها تعریف می‌شود:

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x_i) - y_i)^2$$

که در آن $J(\theta)$ تابع هزینه، $h_{\theta}(x_i)$ پیش‌بینی مدل، y_i مقدار واقعی، و m تعداد نمونه‌هاست.

۲-۶-۲ نزول گرادیان چیست؟

نزول گرادیان یک الگوریتم بهینه‌سازی است که با تنظیم پارامترها در جهت مخالف گرادیان تابع هزینه، به کمینه آن می‌رسد. این روش مانند حرکت به سمت پایین‌ترین نقطه دره‌ای است که با محاسبه شیب تابع انجام می‌شود. این الگوریتم پایه‌ای برای آموزش مدل‌هایی مانند شبکه‌های عصبی است.


۲-۶-۳ نحوه کار نزول گرادیان چگونه است؟

نزول گرادیان با محاسبه گرادیان تابع هزینه در نقطه فعلی آغاز می‌شود. پارامترها با فرمول زیر به‌روزرسانی می‌شوند:

$$\theta_j := \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j}$$

^۱ Cost Function

که در آن پارامترها، α نرخ یادگیری، و $\frac{\partial J(\theta)}{\partial \theta_j}$ گرادیان تابع هزینه نسبت به پارامتر j است. این فرآیند تکراری است تا تابع هزینه به کمینه برسد.




شکل ۲-۲: نحوه کار نزول گرادیان در بهینه‌سازی

۲-۶-۴ آلفا - نرخ یادگیری^۱

نرخ یادگیری (α) اندازه قدم‌ها در هر تکرار است. اگر α بزرگ باشد، مدل ممکن است از کمینه عبور کند؛ اگر کوچک باشد، فرآیند کند می‌شود. فرمول به‌روزرسانی با نرخ یادگیری نشان می‌دهد که تعادل آن حیاتی است:

$$\theta_{new} = \theta_{old} - \alpha \cdot \nabla J(\theta)$$

تصویر ۲-۳ تأثیر نرخ‌های مختلف را با نمودار مقایسه می‌کند.




شکل ۲-۳: تأثیر نرخ یادگیری بر فرآیند بهینه‌سازی

^۱ Learning rate

۲-۶-۵ کمینه‌های محلی

کمینه‌های محلی نقاطی هستند که تابع هزینه در آن‌ها کاهش می‌یابد اما کمینه سراسری نیستند. مدل ممکن است در این نقاط گیر کند، به‌ویژه در توابع غیرخطی. تصویر ۲-۴ این وضعیت را نشان می‌دهد.



شکل ۲-۴: کمینه‌های محلی در تابع هزینه

۲-۶-۶ مزایا و معایب

نزول گرادیان دارای مزایای قابل‌توجهی است که از جمله آن‌ها می‌توان به سرعت بالا در بهینه‌سازی به‌ویژه در نسخه‌های کوچک‌دسته‌ای^۱ برای داده‌های بزرگ اشاره کرد. این الگوریتم همچنین انعطاف‌پذیری بالایی دارد و می‌تواند برای انواع مدل‌ها مانند رگرسیون و شبکه‌های عصبی به کار رود، همچنین با تنظیم مناسب پارامترها امکان استفاده در مسائل پیچیده را فراهم می‌کند. با این حال، این روش با معایبی نیز همراه است؛ حساسیت به نرخ یادگیری نامناسب می‌تواند منجر به همگرایی ناقص شود و خطر به دام افتادن در کمینه‌های محلی در توابع غیرخطی وجود دارد. علاوه بر این، نیاز به محاسبات تکراری زیاد برای داده‌های بزرگ، این الگوریتم را در برخی موارد چالش‌برانگیز می‌کند.

مقایسه انواع روش‌های نزول گرادیان

انواع مختلف نزول گرادیان، از جمله نزول گرادیان ساده^۲، نزول گرادیان تصادفی^۳، و نزول گرادیان کوچک‌دسته‌ای^۴، هر یک ویژگی‌ها و کاربردهای خاص خود را دارند. جدول زیر این روش‌ها را از نظر نحوه محاسبه گرادیان، سرعت، دقت، و کاربردها مقایسه می‌کند:

^۱ Mini-Batch

^۲ Batch Gradient Descent (BGD)

^۳ Stochastic Gradient Descent (SGD)

^۴ Mini-Batch Gradient Descent

جدول ۲-۱: مقایسه انواع روش‌های نزول گرادیان

ویژگی / روش	گرادیان ساده	گرادیان تصادفی	گرادیان مینی بچ
واحد به‌روزرسانی پارامترها	کل مجموعه داده	یک نمونه تصادفی	دسته‌های کوچک
سرعت همگرایی	پایدار ولی کند	سریع ولی پرنوسان	تعادل میان سرعت و پایداری
نیاز حافظه	بالا	کم	متوسط
احتمال گیر کردن در مینیمم محلی	بیشتر	کمتر به دلیل نویز تصادفی	کمتر
مناسب برای داده‌های بزرگ	خیر	بله	بله
نوسان در مسیر گرادیان	ندارد	زیاد	کنترل شده
پیاده‌سازی ساده	بله	بله	نسبتاً پیچیده‌تر

۲-۲ ناخالصی جینی^۱

یکی از معیارهای رایج برای سنجش کیفیت تقسیم داده‌ها در مدل‌های مبتنی بر درخت، ناخالصی جینی است. این معیار برای مسائل دسته‌بندی^۲ به کار می‌رود و میزان اختلاط یا عدم خلوص نمونه‌های موجود در یک گره را اندازه‌گیری می‌کند.

اگر در یک گره خاص، نسبت نمونه‌های متعلق به دسته k ام برابر با p_k باشد، مقدار ناخالصی جینی برای آن گره از رابطه زیر محاسبه می‌شود:

$$\text{Gini} = 1 - \sum_{k=1}^K p_k^2$$

که در آن:

• K تعداد کل دسته‌های ممکن است.

• p_k احتمال حضور داده در دسته k ام در آن گره است.

مقدار این معیار همیشه بین ۰ و ۱ قرار دارد. اگر تمام نمونه‌های یک گره متعلق به یک دسته باشند، مقدار ناخالصی برابر با صفر خواهد بود که نشان‌دهنده خالص بودن گره است. هرچه توزیع نمونه‌ها در گره یکنواخت‌تر باشد (یعنی بین چند دسته پخش شده باشند)، مقدار ناخالصی افزایش می‌یابد. در هنگام ساخت درخت، برای هر تقسیم ممکن، مقدار ناخالصی گره‌های حاصل از تقسیم محاسبه می‌شود و تقسیماتی انتخاب می‌شوند که ناخالصی کلی را کاهش دهند.

¹Gini Impurity

²Classification

۲-۸ اطلاعات کسب شده^۱

یکی دیگر از معیارهای متداول برای ارزیابی کیفیت تقسیم در درخت‌های تصمیم، اطلاعات کسب شده است که بر پایه مفهوم آنتروپی^۲ تعریف می‌شود. این معیار نیز معمولاً در مسائل دسته‌بندی کاربرد دارد. آنتروپی یک گره به صورت زیر تعریف می‌شود:

$$\text{Entropy} = - \sum_{k=1}^K p_k \log_2(p_k)$$

که در آن:

- K تعداد دسته‌ها است.
 - p_k احتمال حضور یک نمونه در دسته k ام در آن گره است.
- آنتروپی بیانگر میزان بی‌نظمی یا عدم قطعیت درون گره است. هرچه نمونه‌های یک گره به دسته‌های مختلف تعلق داشته باشند، مقدار آنتروپی بیشتر خواهد بود. اطلاعات کسب شده برای یک تقسیم خاص برابر است با:

$$\text{Gain Information} = \text{Entropy}_{\text{پیش از تقسیم}} - \sum_i \frac{n_i}{n} \cdot \text{Entropy}_i$$

که در آن:

- n تعداد کل نمونه‌های گره مادر است.
 - n_i تعداد نمونه‌های هر گره فرزند پس از تقسیم است.
 - Entropy_i آنتروپی گره i ام است.
- هدف الگوریتم در ساخت درخت، انتخاب تقسیم‌هایی است که بیشترین کاهش آنتروپی و در نتیجه بیشترین کسب اطلاعات را ایجاد کنند.

۲-۹ مدل‌های مورد استفاده

در این پروژه از چندین مدل یادگیری ماشین برای پیش‌بینی مقدار اولین رکورد شیردهی گاو استفاده شده است. در ادامه، هر یک از این مدل‌ها با جزئیات بیشتری از نظر سازوکار ریاضی و نحوه عملکرد معرفی می‌گردند.

^۱Information Gain

^۲Entropy

۲-۹-۱ رگرسیون ريج^۱

یکی از چالش‌های رایج در مدل‌سازی رگرسیون خطی، هم‌خطی چندگانه^۲ میان ویژگی‌ها و همچنین بیش‌برازش مدل به داده‌های آموزشی است. روش رگرسیون ريج که با عنوان رگرسیون خطی با منظم‌سازی $L2$ ^۳ نیز شناخته می‌شود، برای کاهش این مشکلات ارائه شده است.

در مدل رگرسیون خطی معمولی، هدف یافتن بردار ضرایب w است به گونه‌ای که مجموع مجزورات خطای مدل بر داده‌های آموزشی حداقل شود:

$$\min_w \sum_{i=1}^n (y_i - w^\top x_i)^2$$

اما در رگرسیون ريج، برای جلوگیری از بزرگ شدن بیش از حد ضرایب، یک جمله‌ی جریمه (پنالتی) به تابع هدف افزوده می‌شود:

$$\min_w \sum_{i=1}^n (y_i - w^\top x_i)^2 + \lambda \|w\|_2^2$$

که در آن:

- x_i بردار ویژگی‌های نمونه‌ی i ام است.
- y_i خروجی یا مقدار هدف برای نمونه‌ی i ام است.
- w بردار ضرایب مدل است.
- $\lambda \geq 0$ پارامتر منظم‌سازی است که شدت جریمه را کنترل می‌کند.
- $\|w\|_2^2 = \sum_{j=1}^p w_j^2$ مربع نرم $L2$ ضرایب است.

هنگامی که $\lambda = 0$ ، مدل معادل با رگرسیون خطی معمولی خواهد بود. با افزایش λ ، مدل به سمت کاهش اندازه ضرایب و در نتیجه جلوگیری از پیچیدگی بیش از حد گرایش پیدا می‌کند. در رگرسیون ريج همه ضرایب کوچک ولی غیرصفر باقی می‌مانند. بنابراین این روش زمانی مناسب است که انتظار می‌رود تمامی ویژگی‌ها تا حدودی در پیش‌بینی مؤثر باشند.

حل با استفاده از نزول گرادینان

در مسائل با داده‌های پرتعداد یا تعداد ویژگی‌های زیاد، حل تحلیلی مدل ممکن است دشوار یا ناکارآمد باشد. در این موارد، می‌توان از الگوریتم نزول گرادینان برای یافتن ضرایب استفاده کرد.

^۱Ridge Regression

^۲Multicollinearity

^۳L2-Regularized Linear Regression

تابع هزینه در این حالت به شکل زیر تعریف می‌شود:

$$J(w) = \frac{1}{n} \sum_{i=1}^n (y_i - w^\top x_i)^2 + \lambda \|w\|_2^2$$

در هر تکرار الگوریتم، بردار ضرایب w با استفاده از گرادیان تابع هزینه به‌روزرسانی می‌شود:

$$w \leftarrow w - \alpha \nabla J(w)$$

که در آن α نرخ یادگیری و گرادیان تابع هزینه به‌صورت برداری برابر است با:

$$\nabla J(w) = -\frac{2}{n} X^\top (y - Xw) + 2\lambda w$$

در نهایت، مدل رگرسیون ريج برای پیش‌بینی خروجی جدید به‌صورت زیر نوشته می‌شود:

$$\hat{y} = w^\top x + b$$

که در آن b مقدار بایاس (اختیاری) و $\hat{y}$ مقدار پیش‌بینی شده است.

۲-۹-۲ درخت تصمیم^۱

درخت تصمیم یکی از مدل‌های پایه‌ای، ساده و در عین حال مؤثر در یادگیری ماشین است که برای حل مسائل دسته‌بندی و رگرسیون به‌کار می‌رود. این مدل ساختاری درختی دارد که از تقسیم متوالی داده‌ها بر اساس ویژگی‌های آن‌ها تشکیل می‌شود.

هر درخت تصمیم از مجموعه‌ای از **گره‌های تصمیم**^۲ و **برگ‌ها**^۳ تشکیل شده است. در گره‌های تصمیم، بر اساس یک شرط مشخص (مثلاً "آیا ویژگی x_j از مقدار معینی کمتر است؟") داده‌ها به دو شاخه تقسیم می‌شوند و این روند تا رسیدن به گره‌های نهایی (برگ‌ها) ادامه می‌یابد. هر برگ بیانگر خروجی نهایی مدل برای داده‌هایی است که به آن گره رسیده‌اند.

فرایند ساخت درخت

مراحل کلی آموزش یک درخت تصمیم عبارت‌اند از:

- انتخاب بهترین ویژگی و مقدار آستانه برای تقسیم داده‌ها در هر گره. این انتخاب بر اساس معیارهایی مانند:

• ناخالصی جینی

^۱Decision Tree

^۲Decision Nodes

^۳Leaves

- اطلاعات کسب شده (بر اساس آنتروپی)
- میانگین مربعات خطا (برای مسائل رگرسیون)

صورت می‌گیرد.

۲. تقسیم داده‌ها به دو زیرمجموعه بر اساس ویژگی انتخاب شده.

۳. تکرار مرحله بالا به صورت بازگشتی تا زمانی که یکی از شرایط توقف برقرار شود:

- رسیدن به حداکثر عمق درخت
- تعداد نمونه‌های گره کمتر از مقدار آستانه
- خالص بودن داده‌های گره (برای مسائل رده‌بندی)

درخت تصمیم به دلیل سادگی و تفسیرپذیری خود برجسته است، زیرا خروجی آن به صورت سلسله‌مراتبی و قابل فهم برای انسان ارائه می‌شود. این مدل همچنین نیازی به نرمال‌سازی داده‌ها ندارد و نسبت به مقیاس ویژگی‌ها حساس نیست. از دیگر مزایای آن، پشتیبانی از ویژگی‌های عددی و طبقه‌ای است که امکان استفاده از هم داده‌های پیوسته و هم داده‌های گسسته را فراهم می‌سازد.

مدل ریاضی برای رگرسیون

در مسائل رگرسیون، مقدار خروجی هر برگ به صورت میانگین مقادیر هدف داده‌هایی که به آن گره رسیده‌اند تعریف می‌شود. بنابراین مدل کلی برای پیش‌بینی $\hat{y}$ به شکل زیر است:

$$\hat{y} = \frac{1}{|L(x)|} \sum_{i \in L(x)} y_i$$

که در آن:

- $L(x)$ مجموعه نمونه‌هایی است که در داده‌های آموزشی به همان برگ که x به آن تعلق می‌گیرد، رسیده‌اند.
- y_i مقدار هدف برای نمونه i ام است.

این مدل اگرچه ساده است، اما به‌تنهایی ممکن است دچار بیش‌برازش شود، و به همین دلیل در الگوریتم‌هایی مانند جنگل تصادفی یا افزایش گرادیان افراطی به صورت ترکیبی از چند درخت مورد استفاده قرار می‌گیرد.

۲-۹-۳ جنگل تصادفی^۱

جنگل تصادفی یکی از مدل‌های قدرتمند و پرکاربرد در یادگیری ماشین است که در مسائل دسته‌بندی و رگرسیون استفاده می‌شود. این مدل بر پایه الگوریتم درخت تصمیم ساخته شده و با ترکیب تعداد زیادی از درخت‌های تصمیم، دقت و پایداری مدل را افزایش می‌دهد.

مدل جنگل تصادفی از رویکرد یادگیری تجمعی^۲ بهره می‌برد؛ به این معنا که به‌جای تکیه بر یک مدل منفرد، مجموعه‌ای از مدل‌ها به‌طور موازی آموزش می‌بینند و خروجی نهایی بر اساس تجمیع تصمیم آن‌ها به‌دست می‌آید.

مراحل ساخت مدل

الگوریتم جنگل تصادفی شامل مراحل زیر است:

۱. با استفاده از روش نمونه‌گیری تکراری^۳ چندین نمونه تصادفی (با تکرار) از داده‌های آموزشی گرفته می‌شود.

۲. برای هر نمونه، یک درخت تصمیم مستقل ساخته می‌شود.

۳. در هر گره از هر درخت، به‌جای بررسی تمام ویژگی‌ها، تنها یک زیرمجموعه تصادفی از ویژگی‌ها برای تقسیم گره انتخاب می‌شود. این کار موجب تنوع بیشتر میان درخت‌ها می‌شود.

۴. برای پیش‌بینی یک نمونه جدید، خروجی تمام درخت‌ها محاسبه می‌شود:

- در رگرسیون: میانگین خروجی درخت‌ها به‌عنوان پیش‌بینی نهایی انتخاب می‌شود.

- در دسته‌بندی: از رای‌گیری اکثریت میان خروجی درخت‌ها استفاده می‌شود.

جنگل تصادفی با ترکیب چندین درختی که روی داده‌ها و ویژگی‌های متفاوت آموزش دیده‌اند، به کاهش بیش‌برازش کمک می‌کند و از این طریق مدل نهایی را از وابستگی بیش از حد به داده‌های آموزشی محافظت می‌کند. همچنین، این مدل از پایداری بالایی برخوردار است، زیرا حساسیت آن به داده‌های پرت یا نویز به‌طور قابل‌توجهی کاهش می‌یابد. از دیگر مزایای آن، قابلیت سنجش اهمیت ویژگی‌هاست که امکان ارزیابی میزان تأثیر هر ویژگی بر نتیجه نهایی را فراهم می‌سازد.

¹Random Forest

²Ensemble Learning

³Bootstrap Sampling

مدل ریاضی برای رگرسیون

فرض کنید $T_1(x), T_2(x), \dots, T_K(x)$ خروجی‌های K درخت تصمیم آموزش دیده باشند. در این صورت، پیش‌بینی نهایی مدل جنگل تصادفی برای ورودی x در مسئله رگرسیون به صورت زیر خواهد بود:

$$\hat{y} = \frac{1}{K} \sum_{k=1}^K T_k(x)$$

که در آن $\hat{y}$ خروجی پیش‌بینی شده و K تعداد درخت‌ها در جنگل است.

۲-۹-۴ رگرسیون بردار پشتیبان^۱

رگرسیون بردار پشتیبان یکی از انواع الگوریتم‌های ماشین بردار پشتیبان^۲ است و به طور رایج برای تحلیل‌های رگرسیونی مورد استفاده قرار می‌گیرد. الگوریتم‌های ماشین بردار پشتیبان، روش‌هایی قدرتمند در حوزه یادگیری با ناظر هستند که در اصل برای حل مسائل دسته‌بندی طراحی شده‌اند.

هدف الگوریتم ماشین بردار پشتیبان، یافتن ابرصفحه‌ای^۳ بهینه است که به بهترین شکل ممکن دو دسته را در فضای ویژگی از هم جدا کند. منظور از ابرصفحه، یک زیرفضای تخت با بُعد $p-1$ در فضای p -بعدی است که p برابر با تعداد ویژگی‌های ورودی می‌باشد. ابرصفحه بهینه، صفحه‌ای است که حاشیه^۴ را حداکثر می‌کند. منظور از حاشیه، فاصله بین ابرصفحه و نزدیک‌ترین نقاط از هر دسته است که به آن‌ها بردارهای پشتیبان^۵ گفته می‌شود.

رگرسیون بردار پشتیبان نیز همچون نسخه دسته‌بندی، بر مفهوم ابرصفحه و حاشیه تکیه دارد، اما تعریف این مفاهیم در آن متفاوت است. در رگرسیون بردار پشتیبان، حاشیه به صورت ناحیه تحمل خطا^۶ تعریف می‌شود. این ناحیه، یک نوار اطراف ابرصفحه را در نظر می‌گیرد که مقادیر خروجی تا میزان ε می‌توانند از آن انحراف داشته باشند بدون اینکه به عنوان خطا محسوب شوند.

ابرفصفحه در این مدل، بهترین برازش ممکن برای داده‌هایی است که درون این نوار قرار دارند. تفاوت اصلی میان مدل دسته‌بندی و رگرسیون در این است که در دسته‌بندی، هدف جداسازی داده‌ها است، اما در رگرسیون، هدف برازش داده‌ها در ناحیه‌ای مجاز از خطا است.

^۱Support Vector Regression(SVR)


^۲Support Vector Machine (SVM)

^۳Hyperplane

^۴Margin

^۵Support Vectors

^۶ ε -insensitive tube



شکل ۲-۵: تفاوت رگرسیون بردار پشتیبان و ماشین بردار پشتیبان

مبنای نظری مدل رگرسیون بردار پشتیبان

در مدل رگرسیون بردار پشتیبان، هدف یافتن بهترین تابع برازش است که بتواند مقدار متغیر هدف را به درستی پیش‌بینی کرده و هم‌زمان از نظر پیچیدگی نیز ساده باقی بماند تا از بیش‌برازش جلوگیری شود. برای تحقق این هدف، ناحیه‌ای به نام **نوار تحمل‌پذیر** پیرامون ابرصفحه تعریف می‌شود که اجازه می‌دهد مقدار پیش‌بینی‌شده تا حدی (ε) با مقدار واقعی تفاوت داشته باشد. این ناحیه سبب ایجاد تعادلی میان سادگی مدل و توانایی تعمیم آن به داده‌های جدید می‌شود.

این مدل به صورت یک **مسئله بهینه‌سازی محدب**^۱ فرموله می‌شود. هدف از این بهینه‌سازی، یافتن تابعی به صورت $f(x)$ است که تا حد ممکن **صاف**^۲ باشد و بیشینه انحراف آن از مقدار واقعی خروجی، برای تمامی داده‌های آموزشی، بیشتر از ε نباشد.

صاف بودن تابع بدین معناست که حساسیت آن نسبت به تغییرات کوچک در ورودی پایین باشد؛ در نتیجه خطر بیش‌برازش کاهش می‌یابد. در حالت تابع خطی، صاف بودن به این معناست که مقدار بردار وزن‌ها^۳ (w) در تابع $f(x) = wx + b$ کوچک باشد.

مدل ریاضی رگرسیون بردار پشتیبان

مدل رگرسیون بردار پشتیبان را می‌توان به صورت یک مسئله بهینه‌سازی محدب فرموله کرد که در آن هدف، یافتن تابعی است که تا حد امکان صاف باشد و از مقادیر خروجی واقعی داده‌ها، بیش از مقدار ε منحرف نشود. تابع هدف برای این مدل به صورت زیر تعریف می‌شود:

$$\min_{w, b, \xi_i, \xi_i^*} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*)$$

که در آن:

^۱Convex Optimization Problem

^۲Flat


^۳Weight Vector

- w بردار وزن‌ها در تابع خطی است.
 - b عرض از مبدأ است.
 - C یک پارامتر تنظیم^۱ است که بین پیچیدگی مدل و میزان خطا تعادل برقرار می‌کند.
 - ξ_i و ξ_i^* متغیرهای افزایشی هستند که میزان نقض ناحیه ε را در هر طرف ابرصفحه اندازه‌گیری می‌کنند.
- این بهینه‌سازی با رعایت محدودیت‌های زیر انجام می‌شود:

$$\begin{cases} y_i - (w^\top x_i + b) \leq \varepsilon + \xi_i \\ (w^\top x_i + b) - y_i \leq \varepsilon + \xi_i^* \\ \xi_i \geq 0, \quad \xi_i^* \geq 0 \end{cases}$$

که در آن:

- x_i نمونه ورودی i ام،
 - y_i و مقدار خروجی متناظر با آن است.
- هدف از کمینه‌سازی عبارت $\frac{1}{2}\|w\|^2$ ، تولید تابعی است که تا حد ممکن صاف باشد. در عین حال، جمله $\sum(\xi_i + \xi_i^*)$ میزان خطاهای خارج از ناحیه ε را اندازه می‌گیرد، و پارامتر C نقش وزنی برای این خطاها ایفا می‌کند.
- ترکیب این دو بخش، مدلی را می‌سازد که به خوبی تعادلی میان دقت، توانایی تعمیم و جلوگیری از پیچیدگی بیش‌ازحد ایجاد می‌کند.



شکل ۲-۶: مدل ریاضی و نمودار رگرسیون بردار پشتیبان


^۱ Regularization Parameter

در برخی موارد، ممکن است مسئله بهینه‌سازی قابل حل نباشد، یا بخواهیم اجازه دهیم مقدار کمی خطا در مدل وجود داشته باشد. برای این منظور، از متغیرهای افزایشی^۱ استفاده می‌شود. این متغیرها مربوط به داده‌هایی هستند که خارج از ناحیه تحمل‌پذیر ε قرار می‌گیرند. فاصله این نقاط از مرز ناحیه ε با نماد ξ نمایش داده می‌شود.

برای برقراری تعادل میان پیچیدگی مدل (یعنی صاف بودن تابع $f(x)$) و مجموع انحراف‌های فراتر از ناحیه ε ، از یک پارامتر منظم‌ساز با نماد $C > 0$ استفاده می‌شود. میزان قدرت این منظم‌سازی رابطه معکوس با مقدار C دارد؛ یعنی هرچه مقدار C بزرگ‌تر باشد، مدل تمایل بیشتری به کاهش خطاهای خارج از ناحیه ε خواهد داشت و در مقابل، صاف بودن تابع را کمتر در نظر می‌گیرد.

مدل رگرسیون بردار پشتیبان، برای نمونه‌هایی که درون ناحیه ε قرار دارند، خطای پیش‌بینی برابر با صفر در نظر می‌گیرد؛ اما برای داده‌هایی که بیرون از این ناحیه هستند (یعنی متغیرهای افزایشی)، جریمه‌ای متناسب با مقدار ξ اعمال می‌کند.

این ویژگی رگرسیون بردار پشتیبان را قادر می‌سازد تا در مقایسه با مدل‌های رگرسیون معمولی، بهتر با پدیده بیش‌برازش مقابله کند.



شکل ۲-۷: مدل ریاضی و نمودار رگرسیون بردار پشتیبان با متغیرهای افزایشی

رگرسیون غیرخطی با استفاده از تابع هسته

مدل رگرسیون بردار پشتیبان می‌تواند هم برای مسائل خطی و هم برای مسائل غیرخطی به کار رود. این قابلیت با استفاده از تابع هسته^۲ فراهم می‌شود.

در شرایطی که داده‌ها به صورت غیرخطی از یکدیگر قابل تفکیک هستند، از تابع هسته برای نگاشت داده‌ها

¹Slack Variables

²Kernel Function

به یک فضای با ابعاد بالاتر استفاده می‌شود؛ به طوری که در آن فضا بتوان یک مسئله خطی (و در نتیجه رگرسیون خطی) را حل کرد. در واقع، تابع هسته اجازه می‌دهد بدون نیاز به محاسبه مستقیم نگاشت به فضای جدید، مدل رگرسیون به صورت غیرخطی رفتار کند.

در میان توابع هسته که در رگرسیون بردار پشتیبان مورد استفاده قرار می‌گیرند، چهار نوع متداول‌تر وجود دارد. نخست، **هسته خطی**^۱ که ساده‌ترین نوع هسته است و معمولاً در مسائل با رابطه‌های تقریباً خطی میان متغیرها به کار می‌رود. دوم، **هسته چندجمله‌ای**^۲ است که قادر به مدل‌سازی روابط غیرخطی از طریق ترکیب‌های چندجمله‌ای میان ویژگی‌ها می‌باشد. سوم، **هسته پایه شعاعی**^۳ که قدرت بالایی در مدل‌سازی داده‌های پیچیده و غیرخطی دارد و از متداول‌ترین گزینه‌ها در مسائل مختلف یادگیری ماشین محسوب می‌شود. در نهایت، **هسته سیگموئید**^۴ وجود دارد که عملکردی مشابه نورون‌های شبکه عصبی دارد و در برخی کاربردهای خاص مورد استفاده قرار می‌گیرد.

انتخاب نوع هسته به ماهیت داده‌ها و رابطه میان ویژگی‌ها و متغیر هدف بستگی دارد.

جدول ۲-۲: مقایسه انواع تابع‌های هسته در رگرسیون بردار پشتیبان

نام هسته	فرمول ریاضی	پارامترهای قابل تنظیم	ویژگی‌ها و کاربردها
خطی	$K(x, x') = x^\top x'$	ندارد	ساده، سریع، مناسب برای داده‌هایی با رابطه تقریباً خطی
چندجمله‌ای	$K(x, x') = (x^\top x' + c)^d$	d, c	مناسب برای داده‌هایی با رابطه چندجمله‌ای، انعطاف‌پذیر
پایه شعاعی	$K(x, x') = \exp(-\gamma \ x - x'\ ^2)$	γ	بسیار قدرتمند، مناسب برای داده‌های غیرخطی پیچیده
سیگموئید	$K(x, x') = \tanh(\alpha x^\top x' + c)$	c, α	مشابه نورون در شبکه عصبی، حساس به پارامترها

۲-۹-۵ افزایش گرادیان افراطی^۵

مدل افزایش گرادیان افراطی، یکی از الگوریتم‌های **یادگیری با نظارت** محسوب می‌شود که برای حل مسائل رگرسیون و دسته‌بندی بسیار پرکاربرد است.

این مدل بر پایه درخت تصمیم عمل می‌کند و از نوع **یادگیری تجمعی ترقیبی**^۶ محسوب می‌شود. این روش نیازی به مقیاس‌بندی ویژگی‌ها ندارد و نسبت به داده‌های پرت^۷ حساسیت کمی نشان می‌دهد. همچنین، به صورت پیش فرض قادر به مدیریت مقادیر گمشده^۸ است.

¹Linear Kernel

²Polynomial Kernel

³Radial Basis Function (RBF) Kernel

⁴Sigmoid Kernel

⁵Extreme Gradient Boosting(XGBoost)

⁶Sequential Ensemble Learning

⁷Outliers


⁸Missing Values

مراحل اجرای مدل افزایش گرادیان افراطی

۱. پیش‌بینی اولیه: با انجام یک پیش‌بینی ساده روی داده‌های آموزشی آغاز می‌شود. این پیش‌بینی معمولاً میانگین مقدار متغیر هدف را در نظر می‌گیرد.
۲. محاسبه خطا: سپس باقی‌مانده‌ها (اختلاف بین مقدار واقعی و مقدار پیش‌بینی شده) محاسبه می‌شوند. این باقی‌مانده‌ها بیانگر خطاهای موجود در پیش‌بینی اولیه هستند.
۳. ساخت اولین درخت تصمیم: اولین درخت تصمیم در مجموعه مدل‌ها ساخته می‌شود. این درخت بر روی یادگیری همین باقی‌مانده‌ها متمرکز است و هدف آن کاهش مجموع خطاهاست. برای این منظور، درخت به دنبال یافتن بهترین نقاط تقسیم ویژگی‌ها برای کاهش بیشینه خطاها می‌گردد.
۴. درخت‌های بعدی و اصلاح خطا: در این مرحله، فرآیند تقویت گرادیانی^۱ به کار گرفته می‌شود. درخت جدید باقی‌مانده‌های به‌روزشده‌ای را هدف قرار می‌دهد که در پیش‌بینی مدل تجمعی (شامل همه درخت‌های قبلی) هنوز باقی مانده‌اند. هر درخت جدید به بهبود دقت مدل نهایی کمک می‌کند.
۵. کمینه‌سازی تابع زیان: در تمام مراحل، الگوریتم به‌طور پیوسته تابع زیان^۲ را بهینه می‌کند. این تابع به‌صورت ریاضی اندازه می‌گیرد که پیش‌بینی‌های مدل تا چه میزان با مقادیر واقعی تطابق دارند. با کمینه‌سازی این تابع، مدل به سمت پیش‌بینی‌های دقیق‌تر هدایت می‌شود.
۶. معیار توقف: فرآیند افزودن درخت‌ها تا زمانی ادامه می‌یابد که یکی از شرایط توقف برقرار شود. این شرایط می‌تواند شامل: رسیدن به حداکثر تعداد درخت‌ها، کاهش کمتر از آستانه مشخص در تابع زیان، یا دستیابی به سطح مشخصی از دقت باشد.

^۱Gradient Boosting

^۲Loss Function



شکل ۲-۸: کارکر مدل افزایش گرادیان افراطی

۲-۹-۶ مدل تقویت دسته‌ای^۱

در حوزه یادگیری ماشین، روش‌های تقویت گرادیانی تحولی اساسی در حل مسائل رگرسیون و دسته‌بندی ایجاد کرده‌اند. در میان این روش‌ها، مدل تقویت دسته‌ای به‌عنوان الگوریتمی قدرتمند، کارا و منعطف شناخته می‌شود که توانایی پردازش مستقیم داده‌های دسته‌ای^۲ را دارد؛ بدون آن‌که به پیش‌پردازش پیچیده‌ای نیاز داشته باشد. مدل تقویت دسته‌ای، کتابخانه‌ای متن‌باز می‌باشد. این الگوریتم به‌گونه‌ای طراحی شده که بتواند متغیرهای دسته‌ای را بدون نیاز به تبدیل آن‌ها به قالب عددی (مانند کدگذاری وان-هات^۳ یا روش‌های مشابه) مستقیماً پردازش نماید. این ویژگی، فرآیند آماده‌سازی داده‌ها را ساده‌تر کرده و عملکرد مدل را بهبود می‌بخشد. این مدل نیز بر پایه اصل تقویت گرادیانی عمل می‌کند؛ بدین‌صورت که مدل به‌صورت مرحله‌ای ساخته می‌شود. الگوریتم با مدلی ساده آغاز می‌گردد و سپس به‌صورت افزایشی، مدل‌های جدیدی را اضافه می‌کند که هدف آن‌ها اصلاح خطاهای مدل‌های قبلی است. با این حال، تقویت دسته‌ای نوآوری‌های مهمی را نسبت به سایر الگوریتم‌های تقویت گرادیانی ارائه می‌دهد:

پردازش ویژگی‌های دسته‌ای:

این مدل برای تبدیل مقادیر دسته‌ای به مقادیر عددی از الگوریتمی نوآورانه بهره می‌گیرد که در آن ترتیب دسته‌ها بر اساس متغیر هدف تعیین می‌شود. این فرآیند با عنوان **آمار هدف**^۴ شناخته می‌شود و به کاهش بیش‌برازش کمک کرده و نمایشی دقیق‌تر از داده‌های دسته‌ای ارائه می‌دهد.

^۱Category Boosting(CatBoost)

^۲Categorical Data

^۳One-Hot Encoding

^۴Target Statistics

تقویت ترتیبی:

یکی از نوآوری‌های اصلی تقویت دسته‌ای، استفاده از سازوکار **تقویت ترتیبی**^۱ است. الگوریتم‌های تقویت گرادیانی سنتی ممکن است دچار **جابجایی پیش‌بینی**^۲ شوند، چراکه داده‌های مورد استفاده برای آموزش و محاسبه گرادیان با هم هم‌پوشانی دارند. برای رفع این مشکل، تقویت دسته‌ای در هر تکرار از یک جایگشت تصادفی از مجموعه داده استفاده می‌کند و فقط داده‌های قبل از هر نمونه در آن جایگشت را برای آموزش به کار می‌گیرد. این روش، میزان بیش‌برازش را کاهش داده و پایداری مدل را افزایش می‌دهد.

درخت‌های متقارن:

تقویت دسته‌ای از درخت‌های متقارن^۳ به عنوان پیش‌بینی‌های پایه استفاده می‌کند. برخلاف روش‌های سنتی که درخت‌ها را به صورت عمقی یا بر اساس برگ‌ها گسترش می‌دهند، تقویت دسته‌ای درخت‌هایی می‌سازد که در آن تمامی گره‌های یک سطح از قاعدهٔ تصمیم‌گیری یکسانی پیروی می‌کنند. این ساختار موجب اجرای سریع‌تر و کاهش احتمال بیش‌برازش می‌گردد.

مراحل ساخت مدل تقویت دسته‌ای


روند ساخت مدل تقویت دسته‌ای شامل مراحل زیر است:

۱. **آماده‌سازی داده‌ها:** این مدل توانایی پردازش هم‌زمان ویژگی‌های عددی و دسته‌ای را دارد. برای ویژگی‌های دسته‌ای از یک روش رمزگذاری نوین مبتنی بر آمار هدف استفاده می‌کند.
۲. **آموزش مدل:** مدل به صورت افزایشی آموزش داده می‌شود. در هر مرحله، درخت‌هایی افزوده می‌شوند که خطاهای مدل‌های قبلی را اصلاح می‌کنند. بهینه‌سازی مدل از طریق الگوریتمی مبتنی بر گرادیان برای کمینه‌سازی تابع زیان انجام می‌شود.
۳. **اعمال تقویت ترتیبی و درخت‌های متقارن:** این دو سازوکار به مدل کمک می‌کنند تا با کاهش بیش‌برازش، داده‌های دسته‌ای را به صورت مؤثر و دقیق مدیریت کند.

¹Ordered Boosting

²Prediction Shift

³Symmetric Trees



شکل ۲-۹: مدل تقویت دسته‌ای

۲-۹-۷ شبکه عصبی چندلایه^۱

شبکه‌های عصبی در قلب بسیاری از الگوریتم‌ها و کاربردهای نوین یادگیری ماشین و هوش مصنوعی قرار دارند. در میان انواع مختلف این مدل‌ها، ادراک گر چندلایه یا شبکه عصبی چندلایه به عنوان یکی از اجزای پایه‌ای در یادگیری عمیق^۲ شناخته می‌شود. در این بخش، مفهوم شبکه عصبی مصنوعی معرفی می‌گردد و نحوه عملکرد ساختار چندلایه آن، شامل اجزایی مانند انتشار روبه جلو^۳ و پس انتشار خطا^۴ مورد بررسی قرار می‌گیرد.

مقدمه‌ای بر شبکه عصبی مصنوعی

شبکه عصبی مصنوعی، یک مدل یادگیری ماشین است که ساختار آن الهام گرفته از ساختار و عملکرد شبکه نورون‌های درهم تنیده در مغز انسان می‌باشد. این شبکه از گره‌هایی موسوم به نورون مصنوعی^۵ تشکیل شده که

^۱Multilayer Perceptrons (MLPs)

^۲Deep Learning

^۳Feedforward Propagation

^۴Backpropagation

^۵Artificial Neuron

در قالب لایه‌هایی به هم متصل هستند. جریان اطلاعات درون شبکه به گونه‌ای است که هر نورون، سیگنال ورودی را پردازش کرده و یک سیگنال خروجی تولید می‌کند که این خروجی می‌تواند به عنوان ورودی به نورون‌های بعدی منتقل شود.

ادراک گر چندلایه

ادراک گر چندلایه، گونه‌ای از شبکه عصبی مصنوعی است که از چندین لایه از نورون‌ها تشکیل شده است. نورون‌های این ساختار معمولاً از توابع فعال‌سازی^۱ غیرخطی استفاده می‌کنند؛ امری که موجب توانایی یادگیری الگوهای پیچیده و غیرداده‌خطی در داده‌ها می‌شود. اهمیت این ساختار در یادگیری ماشین از آنجاست که می‌تواند روابط غیرخطی میان ویژگی‌ها و خروجی را مدل کند و در نتیجه برای وظایفی مانند دسته‌بندی، رگرسیون و شناسایی الگوها بسیار مؤثر است.

مبانی شبکه‌های عصبی

شبکه‌های عصبی مصنوعی ابزارهای بنیادی در یادگیری ماشین محسوب می‌شوند و زیربنای بسیاری از الگوریتم‌ها و کاربردهای پیشرفته در حوزه‌هایی نظیر بینایی رایانه‌ای، پردازش زبان طبیعی، رباتیک و... را تشکیل می‌دهند. هر شبکه از نورون‌هایی تشکیل شده که در لایه‌های مختلف سازمان‌دهی شده‌اند. هر نورون سیگنال‌های ورودی را دریافت کرده، با استفاده از یک تابع فعال‌سازی بر روی آن‌ها محاسبه انجام می‌دهد، و سیگنال خروجی تولید می‌کند. این توابع فعال‌سازی خروجی هر نورون را تعیین می‌کنند و با وارد کردن خاصیت غیرخطی به مدل، آن را قادر می‌سازند تا الگوهای پیچیده را فراگیرند.

ساختار شبکه معمولاً به صورت لایه‌ای تنظیم می‌شود؛ لایه ورودی داده‌ها را دریافت می‌کند، سپس چندین لایه میانی (پنهان) عملیات محاسباتی را انجام می‌دهند، و نهایتاً لایه خروجی وظیفه تولید پیش‌بینی یا تصمیم نهایی را بر عهده دارد.

اتصالات بین نورون‌های لایه‌های مجاور با وزن‌هایی مشخص تعریف می‌شوند که شدت تأثیر یک نورون بر نورون دیگر را نشان می‌دهند. این وزن‌ها در طول فرآیند آموزش و بر اساس داده‌های آموزشی تنظیم می‌گردند. همچنین، هر نورون معمولاً دارای یک بایاس^۲ نیز هست که به تنظیم آستانه خروجی نورون کمک می‌کند.

^۱Activation Functions

^۲Bias


آموزش شبکه عصبی

آموزش شبکه عصبی از طریق ترکیبی از انتشار روبه جلو و پس انتشار خطا صورت می گیرد. در مرحله انتشار روبه جلو، داده ورودی به صورت لایه به لایه از طریق شبکه عبور داده شده و هر لایه محاسبات لازم را انجام داده و خروجی را به لایه بعدی ارسال می کند.

الگوریتم پس انتشار خطا به عنوان روش آموزش، وظیفه تنظیم وزن ها و بایاس ها را به عهده دارد. این الگوریتم با محاسبه تابع زیان^۱ که معیاری از اختلاف بین خروجی مدل و مقدار واقعی هدف است، مقدار خطا را در لایه خروجی محاسبه کرده و سپس آن را به صورت معکوس از خروجی به ورودی منتقل می کند تا تأثیر هر وزن بر خطا مشخص شود.

هدف آموزش، کمینه سازی مقدار تابع زیان است. این کار با استفاده از الگوریتم های بهینه سازی مانند نزول گرادیان انجام می گیرد که طی آن وزن ها و بایاس ها در جهت کاهش خطا به روزرسانی می شوند. در آموزش های با مجموعه داده های بزرگ، اغلب از روش نزول گرادیان تصادفی برای افزایش سرعت آموزش استفاده می شود. در ادامه، برخی از این مفاهیم مانند توابع فعال سازی و ساختار لایه ها به تفصیل بررسی خواهند شد.

انواع شبکه های عصبی مصنوعی



شکل ۲-۱۰: شبکه عصبی مصنوعی در مقابل شبکه عصبی بیولوژیکی

مدلی که در سمت راست تصویر مشاهده می شود، یک شبکه عصبی ساده موسوم به ادراک گر^۲ است. این مدل تنها از یک لایه تشکیل شده که همان لایه ورودی است و شامل چندین نورون با وزن های مستقل می باشد. در این ساختار، هیچ لایه میانی (پنهان) وجود ندارد. الگوریتم ادراک گر می کوشد وزن های سیگنال های ورودی را به گونه ای بیاموزد که یک مرز تصمیم گیری خطی میان داده ها ترسیم نماید. با این حال، برای حل مسائل پیچیده تر و غیر داده خطی مانند پردازش تصویر، بینایی رایانه ای و پردازش زبان طبیعی، از شبکه های عصبی عمیق استفاده می شود.

^۱Loss Function

^۲Perceptron

شبکه‌های عصبی مصنوعی انواع مختلفی دارند که هر یک برای وظایف خاص و ساختارهای معماری متفاوت طراحی شده‌اند. در ادامه، برخی از رایج‌ترین انواع این شبکه‌ها معرفی می‌گردند:

۱. شبکه‌های عصبی پیش‌خور^۱

این نوع از ساده‌ترین ساختارهای شبکه عصبی است که در آن اطلاعات تنها در یک جهت، از لایه ورودی به لایه خروجی جریان می‌یابد و هیچ‌گونه چرخه یا بازخوردی در ساختار آن وجود ندارد. مدل ادراک‌گر چندلایه نیز زیرمجموعه‌ای از این دسته محسوب می‌شود.

۲. شبکه‌های عصبی بازگشتی^۲

در این شبکه‌ها، ارتباطات بین نوره‌ها به صورت چرخه‌ای و جهت‌دار طراحی می‌شوند تا اطلاعات در طول زمان حفظ شود. این ویژگی آن‌ها را برای مسائل داده‌های ترتیبی مانند پیش‌بینی سری‌های زمانی، پردازش زبان طبیعی و تشخیص گفتار مناسب می‌سازد.

۳. شبکه‌های عصبی پیچشی^۳

این شبکه‌ها برای پردازش داده‌هایی با ساختار شبکه‌ای نظیر تصاویر طراحی شده‌اند. ساختار آن‌ها شامل لایه‌هایی از فیلترهای پیچشی است که ویژگی‌های داده را به صورت سلسله‌مراتبی استخراج می‌کنند. کاربردهای اصلی آن‌ها در طبقه‌بندی تصویر، شناسایی اشیاء و بخش‌بندی تصویر می‌باشد.

۴. حافظه بلندمدت کوتاه‌مدت^۴ و واحدهای بازگشتی دروازه‌دار^۵

این مدل‌ها نسخه‌های پیشرفته‌تری از شبکه‌های بازگشتی هستند که به منظور مقابله با مشکل ناپدید شدن گرادیان در شبکه‌های عصبی بازگشتی سنتی طراحی شده‌اند. استفاده از مکانیزم‌های دروازه‌ای در ساختار آن‌ها موجب توانایی در یادگیری وابستگی‌های بلندمدت در داده‌های ترتیبی شده و در وظایفی مانند ترجمه ماشینی، تشخیص احساسات و تشخیص گفتار بسیار کارآمد هستند.

۵. خودرمزگذارها^۶

این مدل‌ها برای یادگیری بدون ناظر طراحی شده‌اند و از دو بخش تشکیل می‌شوند: بخش رمزگذار که داده ورودی را به یک فضای نهفته با ابعاد کمتر فشرده می‌کند، و بخش بازرمزگذار که از روی فضای

¹Feedforward Neural Networks

²Recurrent Neural Networks

³Convolutional Neural Networks

⁴Long Short-Term Memory Networks

⁵Gated Recurrent Units

⁶Autoencoders

نهفته تلاش می‌کند ورودی اولیه را بازسازی نماید. کاربردهای اصلی آن‌ها شامل کاهش ابعاد، حذف نویز از داده و مدل‌سازی مولد است.

۶. شبکه‌های مولد تخصصی^۱

این ساختار شامل دو شبکه عصبی است: یک تولیدکننده و یک تمایزدهنده که به صورت رقابتی آموزش می‌بینند. تولیدکننده می‌کوشد داده‌هایی مشابه داده‌های واقعی بسازد، در حالی که تمایزدهنده وظیفه تشخیص داده‌های واقعی از داده‌های ساختگی را دارد. این شبکه‌ها در تولید تصاویر واقع‌گرایانه، ویدیوها و انواع دیگر داده بسیار موفق بوده‌اند.

ادراک‌گر چندلایه

ادراک‌گر چندلایه یک نوع از شبکه عصبی پیش‌خور است که از نورون‌هایی کاملاً متصل به یکدیگر تشکیل شده و از توابع فعال‌سازی غیرخطی^۲ بهره می‌برد. این مدل به‌طور گسترده برای تفکیک داده‌هایی که به صورت خطی جداپذیر نیستند مورد استفاده قرار می‌گیرد.

ادراک‌گرهای چندلایه کاربردهای فراوانی در حوزه‌هایی چون شناسایی تصویر، پردازش زبان طبیعی و تشخیص گفتار دارند. انعطاف‌پذیری معماری و توانایی آن‌ها در تقریب هر تابعی (تحت شرایط خاص) سبب شده که از آن‌ها به عنوان اجزای بنیادی در یادگیری عمیق و پژوهش‌های مرتبط با شبکه‌های عصبی یاد شود. در ادامه به بررسی اجزای اصلی این ساختار پرداخته می‌شود:

لایه ورودی: لایه ورودی از نورون‌هایی تشکیل شده که داده‌های خام اولیه را دریافت می‌کنند. هر نورون در این لایه معرف یکی از ویژگی‌ها یا ابعاد داده ورودی است. تعداد نورون‌های این لایه برابر با تعداد ویژگی‌های مسئله است.

لایه میانی (پنهان): بین لایه ورودی و خروجی، یک یا چند لایه میانی^۳ وجود دارد. هر نورون در یک لایه میانی، ورودی‌هایی از تمام نورون‌های لایه قبلی دریافت کرده و خروجی‌ای تولید می‌کند که به لایه بعدی منتقل می‌شود. تعداد این لایه‌ها و تعداد نورون‌ها در هر لایه از جمله فرامترها^۴ محسوب می‌شود که در مرحله طراحی مدل مشخص می‌گردند.

¹Generative Adversarial Networks

²Nonlinear Activation Function

³Hidden Layer

⁴Hyperparameters

لایه خروجی: این لایه شامل نورون‌هایی است که خروجی نهایی شبکه را تولید می‌کنند. تعداد نورون‌های این لایه به ماهیت مسئله بستگی دارد. برای مثال، در دسته‌بندی دودویی ممکن است یک یا دو نورون وجود داشته باشد که احتمال تعلق نمونه به یک رده را نمایش دهند. در مسائل دسته‌بندی چندرده‌ای، تعداد نورون‌ها برابر با تعداد کلاس‌ها خواهد بود.

وزن‌ها: اتصالات بین نورون‌های لایه‌های متوالی با وزن‌هایی^۱ مشخص تعریف می‌شوند که شدت تأثیر یک نورون بر نورون بعدی را تعیین می‌کنند. این وزن‌ها طی فرآیند آموزش به‌روز می‌شوند تا مدل بتواند به‌درستی الگوهای موجود در داده را بیاموزد.

نورون‌های بایاس: در اغلب ساختارها، هر لایه (به‌جز لایه ورودی) دارای یک **نورون بایاس**^۲ است که مقدار ثابتی را به نورون‌های لایه بعدی ارسال می‌کند. بایاس‌ها نیز دارای وزن مخصوص به خود هستند و در طول آموزش مدل یاد گرفته می‌شوند. وجود این نورون‌ها باعث می‌شود تابع فعال‌سازی نورون‌های بعدی جابه‌جا شده و مدل قادر به یادگیری شیف‌ت یا بایاس در مرز تصمیم‌گیری باشد.

نکته: در فضای یادگیری ماشین، اصطلاح «بایاس» می‌تواند به دو مفهوم مرتبط ولی متمایز اشاره کند: یکی بایاس به‌عنوان نورون در ساختار شبکه، و دیگری **سوگیری مدل**^۳ که به میزان ساده‌سازی مدل در تخمین واقعیت اشاره دارد. سوگیری زیاد نشان‌دهنده مدلی ساده‌انگار و دارای **کم‌برازش** است، در حالی که سوگیری کم بیانگر قدرت بیشتر مدل در یادگیری الگوهای پنهان داده است.

توابع فعال‌سازی: معمولاً هر نورون در لایه‌های میانی و خروجی از یک تابع فعال‌سازی برای اعمال بر مجموع وزنی ورودی‌های خود استفاده می‌کند. توابع رایج در این زمینه شامل **سیگموید**^۴، **تانژانت**^۵، **واحد خطی اصلاح‌شده**^۶ و **سافت مکس**^۷ هستند. وجود این توابع موجب غیرخطی شدن مدل شده و قابلیت یادگیری الگوهای پیچیده‌تر را فراهم می‌کند.

انتشار روبه‌جلو و پس‌انتشار خطا: آموزش ادراک‌گر چندلایه با استفاده از الگوریتم **پس‌انتشار خطا** صورت می‌گیرد. در این روش، ابتدا در مرحله **انتشار روبه‌جلو**، داده از لایه ورودی به لایه خروجی منتقل شده و خروجی مدل محاسبه می‌شود. سپس با محاسبه تابع زیان، میزان خطای مدل سنجیده می‌شود. در مرحله بعد، گرادیان تابع

¹Weights

²Bias Neuron

³Model Bias

⁴Sigmoid


⁵Tanh

⁶Rectified Linear Unit (ReLU)

⁷Softmax

زیان نسبت به وزن‌ها محاسبه شده و با استفاده از الگوریتمی نظیر نزول گرادین، وزن‌ها به‌روزرسانی می‌شوند تا تابع زیان به‌مرور کمینه گردد.

عملکرد شبکه عصبی چندلایه به‌صورت گام‌به‌گام



شکل ۲-۱۱: ساختار شبکه‌های عصبی چندلایه

در یک شبکه عصبی چندلایه، نورون‌ها به‌صورت مرحله‌به‌مرحله اطلاعات را پردازش می‌کنند. در هر مرحله محاسباتی شامل جمع وزنی ورودی‌ها و تبدیل‌های غیرخطی انجام می‌شود. در ادامه، به بررسی عملکرد این مدل به‌صورت لایه به لایه پرداخته می‌شود:

لایه ورودی: لایه ورودی، داده‌های اولیه (ویژگی‌های استخراج‌شده از نمونه‌های مجموعه داده) را دریافت می‌کند. هر نورون در این لایه نماینده یک ویژگی از داده است. نورون‌های لایه ورودی هیچ‌گونه پردازشی روی داده انجام نمی‌دهند و صرفاً مقادیر ورودی را به لایه میانی اول منتقل می‌کنند.

لایه‌های میانی: در لایه‌های میانی، نورون‌ها با دریافت ورودی از نورون‌های لایه قبلی، عملیات محاسباتی انجام می‌دهند. هر ورودی با وزن متناظر خود (نماد w) ضرب می‌شود. این وزن‌ها نشان می‌دهند که هر ورودی تا چه میزان بر خروجی نورون تأثیرگذار است. علاوه بر وزن، هر نورون دارای یک مقدار بایاس با نماد b است که مانند یک ورودی اضافی به نورون عمل کرده و به تنظیم آستانه خروجی کمک می‌کند. وزن و بایاس هر دو در

فرآیند آموزش مدل یاد گرفته می‌شوند.

برای هر نورون در لایه میانی یا خروجی، مجموع وزنی ورودی‌ها به صورت زیر محاسبه می‌شود:

$$\text{Sum Weighted} = \sum_{i=1}^n w_i x_i + b$$

در این رابطه، n تعداد کل ورودی‌ها، x_i مقدار i -امین ورودی، و w_i وزن متناظر آن است. این مقدار سپس از طریق یک تابع فعال‌سازی عبور داده می‌شود تا خروجی نهایی نورون تولید شود. این تابع با افزودن خاصیت غیرخطی، توانایی مدل در یادگیری الگوهای پیچیده را افزایش می‌دهد. انتخاب تابع فعال‌سازی به ماهیت مسئله و ویژگی‌های مورد انتظار مدل بستگی دارد.

لایه خروجی: لایه خروجی وظیفه تولید پیش‌بینی نهایی یا پاسخ مدل را دارد. تعداد نورون‌های این لایه با توجه به نوع مسئله تعیین می‌شود (مثلاً در دسته‌بندی دودویی یا چندرده‌ای یا در مسائل رگرسیون). هر نورون در این لایه از نورون‌های لایه میانی قبلی ورودی گرفته و پس از اعمال تابع فعال‌سازی خروجی نهایی را تولید می‌کند. تابع فعال‌سازی در لایه خروجی ممکن است با توابع استفاده‌شده در لایه‌های میانی متفاوت باشد.

در فرآیند آموزش، شبکه تلاش می‌کند با تنظیم وزن‌ها و بایاس‌ها، تفاوت بین خروجی پیش‌بینی‌شده و مقدار واقعی هدف را به حداقل برساند. این کار از طریق به‌روزرسانی پیوسته وزن‌ها بر اساس داده‌های آموزشی انجام می‌شود. به این ترتیب مدل قادر خواهد بود الگوهای پنهان در داده را فراگرفته و روی نمونه‌های جدید، پیش‌بینی دقیقی انجام دهد.

این بهینه‌سازی با استفاده از الگوریتم‌هایی نظیر نزول گرادیان تصادفی انجام می‌شود. در این الگوریتم، گرادیان تابع زیان نسبت به وزن‌ها محاسبه شده و وزن‌ها در جهت کاهش تابع زیان به‌روزرسانی می‌شوند.

۲-۹-۸ شبکه عصبی عمیق^۱


شبکه‌های عصبی عمیق مدل‌هایی هستند که با بهره‌گیری از ساختارهای لایه‌ای پیچیده، به ماشین‌ها امکان می‌دهند الگوها و نمایش‌های پیچیده‌ای را از داده‌ها بیاموزند. این شبکه‌ها در صورت آموزش مناسب، توانایی تفسیر دقیق تصاویر، تقلید گفتار انسان‌مانند، و حتی تولید آثار هنری را با دقت بالا برای مدل‌های یادگیری ماشین فراهم می‌سازند.

^۱ Deep Neural Networks(DNN)

تعریف شبکه عصبی عمیق

شبکه عصبی عمیق نوعی از شبکه‌های عصبی مصنوعی است که دارای چندین لایه بین لایه ورودی و خروجی می‌باشد. هر لایه شامل تعدادی گره محاسباتی است که عملیات پردازش را بر روی داده‌های ورودی انجام می‌دهند. نام دیگر این ساختار در ادبیات علمی، شبکه عمیق نیز می‌باشد.

اصطلاح عمیق در شبکه‌های عصبی عمیق به وجود چندین لایه پنهان اشاره دارد؛ این لایه‌ها موجب می‌شوند شبکه بتواند نمایش‌های پیچیده و سطح بالایی از داده‌های ورودی استخراج کند. در واقع همین ساختار چندلایه‌ای است که شبکه‌های عمیق را قادر می‌سازد تا مسائل پیچیده‌ای را حل کنند که توسط ساختارهای ساده‌تر و کم‌عمق‌تر قابل حل نیستند.



شکل ۲-۱۲: شبکه‌های عصبی و شبکه‌های عصبی عمیق

لایه‌های پنهان در یک شبکه عصبی عمیق معمولاً از نوع لایه‌های متراکم (کامل متصل)^۱ هستند. در این ساختار، هر نورون در یک لایه پنهان به تمام نورون‌های لایه قبلی و بعدی متصل است. این ویژگی موجب می‌شود شبکه‌های عصبی عمیق برای یادگیری روابط پیچیده در داده‌ها بسیار مناسب باشند. نکته مهم آن است که لایه‌های پنهان در یک شبکه عصبی عمیق، صرفاً نسخه‌های تکراری از یکدیگر نیستند. در عوض، این شبکه‌ها دارای ساختارهای متنوع و پیچیده‌ای از لایه‌ها هستند که هر کدام نقشی خاص در یادگیری ایفا می‌کنند. برخی از انواع رایج لایه‌های مورد استفاده در این شبکه‌ها عبارت‌اند از:

- لایه‌های پیچشی^۲ که مجموعه‌ای از فیلترهای قابل یادگیری را بر روی داده‌های ورودی اعمال می‌کنند.
- لایه‌های حافظه بلند کوتاه‌مدت^۳ که وابستگی‌های زمانی در داده‌های ترتیبی را استخراج می‌کنند.
- واحدهای بازگشتی دروازه‌دار^۴ که با استفاده از مکانیزم دروازه‌ای جریان اطلاعات را در شبکه کنترل می‌کنند.

¹Dense (Fully Connected) Layers

²Convolutional Layers

³Long Short-Term Memory (LSTM) Layers

⁴Gated Recurrent Unit (GRU) Layers

• **لایه‌های توجه^۱** که در هنگام پیش‌بینی، تمرکز شبکه را بر بخش‌های خاصی از توالی ورودی معطوف می‌سازند.

• **لایه‌های نرمال‌سازی^۲** که موجب پایداری و تسریع فرآیند آموزش در شبکه می‌شوند.

هرچه تعداد لایه‌های پنهان در یک شبکه عصبی عمیق بیشتر باشد، توانایی آن در یادگیری و پردازش داده‌های ورودی نیز افزایش می‌یابد. گرچه شبکه‌ای که تنها دو لایه پنهان دارد نیز «عمیق» محسوب می‌شود، در عمل بسیاری از شبکه‌های عصبی عمیق دارای صدها لایه پنهان میان ورودی و خروجی هستند.

نحوه عملکرد شبکه‌های عصبی عمیق

شبکه‌های عصبی عمیق از چندین لایه متشکل از گره‌هایی به نام نورون یا واحد تشکیل شده‌اند. این شبکه‌ها معمولاً شامل سه نوع لایه هستند:

• **لایه ورودی:** وظیفه دریافت داده‌های خام را برعهده دارد. هر نورون در این لایه نمایانگر یک ویژگی از داده ورودی است. به عنوان نمونه، برای تفسیر تصاویری با ابعاد 28×28 پیکسل، به 784 نورون در لایه ورودی نیاز است؛ زیرا هر نورون نشان‌دهنده شدت روشنایی یک پیکسل با مقداری در بازه 0 تا 255 است.

• **لایه‌های پنهان:** این لایه‌ها بین لایه ورودی و لایه خروجی قرار دارند و معمولاً بیش از دو عدد هستند. هر لایه پنهان از چندین نورون تشکیل شده است که به نورون‌های لایه‌های مجاور متصل‌اند، اما نورون‌های یک لایه به یکدیگر متصل نمی‌باشند.

• **لایه خروجی:** این لایه مسئول تولید خروجی نهایی شبکه است. تعداد نورون‌های این لایه بسته به نوع مسئله (مانند طبقه‌بندی دودویی، چندکلاسه یا رگرسیون) تعیین می‌شود.

پس از وارد شدن داده‌های خام، این داده‌ها به صورت لایه به لایه از طریق شبکه به جلو هدایت می‌شوند. در هر لایه، نورون‌ها ابتدا با استفاده از تابع فعال‌سازی اختصاص یافته، بر ورودی‌ها عملیات پردازشی انجام داده و سپس خروجی پردازش شده را به لایه بعدی ارسال می‌کنند. در ادامه، چند تابع فعال‌سازی رایج معرفی می‌شود:

¹Attention Layers

²Normalization Layers

• **سیگموئید^۱:** مقدار ورودی را در بازه ۰ تا ۱ فشرده‌سازی می‌کند و برای مسائل طبقه‌بندی دودویی مناسب است.

• **تانژانت هایپربولیک^۲:** ورودی را در بازه ۱- تا ۱ نگاشت می‌کند و در مسائل طبقه‌بندی و رگرسیون کاربرد دارد.

• **واحد خطی اصلاح‌شده^۳:** مقادیر منفی ورودی را صفر و مقادیر مثبت را بدون تغییر عبور می‌دهد.

• **تابع سافت مکس^۴:** امتیازهای خام را به مقادیر احتمالی تبدیل می‌کند، به‌طوری‌که مجموع خروجی‌ها برابر با ۱ باشد.

پس از تولید خروجی نهایی توسط شبکه، این خروجی با مقدار هدف که از سوی طراح یا کاربر تعیین شده مقایسه می‌شود. اختلاف میان مقدار پیش‌بینی‌شده و مقدار واقعی توسط تابع هدف یا تابع زیان سنجیده می‌شود. سپس این خطاها به‌صورت معکوس در شبکه منتشر شده و وزن‌های ارتباطی نورون‌ها با استفاده از الگوریتم‌های بهینه‌سازی، به‌گونه‌ای تنظیم می‌گردند که مقدار خطا کاهش یابد.

شبکه‌های عصبی و مفهوم وزن‌دهی

در یک شبکه عصبی عمیق، هر اتصال بین نورون‌های دو لایه مجاور دارای یک وزن عددی است. این وزن‌ها بیانگر قدرت تأثیرگذاری خروجی یک نورون بر ورودی نورون دیگر می‌باشند و میزان اهمیت یا نفوذ یک نورون را در فرآیند انتقال اطلاعات مشخص می‌کنند.

وزن‌ها می‌توانند دارای مقادیر مثبت یا منفی باشند که نوع و شدت اثر نورون‌ها بر یکدیگر را تعیین می‌کند:

• **وزن مثبت:** اگر وزنی مثبت باشد، افزایش در خروجی نورون مبدأ منجر به افزایش فعالیت نورون مقصد خواهد شد. در این حالت، نورون مبدأ فعالیت نورون مقصد را تحریک می‌کند.

• **وزن منفی:** در صورتی‌که وزن منفی باشد، افزایش در خروجی نورون مبدأ منجر به کاهش فعالیت نورون مقصد می‌شود. در این حالت، نورون مبدأ فعالیت نورون مقصد را مهار می‌کند.

در ابتدای آموزش، وزن‌های شبکه معمولاً به‌صورت تصادفی مقداردهی اولیه می‌شوند. سپس در طول فرایند آموزش، شبکه عصبی این وزن‌ها را به‌طور تدریجی و تکرارشونده بر اساس تفاوت میان خروجی پیش‌بینی‌شده و مقدار واقعی به‌روزرسانی می‌کند.

¹Sigmoid

²Hyperbolic Tangent (Tanh)

³Rectified Linear Unit (ReLU)

⁴Softmax Function

وزن‌ها نقش بسیار حیاتی در هر دو مرحله انتشار و پس انتشار در شبکه‌های عمیق ایفا می‌کنند:

- در مرحله انتشار، هر نورون مجموع وزن‌دار ورودی‌های خود را از نورون‌های لایه قبل محاسبه کرده و سپس با اعمال یک تابع فعال‌سازی بر این مجموع، خروجی خود را تولید و به لایه بعدی ارسال می‌کند.
- در مرحله پس انتشار، سیگنال خطا از خروجی شبکه به صورت معکوس در لایه‌ها انتشار می‌یابد. در این فرآیند، وزن‌ها به گونه‌ای تنظیم می‌شوند که مقدار خطا کاهش یابد.

بهینه‌سازی وزن‌ها از اجزای کلیدی در آموزش شبکه‌های عصبی است، زیرا تعیین می‌کند که شبکه تا چه حد قادر به یادگیری الگوهای معنادار از داده‌های آموزشی و تولید پیش‌بینی‌های دقیق باشد.

چالش‌های شبکه‌های عصبی عمیق

اگرچه شبکه‌های عصبی عمیق توانایی‌های چشمگیری در یادگیری الگوهای پیچیده دارند، اما استفاده از آن‌ها با چالش‌هایی همراه است که آگاهی از آن‌ها پیش از آغاز فرایند آموزش ضروری است. در ادامه، مهم‌ترین مشکلاتی که در پیاده‌سازی و آموزش این مدل‌ها ممکن است رخ دهد بررسی می‌گردد.

کیفیت و کمیت داده‌های آموزشی

برای آموزش مناسب یک شبکه عصبی عمیق و تضمین تعمیم‌پذیری آن نسبت به ورودی‌های جدید و دیده‌نشده، به حجم بالایی از داده‌های برچسب‌خورده دقیق نیاز است. تهیه این داده‌ها به‌ویژه در حوزه‌هایی که فرایند برچسب‌گذاری دشوار یا پرهزینه است، زمان‌بر و پرهزینه می‌باشد. داده‌هایی که به لایه ورودی شبکه تزریق می‌شوند باید دارای ویژگی‌های زیر باشند:

- **دقت:** وجود خطا در برچسب‌ها یا داده‌های نادقیق منجر به یادگیری الگوهای نادرست و پیش‌بینی‌های اشتباه توسط مدل می‌شود.
- **نماینده‌گی:**^۱ داده‌های آموزشی باید تمام حالات و تنوع‌های ممکن را که مدل در محیط واقعی با آن مواجه خواهد شد پوشش دهند؛ در غیر این صورت، مدل دچار سوگیری یا پیش‌بینی ناقص خواهد شد.
- **پاکی:**^۲ وجود نویز یا نقاط پرت در داده‌ها باعث ایجاد ابهام در فرایند یادگیری و کاهش عملکرد مدل می‌شود.

¹Representativeness

²Cleanness

بهبود کیفیت و کمیت داده‌های آموزشی مستلزم جمع‌آوری اصولی، برچسب‌گذاری دقیق، پیش‌پردازش مناسب و اعتبارسنجی داده‌هاست. همچنین استفاده از تکنیک‌های افزایش داده، مانند چرخش، تغییر اندازه، برش، یا افزودن نویز می‌تواند موجب افزایش حجم مؤثر داده‌ها شود.

چالش‌های آموزش شبکه

دو چالش اصلی در آموزش شبکه‌های عصبی عمیق، بیش‌برازش و کم‌برازش هستند که بر توانایی مدل در تعمیم به داده‌های جدید تأثیر می‌گذارند.

بیش‌برازش: زمانی رخ می‌دهد که مدل به‌جای یادگیری روابط بنیادین میان ویژگی‌ها، جزئیات خاص و نویز موجود در داده‌های آموزشی را حفظ می‌کند. نتیجه این حالت، عملکرد بسیار خوب مدل روی داده‌های آموزش و عملکرد ضعیف آن روی داده‌های جدید است.

نشانه‌های بیش‌برازش شامل دقت بالای آموزش، دقت پایین اعتبارسنجی و نمودارهای نوسانی یا نامنظم در روند آموزش است. برای مقابله با این مشکل، روش‌های زیر توصیه می‌شود:

- استفاده از منظم‌سازی، حذف تصادفی نوروها^۱ و توقف زودهنگام در حین آموزش،
- افزایش تنوع و حجم داده‌ها از طریق تکنیک‌های افزایش داده،
- کاهش پیچیدگی مدل با کاهش عمق یا عرض شبکه.

کم‌برازش: زمانی رخ می‌دهد که مدل ساختار بسیار ساده‌ای دارد و قادر به یادگیری روابط اساسی میان ویژگی‌ها نیست. این مشکل موجب عملکرد ضعیف هم در داده‌های آموزش و هم در اعتبارسنجی می‌شود. برای حل این مشکل می‌توان:

- افزایش پیچیدگی مدل از طریق افزایش تعداد لایه‌ها یا نوروها،
- افزودن ویژگی‌های مؤثرتر به ورودی مدل،
- افزایش تنوع داده‌های آموزشی.

یکی دیگر از مشکلات رایج در آموزش این مدل‌ها، **ناپدید شدن گرادیان**^۲ در طول فرایند انتشار معکوس است که باعث کندی یا توقف آموزش می‌شود.

^۱Dropout

^۲Vanishing Gradient

تنظیم ابرپارامترها

ابرپارامترها نقش حیاتی در تعیین رفتار و عملکرد شبکه عصبی دارند. این پارامترها پیش از شروع آموزش تعریف می‌شوند و باید متناسب با هدف مدل انتخاب شوند. مهم‌ترین ابرپارامترها عبارت‌اند از:

- نرخ یادگیری،
- اندازه دسته‌های آموزشی،
- تعداد لایه‌ها،
- تعداد نورون‌ها در هر لایه،
- میزان منظم‌سازی،
- نرخ حذف نورون‌ها،
- نوع توابع فعال‌سازی،
- الگوریتم‌های بهینه‌سازی.

تنظیم نادرست این پارامترها می‌تواند منجر به آموزش کند، عملکرد ضعیف، و تعمیم‌پذیری پایین شود. از آنجا که این ابرپارامترها اثر متقابل و پیچیده‌ای بر یکدیگر دارند، تعیین پیکربندی بهینه معمولاً از طریق آزمون و خطا و تحلیل دقیق شاخص‌های آموزش انجام می‌گیرد که نیازمند زمان و دقت فراوان است.

۱۰-۲ معیارهای ارزیابی مدل‌ها

برای ارزیابی مدل‌های پیش‌بینی، از شش شاخص اصلی استفاده شده است:

۱. ضریب تعیین

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

نشان‌دهنده درصد واریانس توضیح داده‌شده توسط مدل.

۲. میانگین قدرمطلق خطا

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

مقدار میانگین قدرمطلق خطا بین پیش‌بینی و مقدار واقعی.

۳. ریشه میانگین مربع خطا

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

شاخصی حساس به خطاهای بزرگ.

۴. درصد خطای میانگین

$$MPE = \frac{100}{n} \sum_{i=1}^n \frac{y_i - \hat{y}_i}{y_i}$$

برای بررسی جهت کلی خطا.

۵. میانگین قدرمطلق درصد خطای متقارن

$$sMAPE = \frac{100}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2}$$

مناسب برای مقایسه مقادیر نسبی خطا.

۶. انحراف استاندارد نسبی

$$SDR = \frac{RMSE}{\sigma_y}$$

که σ_y انحراف معیار مشاهدات واقعی است. این شاخص میزان پراکندگی خطا نسبت به پراکندگی داده‌ها را نشان می‌دهد.

فصل سوم

مروری بر پژوهش‌های پیشین

۳-۱ مقدمه

پیش‌بینی دقیق عملکرد شیر در گاوهای شیری یکی از موضوعات کلیدی در مدیریت بهینه گله‌ها، برنامه‌ریزی تولید، و افزایش سودآوری مزارع لبنی محسوب می‌شود. این فرآیند به دامداران امکان می‌دهد تا با اتخاذ تصمیمات آگاهانه در زمینه تغذیه، سلامت، و انتخاب نژادی دام، بهره‌وری را بهبود بخشند [۷]. در دهه‌های اخیر، با افزایش حجم داده‌های تولیدشده در دام‌پروری و پیشرفت‌های چشمگیر در حوزه تحلیل داده‌ها و یادگیری ماشین، روش‌های پیش‌بینی نیز تحولات قابل‌توجهی را تجربه کرده‌اند [۵]. پژوهش حاضر با هدف توسعه مدلی مبتنی بر یادگیری ماشین برای پیش‌بینی اولین رکورد شیردهی در دوره شیردهی بعدی، با استفاده از داده‌های تاریخی و پارامترهای کلیدی از جمله اطلاعات روز تست، تلاش دارد ابزاری نوین برای ارزیابی مدیریت گله، به‌ویژه در دوره انتقال، ارائه دهد. دوره انتقال، به‌عنوان یکی از حساس‌ترین مراحل زندگی گاوهای شیری (شامل سه هفته قبل تا یک ماه پس از زایمان)، نیازمند توجه ویژه‌ای است، زیرا مشکلات متابولیکی و سلامتی در این دوره می‌توانند تأثیرات بلندمدتی بر تولید شیر و سلامت کلی دام داشته باشند [۱، ۲]. این فصل به بررسی جامع پژوهش‌های پیشین در زمینه پیش‌بینی تولید شیر، کاربرد روش‌های نوین مانند یادگیری ماشین در دام‌پروری، عوامل مؤثر بر عملکرد شیر در اوایل شیردهی، و اهمیت پایش دوره انتقال با استفاده از شاخص‌های خاص

مانند شاخص دوره انتقال می‌پردازد. مرور این مطالعات نه تنها زمینه علمی پژوهش را فراهم می‌کند، بلکه نقاط قوت و ضعف روش‌های موجود را نیز مشخص می‌سازد تا مسیر توسعه مدل‌های جدید هموار شود. با توجه به تنوع داده‌ها و پیچیدگی‌های بیولوژیکی، این فصل تلاش دارد با ارائه یک دید کلی و عمیق، پایه‌ای محکم برای تحقیقات آتی ایجاد کند. همچنین، با در نظر گرفتن محدودیت‌های موجود در مطالعات پیشین، مانند کمبود داده‌های سلامتی یا عدم تعمیم‌پذیری مدل‌ها، راهکارهایی برای بهبود پیشنهاد خواهد شد.

۳-۲ دوره انتقال و اهمیت پایش آن در گاوهای شیری

دوره انتقال در گاوهای شیری، که به طور معمول بازه شش هفته‌ای در محدوده زایمان را شامل می‌شود، از حساس‌ترین مراحل فیزیولوژیکی در چرخه زندگی تولیدی دام است [۱]. در این مدت کوتاه، دام تغییرات متابولیکی و هورمونی عمیقی را تجربه می‌کند که شامل کاهش مصرف ماده خشک و همزمان افزایش شدید نیازهای غذایی برای تولید شیر است [۹]. این عدم تطابق بین مصرف خوراک و نیازهای انرژی، منجر به بروز تعادل منفی انرژی^۱ و اختلال در عملکرد سیستم ایمنی می‌شود. در نتیجه، گاوها به شدت مستعد ابتلا به انواع بیماری‌های متابولیکی و عفونی، از جمله کتوز، ورم پستان، متریت، و جابجایی شیردان می‌گردند [۲]. آمارها نشان می‌دهند که ۳۰ تا ۵۰ درصد از گاوها در این دوره دچار حداقل یک اختلال سلامتی می‌شوند که می‌تواند به طور مستقیم بر تولید شیر جاری و عملکرد تولیدمثلی آینده آن‌ها تأثیر منفی بگذارد [۸].

روش‌های سنتی برای شناسایی و مدیریت مشکلات دوره انتقال، غالباً بر پایه آزمایش‌های آزمایشگاهی نمونه‌های خون یا شیر (مانند اندازه‌گیری نشانگرهای متابولیکی) استوار هستند [۴]. اگرچه این روش‌ها اطلاعات ارزشمندی ارائه می‌دهند، اما اغلب نیازمند مداخله دستی دامدار هستند که می‌تواند به شناسایی دیرنگام مشکلات منجر شود و کارایی پایش را کاهش دهد [۸]. این امر، نیاز به توسعه ابزارهای پایش خودکار و داده‌محور را برای شناسایی زودهنگام دام‌های در معرض خطر و اتخاذ تصمیمات پیشگیرانه، بیش از پیش ضروری می‌سازد.

۳-۲-۱ شاخص دوره انتقال و محدودیت‌های آن

یکی از ابزارهای مهمی که برای ارزیابی موفقیت یا شکست دوره انتقال در گاوهای شیری چند شکم‌زا پیشنهاد شده است، شاخص دوره انتقال است [۳]. این شاخص بر اساس تفاوت بین تولید شیر مشاهده شده و تولید شیر پیش‌بینی شده در اولین روز تست شیردهی پس از زایمان عمل می‌کند. مدل شاخص دوره انتقال برای پیش‌بینی تولید شیر، از پارامترهای حاصل از شیردهی جاری و قبلی استفاده می‌کند، از جمله روزهای شیردهی در اولین

^۱Negative Energy Balance (NEB)

روز تست، تولید شیر ۳۰۵ روزه قبلی، طول شیردهی قبلی، نمره لگاریتمی سلول‌های سوماتیک^۱ در آخرین تست شیردهی قبلی، روزهای خشک، و دفعات شیردوشی جاری [۳]. با این حال، کاربرد شاخص دوره انتقال عمدتاً به گاوهای محدود می‌شود که در دومین یا شیردهی‌های بعدی خود قرار دارند، زیرا این شاخص برای عملکرد تلیسه‌ها^۲ (گاوهای شکم اول) که سابقه شیردهی قبلی ندارند، طراحی نشده است [۹].

۳-۲-۲ چالش پایش دوره انتقال در تلیسه‌ها

دوره انتقال برای تلیسه‌ها نیز به همان اندازه گاوهای بالغ چالش‌برانگیز است [۹]. تلیسه‌ها علاوه بر شروع تولید شیر، همچنان در مرحله رشد بدنی نیز قرار دارند که نیازهای تغذیه‌ای آن‌ها را پیچیده‌تر می‌کند [۹]. مطالعات نشان داده‌اند که تلیسه‌ها نیز پس از زایمان مستعد اسیدوز شکمبه و کتوز هستند [۹]. با توجه به محدودیت شاخص دوره انتقال برای تلیسه‌ها، نیاز به توسعه ابزارهایی برای ارزیابی و پیش‌بینی عملکرد شیردهی در این دسته از دام‌ها، به منظور کمک به دامداران در فرآیند تصمیم‌گیری، به شدت احساس می‌شود. این امر به ویژه از آن جهت حائز اهمیت است که یک استراتژی مدیریتی موفق برای گاوهای چند شکم‌زا می‌تواند به طور مشابه برای تلیسه‌ها نیز مؤثر باشد، به شرط آنکه ابزارهای پایش مناسب در دسترس باشند [۹].

۳-۳ روش‌های پیش‌بینی عملکرد شیر

۳-۳-۱ روش‌های سنتی و آماری

پژوهش‌های اولیه در حوزه پیش‌بینی تولید شیر عمدتاً بر پایه مدل‌های آماری کلاسیک استوار بودند. این مدل‌ها، مانند رگرسیون خطی چندگانه^۳ و مدل‌های گاوسین^۴، با استفاده از متغیرهایی نظیر مشخصات ظاهری، نژاد، و رکوردهای اولیه شیردهی، تلاش می‌کردند عملکرد آتی دام را تخمین بزنند. به طور سنتی، داده‌های تولید شیر در روزهای تست^۵ به منظور پیش‌بینی تولید آتی دام بر اساس منحنی شیردهی مورد استفاده قرار می‌گرفتند. در بسیاری از این موارد، تابع گامای ناقص که توسط وود در سال ۱۹۶۷ پیشنهاد شد، یکی از متداول‌ترین توابع برای توصیف منحنی شیردهی بوده است [۱۱]. همچنین، مدل‌هایی برای ارزیابی ژنتیکی گاوهای شیری به عنوان جایگزینی برای عملکرد سنتی ۳۰۵ روزه شیردهی پیشنهاد شده‌اند که قادرند اثرات محیطی را در روز ثبت شیر لحاظ کنند [۱۲]. با این حال، این روش‌ها، هرچند پایه‌گذار تحلیل‌های آماری در این حوزه بودند، اما در مدل‌سازی روابط پیچیده و غیرخطی موجود در داده‌های بیولوژیکی دام‌پروری با محدودیت‌هایی مواجه بودند [۶]. به عنوان مثال، گیوارا-اسکوبار و همکاران در مطالعه خود برای پیش‌بینی تولید شیر ۳۰۵ روزه از

^۱ SCC

^۲ Heifer

^۳ Multiple Linear Regression (MLR)

^۴ Gaussian Models

^۵ Test Day (TD)

داده‌های روزهای تست، به محدودیت‌هایی در دقت مدل‌های سنتی و وابستگی به داده‌های منظم اشاره کرده‌اند [۶]. همچنین، این مدل‌ها غالباً قادر به شناسایی الگوهای ظریف و پیچیده‌ای که در پس داده‌های بزرگ و متنوع نهفته‌اند، نبودند.

۳-۲ کاربرد یادگیری ماشین در پیش‌بینی عملکرد شیر

با گسترش داده‌های حجیم در دام‌پروری و پیشرفت الگوریتم‌های یادگیری ماشین، رویکردهای نوین جایگزین روش‌های سنتی شدند. الگوریتم‌هایی نظیر درخت تصمیم، شبکه‌های عصبی مصنوعی، ماشین‌های بردار پشتیبانی، و جنگل‌های تصادفی به دلیل توانایی بالای خود در کشف الگوهای پیچیده و مدل‌سازی روابط غیرخطی، به‌طور گسترده‌ای مورد استفاده قرار گرفته‌اند [۶]. استفاده از مدل‌های یادگیری ماشین مزایای قابل توجهی نسبت به مدل‌های رگرسیون سنتی دارد؛ از جمله قابلیت مدیریت داده‌های ناقص، روال‌های اعتبارسنجی متقاطع، انتخاب ویژگی‌ها، بهینه‌سازی هایپرپارامترها، و مدل‌های ترکیبی^۱ خودکار که همگی به منظور جلوگیری از بیش‌برازش و بهبود تعمیم‌پذیری مدل طراحی شده‌اند [۶].

پیش‌بینی اولین شیردهی روز تست با یادگیری ماشین

پیش‌بینی اولین رکورد شیردهی^۲ در شیردهی بعدی، به ویژه در اوایل دوره انتقال، از اهمیت خاصی برخوردار است، چرا که مشکلات سلامتی در این دوره می‌توانند تأثیرات منفی قابل توجهی بر تولید شیر داشته باشند [۹]. **سالامون و همکاران** به منظور پیش‌بینی اولین رکورد شیردهی در گاوهای شیری، از داده‌های تاریخی روز تست^۳ شیردهی قبلی و اطلاعات اضافی گاو و گله استفاده کردند [۸]. آن‌ها مجموعه‌ای از مدل‌های رگرسیون جنگل تصادفی را توسعه دادند و عملکرد آن‌ها را در برابر چهار مدل پایه^۴ ساده‌تر مقایسه کردند. مدل‌های جنگل تصادفی عملکرد پیش‌بینی بهتری داشتند و ریشه میانگین مربع خطا^۵ آن‌ها بین ۶/۰۸ تا ۶/۲۴ کیلوگرم شیر بود، که در محدوده حداقل ریشه میانگین مربع خطا نظری (۶ کیلوگرم) برای پیش‌بینی تولید شیر روزانه قرار می‌گیرد [۸]. این مطالعه نشان داد که استفاده از داده‌های تاریخی تولید شیر امکان پیش‌بینی دقیق تولید در آغاز شیردهی بعدی را فراهم می‌کند و می‌تواند به عنوان بخشی از ابزارهای پایش سلامت مبتنی بر داده مورد استفاده قرار گیرد. مهمترین ویژگی‌های شناسایی شده در این مدل‌ها شامل روزهای شیردهی در اولین روز تست شیردهی بعدی^۶ و تولید شیر ۳۰۵ روزه تجمعی^۷ شیردهی قبلی بود. همچنین، تولید شیر در روزهای تست چهارم

^۱Ensemble

^۲First Test Day Milk(FT-MILK)

^۳Test Day Records(TDRs)

^۴Benchmark

^۵RMSE

^۶DIM TD1X+1

^۷M305

و پنجم شیردهی قبلی نیز اهمیت بالایی در پیش‌بینی داشت [۸].

دالاگو و همکاران با تمرکز بر پیش‌بینی اولین رکورد شیردهی در تلیسه‌های شیری، به این نتیجه رسیدند که مدل‌های یادگیری ماشین پتانسیل بالایی برای پر کردن خلاء موجود در ابزارهای پایش دوره انتقال برای این دسته از دام‌ها دارند [۹]. آن‌ها سه نوع مدل رگرسیون خطی چندمتغیره، جنگل تصادفی و شبکه عصبی مصنوعی را ارزیابی کردند. نتایج نشان داد که مدل شبکه عصبی مصنوعی عملکرد بهتری در پیش‌بینی اولین رکورد شیردهی نسبت به رگرسیون خطی چندمتغیره و جنگل تصادفی دارد (میانگین خطای مطلق کمتر از ۴ کیلوگرم). این مطالعه همچنین بر اهمیت متغیرهایی مانند وزن در زمان زایمان، روزهای شیردهی در روز تست، و بتا-هیدروکسی‌بوتیرات^۱ شیر (به عنوان نشانگر کتوز) در پیش‌بینی اولین رکورد شیر تأکید کرد. در حالی که مدل جنگل تصادفی دچار بیش‌برازش شد، مدل شبکه عصبی مصنوعی پایداری و تعمیم‌پذیری بهتری نشان داد که آن را به گزینه‌ای مناسب‌تر برای مدل‌سازی معیارهای طرح بهبود گله‌های شیری^۲ تبدیل می‌کند [۹]. این تحقیق اولین قدم مهمی در توسعه ابزاری مشابه شاخص دوره انتقال برای تلیسه‌ها محسوب می‌شود.

پیش‌بینی تولید شیر ۳۰۵ روزه با داده‌های اولیه شیردهی

در حالی که پژوهش حاضر بر پیش‌بینی اولین رکورد شیردهی متمرکز است، پژوهش‌هایی که به پیش‌بینی کل دوره شیردهی (مانند ۳۰۵ روزه) با استفاده از داده‌های اولیه شیردهی می‌پردازند، نیز ارتباط نزدیکی با هدف این تحقیق دارند. **گیوارا-اسکوبار و همکاران** به دنبال دستیابی به یک مدل یادگیری ماشین برای پیش‌بینی تولید شیر ۳۰۵ روزه^۳ از همان دوره شیردهی، با استفاده از داده‌های روزهای تست بودند [۶]. آن‌ها پایگاه داده‌ای از ۱۱,۸۹۲ رکورد تولید شیر روزانه از گاوهای هلشتاین-فریزین^۴ را مورد استفاده قرار دادند. مدل‌های یادگیری ماشین مختلفی از جمله یادگیری عمیق، ماشین تقویت گرادیان^۵، افزایش گرادیان افراطی و مدل خطی تعمیم‌یافته مورد بررسی قرار گرفتند. نتایج آن‌ها نشان داد که مدل‌های ترکیبی بهترین برازش را در پیش‌بینی شیر جمعی ۳۰۵ روز ارائه می‌دهند (ضریب تعیین ۰/۷۹ و ریشه میانگین مربع خطا ۱۲۵۶).

این مطالعه تأکید کرد که تولید شیر در فاز اولیه شیردهی (روزهای ۵، ۱۰، ۲۰، ۳۰) مهمترین متغیرها در مدل‌های پیش‌بینی شیرتجمعی ۳۰۵ روز بودند. این رویکرد نشان می‌دهد که حتی با داده‌های محدود از روزهای اولیه شیردهی، می‌توان پیش‌بینی‌های دقیقی از عملکرد کلی شیردهی به دست آورد که می‌تواند برای اتخاذ تصمیمات مدیریتی مهم در تغذیه، سلامت، و بهبود ژنتیکی به کار رود [۶].

¹Beta-hydroxybutyrate

²Dairy Herd Improvement(DHI)

³MY305

⁴Holstein-Friesian

⁵Gradient Boost Machine(GBM)

۳-۴ عوامل تأثیرگذار بر عملکرد شیر در اوایل شیردهی و دوره انتقال

مطالعات گوناگون نشان داده‌اند که عوامل متعددی بر عملکرد شیر در اوایل دوره شیردهی و به طور کلی بر موفقیت دوره انتقال تأثیرگذار هستند. شناخت این عوامل برای ساخت مدل‌های پیش‌بینی دقیق بسیار حیاتی است:

۱. سابقه تولید شیر پیشین: داده‌های تاریخی مانند تولید ۳۰۵ روزه شیردهی قبلی^۱، تولید شیر در روزهای تست خاص در شیردهی قبلی (مانند روزهای تست چهارم، پنجم و ششم) و حداکثر تولید شیر در شیردهی قبلی، از مهم‌ترین ورودی‌ها برای پیش‌بینی عملکرد آتی دام هستند [۸]. این سوابق به مدل‌ها امکان می‌دهند تا ظرفیت تولیدی ژنتیکی و سابقه عملکردی هر دام را در نظر بگیرند.

۲. روزهای شیردهی در زمان تست^۲: این متغیر نقش مستقیمی در تعیین مقدار شیر ثبت‌شده در اولین تست دارد و به دلیل شیب صعودی منحنی شیردهی در آغاز شیردهی، تأثیر قابل توجهی بر پیش‌بینی اولین رکورد شیردهی دارد [۸، ۹]. همچنین، تولید شیر در روزهای اولیه شیردهی (مانند روزهای ۳۰، ۲۰، ۱۰، ۵) به عنوان مهم‌ترین متغیرها در پیش‌بینی شیر تجمعی ۳۰۵ روزه شناخته شده‌اند [۶].

۳. دوره شیردهی: الگوی منحنی شیردهی و پتانسیل تولید شیر گاو بسته به شماره زایش دام تغییر می‌کند. گاوهای جوان‌تر (تلیسه‌ها) ممکن است الگوی رشد متفاوتی نسبت به گاوهای بالغ داشته باشند و این عامل باید در مدل‌سازی لحاظ شود [۶، ۹].

۴. طول دوره خشک و فاصله گوساله‌زایی: مدت زمان دوره خشک بین دو شیردهی و فاصله گوساله‌زایی نیز بر تولید شیر بعدی تأثیرگذار است. یک دوره خشک بهینه برای بازسازی بافت پستان و آماده‌سازی برای شیردهی بعدی ضروری است [۸].

۵. سلامت پستان و شمارش سلول‌های سوماتیک^۳: شمارش بالای سلول‌های سوماتیک معمولاً با التهاب پستان (ورم پستان) و کاهش عملکرد شیر همراه است. این شاخص می‌تواند به عنوان یک نشانگر مهم برای سلامت پستان و در نتیجه تأثیرگذاری بر تولید شیر در نظر گرفته شود [۶].

۶. شاخص‌های متابولیکی و بهداشتی: نشانگرهایی مانند بتا-هیدروکسی‌بوتیرات شیر می‌توانند به عنوان شاخصی برای کتوزیس (یک اختلال متابولیکی شایع در دوره انتقال) عمل کنند و تأثیر منفی قابل

^۱M305X

^۲Days In Milk(DIM)

^۳SCC

توجهی بر تولید شیر اولیه دارند [۹]. سایر عوامل مانند دوقلوزایی، سهولت زایمان، و اندازه گوساله نیز می‌توانند بر سلامت دام و در نتیجه اولین رکورد شیر تأثیر بگذارند [۹].

۷. **وزن دام در زمان زایمان:** وزن مناسب در زمان زایمان با عملکرد تولیدی بهتر در تلیسه‌ها مرتبط است و می‌تواند به عنوان یک عامل مثبت در پیش‌بینی اولین رکورد شیر در نظر گرفته شود [۹].

۸. **فاکتورهای محیطی و مدیریتی در سطح گله:** عواملی نظیر ماه زایش یا فصل شیردهی و میانگین‌های عملکردی گله (مانند میانگین تولید شیر تجمعی در روزهای مختلف، میانگین سن اولین زایمان، میانگین فاصله گوساله‌زایی، و میانگین روزهای خشک) نیز می‌توانند تأثیر قابل توجهی بر عملکرد فردی دام داشته باشند. این عوامل نشان‌دهنده شرایط مدیریتی و محیطی حاکم بر گله هستند و می‌توانند تفاوت در سطوح تولید را توجیه کنند [۸، ۶].

شناسایی و گنجاندن این متغیرهای کلیدی در مدل‌های پیش‌بینی، دقت و قدرت تفسیر آن‌ها را به طور قابل توجهی افزایش می‌دهد و بینش‌های ارزشمندی را برای بهبود شیوه‌های مدیریتی ارائه می‌کند.

۳-۵ چالش‌ها، محدودیت‌ها و پژوهش‌های آتی

با وجود پیشرفت‌های قابل توجه در زمینه پیش‌بینی عملکرد شیر با استفاده از یادگیری ماشین، همچنان چالش‌ها و محدودیت‌هایی وجود دارد که مسیر را برای پژوهش‌های آتی هموار می‌سازد:

- **کیفیت و تکمیل بودن داده‌ها:** یکی از بزرگترین محدودیت‌ها، عدم دسترسی به پایگاه داده‌های جامع و با کیفیت از اطلاعات سلامتی دام است. نبود اطلاعات دقیق بیماری‌ها، انتخاب گاوهای "سالم" و "بدون اختلال" در دوره انتقال را دشوار می‌سازد و می‌تواند بر دقت مدل‌های پیش‌بینی تولید شیر "مورد انتظار" تأثیر بگذارد [۸]. علاوه بر این، پراکندگی داده‌های روز تست شیردهی و نبود ثبت منظم تمام اطلاعات (مانند درصد چربی، پروتئین، یا شمارش سلول‌های سوماتیک در تمامی تست‌ها) می‌تواند کارایی مدل‌ها را کاهش دهد [۶].

- **تعمیم‌پذیری مدل‌ها:** بسیاری از مطالعات، از جمله **دالاگو و همکاران**، تنها بر یک نژاد خاص (مانند هلشتاین) متمرکز بوده‌اند [۹]. این امر نیاز به توسعه و ارزیابی مدل‌ها برای نژادهای دیگر را ضروری می‌سازد تا قابلیت تعمیم‌پذیری آن‌ها در سناریوهای مختلف دامداری تضمین شود. همچنین، تغییرات قابل توجه بین گله‌ها (مانند تفاوت در ژنتیک گله، شیوه‌های مدیریتی، و محیط) می‌تواند بر عملکرد

مدل‌ها تأثیر بگذارند و گنجانند "فاکتور گله" به عنوان یک متغیر در مدل‌ها، می‌تواند دقت پیش‌بینی را بهبود بخشد [۹].

• **بیش‌برازش در مدل‌ها:** در برخی موارد، مانند مدل جنگل تصادفی در مطالعه **دالاگو و همکاران**، پدیده بیش‌برازش مشاهده شده است که می‌تواند توانایی تعمیم‌پذیری مدل را به داده‌های جدید کاهش دهد [۹]. اگرچه الگوریتم‌های یادگیری ماشین مدرن دارای مکانیزم‌هایی برای مقابله با بیش‌برازش هستند، اما انتخاب صحیح هایپرپارامترها و اعتبارسنجی دقیق مدل برای جلوگیری از این پدیده حیاتی است.

• **محدودیت‌های روزهای تست شیردهی:** اگرچه داده‌های روز تست شیردهی به طور گسترده در دسترس هستند و استانداردسازی شده‌اند، اما به دلیل فاصله زمانی بین ثبت رکوردها (معمولاً هر چهار تا هشت هفته)، ممکن است رکوردهای مربوط به اوایل شیردهی بسیار دیرتر از زمان بروز مشکلات سلامت ثبت شوند [۸]. این محدودیت می‌تواند کاربرد این داده‌ها را در پایش زمان واقعی دوره انتقال با چالش مواجه کند. با این حال، اگر قدرت پیش‌بینی مشکلات دوره انتقال با استفاده از این داده‌ها اثبات شود، می‌توان به فکر تغییر روش ثبت تولید در مراحل اولیه شیردهی بود (مثلاً افزایش دفعات ثبت در هفته‌های اول) [۸].

• **اعتبارسنجی کاربردی مدل‌ها:** مدل‌های پیش‌بینی‌کننده توسعه یافته، اگرچه عملکرد آماری خوبی از خود نشان داده‌اند، اما نیاز به اعتبارسنجی گسترده در محیط‌های واقعی دامداری دارند تا میزان کارایی آن‌ها به عنوان ابزارهای عملی پایش و تصمیم‌گیری مورد ارزیابی قرار گیرد [۸، ۹]. این شامل بررسی تأثیر دام‌هایی است که به دلیل بیماری‌های مرتبط با دوره انتقال، پیش از اولین روز تست حذف می‌شوند، بر قابلیت‌های پایش مدل‌ها [۸].

پژوهش‌های آتی می‌توانند بر جمع‌آوری و یکپارچه‌سازی پایگاه داده‌های غنی‌تر شامل اطلاعات سلامت دقیق‌تر، ارزیابی مدل‌ها بر روی نژادهای مختلف و در محیط‌های گله‌ای متنوع، و توسعه مدل‌هایی با قابلیت تفسیرپذیری بالاتر تمرکز کنند تا کاربرد عملی این ابزارها در صنعت دامپروری به حداکثر رسد [۶].

۳-۶ نتیجه‌گیری

مرور پژوهش‌های پیشین نشان می‌دهد که پیش‌بینی دقیق عملکرد شیر در گاوهای شیری، به‌ویژه در اوایل دوره شیردهی و دوره حساس انتقال، از اهمیت حیاتی برای مدیریت بهینه دامداری برخوردار است. در حالی که روش‌های آماری سنتی محدودیت‌هایی در مدل‌سازی روابط پیچیده دارند، پیشرفت‌های اخیر در یادگیری ماشین

راهکارهای قدرتمندی را ارائه کرده‌اند. مطالعات اخیر، از جمله تحقیقات سالامون و همکاران، دالاگو و همکاران، و گیوارا-اسکوبار و همکاران، به وضوح پتانسیل بالای الگوریتم‌هایی نظیر جنگل تصادفی، شبکه‌های عصبی مصنوعی، و مدل‌های ترکیبی را در پیش‌بینی دقیق تولید شیر نشان داده‌اند. این مدل‌ها قادرند با بهره‌گیری از داده‌های تاریخی تولید شیر (مانند رکورد ۳۰۵ روزه شیردهی قبلی و رکوردهای روز تست اولیه) و سایر اطلاعات کلیدی (نظیر دوره شیردهی، وزن در زمان زایمان، و شاخص‌های سلامتی مانند بتا-هیدروکسی بوتیرات)، عملکرد شیردهی آینده دام را با دقت مناسبی پیش‌بینی کنند. این پژوهش‌ها تأکید می‌کنند که پیش‌بینی اولین رکورد شیردهی در دوره بعدی، می‌تواند به عنوان یک ابزار پایش مؤثر برای شناسایی زودهنگام دام‌های در معرض خطر در دوره انتقال عمل کند و به دامداران امکان دهد تا مداخلات مدیریتی و بهداشتی لازم را به موقع انجام دهند. با این وجود، چالش‌هایی نظیر کیفیت و کامل بودن داده‌های سلامت، تعمیم‌پذیری مدل‌ها به نژادها و گله‌های مختلف، و نیاز به اعتبارسنجی عملی مدل‌های توسعه‌یافته همچنان وجود دارد. پژوهش حاضر، با تمرکز بر پیش‌بینی اولین رکورد شیر با استفاده از یادگیری ماشین و اطلاعات دوره‌های پیشین و همچنین داده‌های روز تست، در راستای پر کردن این شکاف‌های پژوهشی و توسعه ابزاری کاربردی برای دامداران کشور گام برمی‌دارد. هدف نهایی این تحقیق، ارائه یک مدل قوی و قابل اعتماد است که بتواند به بهبود سلامت گله، افزایش بهره‌وری، و ارتقاء پایداری صنعت دامپروری کشور کمک کند.

فصل چهارم

توسعه مدل

۴-۱ مقدمه

این فصل به تشریح فرآیند توسعه مدل‌های هوشمند اختصاص دارد که برای پیش‌بینی مقدار شیر تولیدی در اولین رکورد دوره بعدی گاوهای شیری طراحی شده است. این مدل‌ها با بهره‌گیری از داده‌های گسترده‌ای از ۹۹ دامداری مختلف در سراسر کشور، که شامل اطلاعات جامع و متنوعی از عملکرد شیر و شاخص‌های مرتبط است، توسعه یافته است. هدف اصلی، تحلیل داده‌های تاریخی، اجرای مراحل پیش‌پردازش، آموزش مدل‌های پیش‌بینی و ارزیابی دقت آن‌ها می‌باشد. در این فصل، ابتدا به تحلیل داده‌های دامداری **رحمت‌آباد** به عنوان یک نمونه موردی پرداخته می‌شود تا درک بهتری از شاخص دوره انتقال فراهم شود. سپس، مراحل پیش‌پردازش داده‌ها، آموزش مدل‌ها با استفاده از مجموعه داده‌های جامع، و نتایج حاصل از ارزیابی آن‌ها ارائه خواهد شد.

۴-۲ تحلیل داده‌های دامداری رحمت‌آباد

داده‌های مورد بررسی در این بخش، شامل سوابق چندین دوره شیردهی گاوها در دامداری رحمت‌آباد است. این داده‌ها شامل اطلاعاتی نظیر تعداد گاوها، تاریخ زایش، تعداد شکم‌های زایش، شاخص دوره انتقال، ویژگی‌های زیستی دام، و شاخص‌های بهداشتی مانند شمارش سلول‌های سوماتیک بوده و به صورت جدول‌های سازمان‌یافته

جمع‌آوری شده‌اند. دامداری رحمت‌آباد به‌عنوان یک نمونه انتخاب شده تا الگوهای فصلی و مدیریت دوره انتقال در یک محیط خاص مورد مطالعه قرار گیرد، اما مجموعه داده اصلی برای آموزش مدل‌ها از ۹۹ دامداری مختلف در سطح کشور استخراج شده است.

۴-۲-۱ شاخص دوره انتقال در ماه‌های مختلف سال

در این بخش، تغییرات شاخص دوره انتقال در طول ماه‌های سال بررسی شده است. این شاخص برای گاوهای شکم اول، شکم دوم، و گاوهای چندزا (شکم‌های سوم تا پنجم) به‌صورت جداگانه محاسبه شده تا الگوهای فصلی و تأثیر آن‌ها بر کیفیت عبور از دوره انتقال تحلیل شود. هدف، ارائه دیدگاهی جامع برای بهبود مدیریت گله‌ها و تصمیم‌گیری‌های مبتنی بر داده است.

برای این منظور، داده‌های دامداری رحمت‌آباد طی یک دوره یک‌ساله مورد ارزیابی قرار گرفته و گاوهای تازه‌زا در هر ماه دسته‌بندی شده‌اند. سپس، میانگین شاخص دوره انتقال برای هر گروه در هر ماه محاسبه شده است. نتایج این تحلیل در جدول زیر ارائه شده است:

جدول ۴-۱: شاخص دوره انتقال برای گروه‌های مختلف در ماه‌های مختلف

کل تازه‌زا		شکم دوم		شکم‌های سوم تا پنجم	
تعداد	شاخص دوره انتقال	تعداد	شاخص دوره انتقال	تعداد	شاخص دوره انتقال
۲۷۱	۷/۶	۱۱۵	۷/۶	۱۵۶	۷/۶
۲۷۰	۵/۱	۱۱۶	۴/۶	۱۵۴	۵/۴
۱۶۳	۵/۵	۶۳	۵/۰	۱۰۰	۵/۷
۱۸۷	۵/۹	۸۰	۵/۷	۱۰۷	۶/۱
۱۷۳	۴/۸	۵۴	۴/۹	۱۱۹	۴/۷
۱۳۷	۳/۳	۴۳	۳/۹	۹۴	۳/۰
۱۶۷	۴/۹	۶۵	۴/۴	۱۰۲	۵/۳
۱۲۰	۶/۵	۵۴	۷/۵	۶۶	۵/۶
۱۳۰	۴/۳	۷۲	۳/۹	۵۸	۴/۸
۱۲۵	۳/۵	۷۷	۲/۶	۴۸	۵/۰
۱۳۴	۵/۳	۸۸	۶/۲	۴۶	۳/۶
۱۶۹	۵/۴	۷۷	۵/۵	۹۲	۵/۳
۲۲۰	۴/۵	۷۸	۵/۹	۱۴۲	۳/۷
فروردین		فروردین		فروردین	
اردیبهشت		اردیبهشت		اردیبهشت	
خرداد		خرداد		خرداد	
تیر		تیر		تیر	
مرداد		مرداد		مرداد	
شهریور		شهریور		شهریور	
مهر		مهر		مهر	
آبان		آبان		آبان	
آذر		آذر		آذر	
دی		دی		دی	
بهمن		بهمن		بهمن	
اسفند		اسفند		اسفند	
فروردین (سال بعد)		فروردین (سال بعد)		فروردین (سال بعد)	


بر اساس نتایج جدول، شاخص دوره انتقال در طول سال نوسانات قابل توجهی نشان می‌دهد. بالاترین مقدار این شاخص در ماه فروردین سال بعد (۷/۶) مشاهده شده است، که نشان‌دهنده عملکرد مطلوب گاوها در عبور از دوره انتقال و شرایط مدیریتی مناسب در این بازه است. به‌ویژه، گاوهای شکم دوم و شکم‌های سوم تا پنجم

در این ماه شاخص یکسانی داشته‌اند.

در مقابل، کمترین مقدار شاخص برای گاوهای شکم دوم در ماه دی (۲/۶) و برای گاوهای شکم‌های سوم تا پنجم در ماه شهریور (۳/۰) ثبت شده است. این کاهش می‌تواند ناشی از عوامل محیطی مانند استرس گرمایی، کمبود تغذیه، یا مدیریت نامناسب باشد و نیاز به بررسی دقیق‌تر دارد. به‌طور کلی، این تحلیل می‌تواند به‌عنوان ابزاری برای پایش و بهبود مدیریت دامداری در فصول مختلف سال به کار رود و به تصمیم‌گیری‌های مبتنی بر داده برای افزایش بهره‌وری گله‌ها کمک کند.

۲-۲-۴ روند تغییرات شاخص دوره انتقال

برای بررسی و تحلیل روند شاخص دوره انتقال در طول زمان، نموداری از داده‌های ثبت شده برای دامداری رحمت‌آباد رسم شده است که در شکل ۴-۱ قابل مشاهده است. این نمودار به‌صورت پراکندگی نقاط^۱ با خطوط میانگین متحرک ترسیم شده است. محور افقی نشان‌دهنده فاصله زمانی تا زایش (بر حسب روز) و محور عمودی مقدار شاخص گاوها را نمایش می‌دهد.



شکل ۴-۱: نمودار پراکندگی شاخص دوره انتقال در طول زمان نسبت به زایش

همان‌گونه که در نمودار قابل مشاهده است، هر نقطه نمایانگر یک گاو منفرد و مقدار شاخص آن پس از زایش است. روند کلی میانگین نیز با خط قرمز مشخص شده است تا تغییرات عمومی را بهتر نمایش دهد. در مطالعه‌ی لاکروآ و نوردلوند [۱۳] نیز شکلی مشابه برای پایش برنامه‌های مدیریت دوره انتقال ارائه شده

^۱ scatter plot


است. آن‌ها تاکید دارند که در محاسبه‌ی شاخص دوره انتقال، تمامی گاوهایی که اولین رکورد شیر ثبت شده دارند، تا ۳۶۵ روز در نمودار و محاسبات لحاظ می‌شوند، حتی اگر از گله حذف شده یا بیمار بوده باشند. این موضوع اهمیت بررسی دقیق داده‌های انفرادی را به‌ویژه برای شناسایی موارد شکست مدیریتی نشان می‌دهد.

با تحلیل نمودار حاضر، مشخص می‌شود که مقدار شاخص دوره انتقال به‌صورت میانگین در نزدیکی صفر باقی می‌ماند، اما پراکندگی قابل‌توجهی در مقادیر وجود دارد. این تنوع می‌تواند ناشی از تفاوت در وضعیت بدنی گاوها، مدیریت فردی دام، سلامت پستان، تغذیه و یا خطاهای رکوردگیری باشد. همچنین دام‌هایی با مقادیر منفی شدید ممکن است نشان‌دهنده اختلالات جدی در دوره انتقال یا بیماری‌های متابولیکی نظیر کتوز یا ورم پستان باشند.

با استناد به یافته‌های نوردلوند و همکاران، استفاده از این شاخص می‌تواند ابزاری مؤثر برای پایش مداوم و شناسایی مشکلات مدیریتی در گله باشد، به شرطی که ثبت داده‌ها به‌صورت دقیق و منظم انجام شود [۱۳].

۳-۲-۴ هیستوگرام شاخص دوره انتقال برای گاوهای تازه‌زا

برای بررسی توزیع شاخص دوره انتقال در گله مورد مطالعه، هیستوگرامی از مقادیر شاخص دوره انتقال گاوهای تازه‌زا ترسیم شد (شکل ۲-۴). در این نمودار، محور افقی مقادیر شاخص و محور عمودی تعداد گاوهای مربوط به هر بازه را نشان می‌دهد.



شکل ۲-۴: هیستوگرام شاخص دوره انتقال برای گاوهای تازه‌زا

همان‌طور که در شکل مشخص است، توزیع داده‌ها نسبتاً نرمال بوده و بیشترین فراوانی مربوط به بازه‌ی ۴ تا ۱۰ است. این موضوع نشان می‌دهد که بیشتر گاوها عملکردی نسبتاً نرمال یا کمی بالاتر از پیش‌بینی در اولین

رکورد شیردهی داشته‌اند. مقادیر شاخص نزدیک به صفر نشان‌دهنده آن هستند که عملکرد واقعی دام تقریباً مطابق با مقدار پیش‌بینی‌شده بر اساس داده‌های تاریخی بوده است.


طبق یافته‌های لاکروآ و نوردلوند [۱۳]، چون مقدار پیش‌بینی‌شده‌ی اولین رکورد در فرمول شاخص دوره انتقال بر اساس ویژگی‌های مشابه مانند سن، رکورد قبلی، روزهای خشکی و شمارش سلول‌های سوماتیک محاسبه می‌شود، میانگین شاخص دوره انتقال گله معمولاً نزدیک به صفر قرار می‌گیرد.

با این حال، گستره‌ی پراکندگی مقادیر شاخص دوره انتقال می‌تواند تا بیش از ۷۰۰۰ پوند تفاوت را نشان دهد که بیانگر تفاوت چشم‌گیر بین گله‌هایی با مدیریت انتقال موفق و گله‌هایی با مدیریت ضعیف است. در این راستا، ارائه‌ی حدود صدک دهم، میانگین، و صدک نودم به‌عنوان معیارهایی برای مقایسه عملکرد گله‌ها پیشنهاد شده است. چنین اطلاعاتی می‌تواند نه‌تنها برای پژوهشگران، بلکه برای دامداران نیز ابزار مهمی در جهت اصلاح و بهبود برنامه‌های مدیریت دوره انتقال باشد.

با توجه به نمودار حاضر، می‌توان نتیجه گرفت که وضعیت کلی گله در حد نرمال یا نسبتاً مثبت ارزیابی می‌شود، اما وجود تعداد قابل‌توجهی از دام‌ها با مقادیر شاخص دوره انتقال منفی هشدارهایی درباره کیفیت دوره انتقال برخی از گاوها به همراه دارد و می‌تواند انگیزه‌ای برای بررسی دقیق‌تر شرایط مدیریتی، تغذیه‌ای و سلامت گاوهای خاص باشد.

۴-۲-۴ روند تغییرات نسبت چربی به پروتئین

یکی از شاخص‌های مهم در ارزیابی وضعیت متابولیکی گاوهای شیری در اوایل شیردهی، نسبت چربی به پروتئین شیر است. نسبت بالاتر از ۱/۴ معمولاً به‌عنوان نشانه‌ای از بروز کتوز تحت‌کلینیکی در نظر گرفته می‌شود. شکل ۳-۴ روند تغییرات این نسبت را در طول ماه‌های مختلف رکوردگیری نشان می‌دهد.



شکل ۴-۳: روند تغییرات نسبت چربی به پروتئین در طول ماه‌های مختلف

در این نمودار، هر ستون شامل اطلاعات مربوط به میانگین، صدک ۲۵ و ۷۵، و درصد گاوهایی با نسبت چربی به پروتئین بالاتر از ۱/۴ است:

- در ماه‌های خرداد و تیر، نسبت میانگین چربی به پروتئین به بیش از ۱/۴ نزدیک می‌شود که می‌تواند نشان‌دهنده افزایش خطر بروز کتوز در این ماه‌ها باشد.
- بیشترین درصد گاوها با نسبت بالاتر از ۱/۴ در همین دو ماه دیده می‌شود (ستون‌های بنفش بلندتر)، که می‌تواند ناشی از استرس گرمایی و تغییرات جیره غذایی در فصل گرم سال باشد.
- در مقابل، در ماه‌های آبان، اسفند و اردیبهشت، درصد گاوهایی با نسبت بالا کاهش یافته و میانگین نسبت در حد نرمال (حدود ۱/۱ تا ۱/۲) قرار دارد، که نشان‌دهنده شرایط متابولیکی پایدارتر در این ماه‌ها است.
- در بیشتر ماه‌ها، فاصله بین صدک ۲۵ تا ۷۵ گسترده است که نشان می‌دهد تنوع بین گاوها از نظر متابولیسم قابل توجه است و ممکن است نیاز به بررسی‌های مدیریتی انفرادی وجود داشته باشد.

با توجه به نقش این شاخص در تشخیص اختلالات متابولیکی، پایش مستمر آن در طول سال می‌تواند به عنوان یک ابزار غربالگری مؤثر برای مدیریت پیشگیرانه سلامت گله در نظر گرفته شود. مقایسه نتایج بین ماه‌های مختلف همچنین می‌تواند به شناسایی الگوهای فصلی در بروز کتوز کمک کند.

۴-۲-۵ تعداد ریزش داده خام

در این بخش، وضعیت حذف داده‌ها در متغیرهای کلیدی برای هر ماه رکورد نمایش داده شده است. جدول ۴-۲ اطلاعات مربوط به ریزش در هر مرحله پردازش داده برای متغیرهایی مانند شیر ۳۰۵ روزه، مقدار شیر، روزهای شیردهی، طول آبستنی و طول خشکی را نشان می‌دهد.

جدول ۴-۲: تعداد ریزش داده‌ها به ازای متغیرهای کلیدی در هر ماه رکورد

ماه رکورد	تعداد کل داده‌ها	شیر ۳۰۵ روزه	مقدار شیر	روزهای شیردهی	طول آبستنی	طول خشکی
فروردین	۲۷۹	۰	۳	۰	۵	۲
اردیبهشت	۲۷۱	۰	۱	۰	۰	۰
خرداد	۱۶۸	۰	۱	۰	۵	۳
تیر	۱۹۱	۰	۲	۰	۴	۲
مرداد	۱۷۵	۰	۰	۰	۲	۱
شهریور	۱۳۸	۰	۰	۰	۱	۱
مهر	۱۷۰	۰	۱	۰	۲	۱
آبان	۱۲۲	۰	۱	۰	۱	۱
آذر	۱۳۰	۱	۲	۰	۳	۱
دی	۱۳۶	۰	۰	۰	۶	۵
بهمن	۱۳۷	۰	۰	۰	۳	۰
اسفند	۱۷۳	۰	۰	۰	۴	۲
فروردین (سال بعد)	۲۲۴	۰	۰	۰	۳	۴

تحلیل جدول:

- بیشترین ریزش مربوط به متغیر **طول آبستنی** در ماه دی است (۶ مورد)، که ممکن است ناشی از ثبت ناقص اطلاعات آبستنی در آن دوره باشد.
- در ماه آذر، داده‌ها از نظر شیر ۳۰۵ روزه و مقدار شیر نیز دچار حذف شده‌اند، که اهمیت کنترل کیفیت ثبت در آن ماه را نشان می‌دهد.
- به‌طور کلی، تعداد کل داده‌ها در ماه‌های فروردین، اردیبهشت و تیر بالاتر است که به احتمال زیاد به دلیل تراکم زایش‌ها در فصل بهار است.
- در بیشتر ماه‌ها، تعداد داده‌های حذف‌شده نسبتاً پایین است که نشان‌دهنده کیفیت قابل قبول داده‌های خام است.

۴-۲-۶ گاوهای تازه‌زا با شاخص دوره انتقال کمتر از ۸-

یکی از مهم‌ترین شاخص‌ها در بررسی عملکرد متابولیکی گاوهای تازه‌زا، شاخص دوره انتقال است. مقادیر منفی زیاد این شاخص می‌تواند بیانگر وجود مشکل در سلامت متابولیکی یا مدیریتی گاوها باشد. در جدول ۴-۳، فهرستی از گاوهایی که مقدار شاخص دوره انتقال آن‌ها کمتر از ۸- بوده، ارائه شده است. این جدول شامل اطلاعاتی درباره شماره بدن، دوره شیردهی، روزهای شیردهی، مقدار شاخص دوره انتقال، نسبت چربی به پروتئین، و وضعیت سلامت پستان گاو است.

جدول ۴-۳: گاوهای تازه‌زا با شاخص دوره انتقال کمتر از ۸-

شماره بدن	دوره شیردهی	روزهای شیردهی	شاخص دوره انتقال	نسبت چربی به پروتئین	سلامت پستان
۹۶۰۲۶	۵	۳۳	-۱۲/۵۰	۱/۲۴	غیر عفونی
۹۶۳۱۷	۵	۸	-۱۱/۸۰	—	—
۹۶۴۱۸	۵	۳۳	-۹/۶۹	۰/۹۲	عفونت جدید
۹۶۹۴۵	۵	۱۹	-۱۲/۹۹	۱/۲۵	عفونت جدید
۳۶۲۶۱	۴	۹	-۸/۳۶	۱/۲۸	غیر عفونی
۹۷۱۵۷	۴	۱۲	-۱۳/۳۱	۱/۴۲	غیر عفونی
۹۷۶۳۴	۴	۲۹	-۱۰/۷۲	۱/۴۸	عفونت جدید
۹۷۸۳۴	۴	۳۵	-۱۸/۸۰	—	—
۹۷۸۴۹	۴	۱۵	-۱۳/۸۲	۱/۰۳	غیر عفونی
۳۷۱۴۵	۴	۱۳	-۳۲/۰۰	—	—
۹۸۶۴۸	۳	۱۳	-۸/۷۰	۱/۰۸	غیر عفونی
۹۸۶۵۷	۳	۲۹	-۱۶/۲۲	—	—
۹۸۶۹۰	۳	۸	-۱۳/۲۱	—	—
۹۸۸۵۴	۳	۳۰	-۸/۱۹	۱/۱۰	غیر عفونی
۹۸۹۶۹	۳	۱۷	-۸/۴۶	۱/۳۴	عفونت مزمن
۳۸۰۵۰	۳	۳۵	-۸/۱۶	۱/۰۹	غیر عفونی
۳۸۰۹۸	۳	۲۳	-۹/۶۳	۱/۶۵	غیر عفونی
۳۸۱۳۴	۳	۱۴	-۲۳/۷۵	—	—
۹۹۴۲۰	۲	۲۹	-۱۸/۹۵	—	—
۹۹۷۷۳	۲	۲۶	-۱۶/۳۴	—	—
۹۹۸۹۶	۲	۱۴	-۱۰/۱۱	۱/۳۳	غیر عفونی
۳۹۲۵۲	۲	۱۲	-۱۱/۱۲	—	—

تحلیل جدول:

- دام‌هایی با شاخص دوره انتقال بسیار پایین (کمتر از ۱۰-) معمولاً در یکی از شرایط زیر قرار دارند: کاهش شدید شیر در اولین آزمون، وضعیت متابولیکی نامناسب، یا مشکلاتی مانند کتوز یا عفونت پستان.

- برخی از گاوهایی که نسبت چربی به پروتئین بالای ۱/۴ داشته‌اند (مانند شماره‌های ۹۷۶۳۴ و ۹۷۱۵۷)، احتمالاً دچار کتوز تحت‌کلینیکی شده‌اند.
- درصد قابل توجهی از رکوردها (بیش از ۳۰٪) فاقد اطلاعات نسبت چربی به پروتئین یا سلامت پستان هستند، که این موضوع اهمیت کامل بودن داده‌ها در ارزیابی دقیق را نشان می‌دهد.
- برخی از موارد، نظیر گاو شماره ۳۷۱۴۵، دارای شاخص دوره انتقال بسیار منفی (بیش از ۳۰ -) بوده‌اند که نیاز به بررسی خاص در مورد عوامل مدیریتی یا بیماری دارد.

۳-۴ پیش‌پردازش داده‌ها^۱

در این بخش، مراحل آماده‌سازی و پاک‌سازی داده‌ها برای مدل‌سازی ارائه می‌شود. ابتدا ساختار کلی مجموعه داده توصیف می‌گردد، سپس روش‌های مقابله با مقادیر گمشده، استانداردسازی متغیرها، و تقسیم‌بندی داده‌ها شرح داده شده و در پایان، توزیع آماری متغیرها و ماتریس همبستگی میان آن‌ها تحلیل می‌شود.

۱-۳-۴ توصیف مجموعه داده^۲

مجموعه داده مورد استفاده شامل رکوردهایی از دام‌های موجود در ۹۹ دامداری در سراسر کشور است. این داده‌ها از روی نرم‌افزار سس^۳ استخراج و در قالب فایل اکسل دریافت شده‌اند. ستون‌های اصلی این مجموعه داده به شرح زیر است:

- گله^۴: شماره گله دام.
- دوره شیردهی^۵: دوره شیردهی (شکم اول، دوم و ...).
- سال زایش^۶: سال زایش دام.
- ماه زایش^۷: ماه زایش دام.
- اولین رکورد شیر^۸: مقدار شیر ثبت شده در اولین رکورد پس از زایمان (متغیر هدف).
- روز رکورد گیری اولین رکورد شیر^۹: روز ثبت اولین رکورد شیر پس از زایمان.

^۱Data Preprocessing

^۲Data Set

^۳SAS

^۴Hrd

^۵milkperiod

^۶zdate

^۷zdate_month

^۸firstmilk

^۹firstmilkdays

- طول دوره آبستنی^۱: مدت آبستنی دام (معمولاً ۹ ماه).
 - طول دوره خشکی^۲: تعداد روزهای خشکی پیش از زایمان بعدی. تقریباً ۲ ماه مانده به زایمان بعدی دام را خشک می‌کنند که به آن دوران خشک می‌گویند. بعد از زایمان حدود ۲ یا ۳ یا ۴ ماه بعد از زایمان آبستن می‌شود. وقتی آبستن شد، از ۹ ماه که آبستنه، ۷ ماهه که آبستنه خشکش می‌کنند.
 - طول دوره شیردهی^۳: طول دوره شیردهی که در واقع نقطه مقابل طول دوره خشکی می‌باشد.
 - گروه^۴: گروه‌بندی ترکیبی بر اساس دروه شیردهی، ماه زایش و طول آبستنی.
 - شیرتجمعی ۳۰۵ روز^۵: مقدار شیر تجمعی در ۳۰۵ روز فعلی.
 - شیرتجمعی ۳۰۵ روز گذشته^۶: مقدار شیر تجمعی در ۳۰۵ روز دوره قبلی.
 - اولین رکورد شیر دوره قبلی^۷: اولین رکورد شیر دوره قبلی.
 - سلول‌های سوماتیک ۳۰۵ روز^۸: تعداد سلول‌های سوماتیک^۹ در شکم قبلی.
- در پیش‌پردازش اولیه، رکوردهایی که مقدار روز رکورد گیری اولین رکورد شیر کمتر از ۴ داشتند حذف شدند، چرا که شیر اولیه دام (آغوز) در روزهای ابتدایی پس از زایمان از کیفیت متفاوتی برخوردار است و ثبت آن به عنوان مقدار شیر معیار در مدل‌سازی صحیح نیست. محدوده قابل قبول برای این متغیر از روز چهارم تا سی‌ام پس از زایمان در نظر گرفته شد.
- از متغیر گروه نیز به دو صورت در مدل‌ها استفاده شد: (۱) استفاده مستقیم از گروه به عنوان متغیر ترکیبی، (۲) استفاده جداگانه از متغیرهای سازنده آن یعنی ماه‌زایش، طول دوره آبستنی و دوره شیردهی. در بخش مدل‌سازی تفاوت عملکرد این دو رویکرد مورد بحث قرار خواهد گرفت.

۴-۳-۲ نمایش توزیع متغیرها

در این بخش، هیستوگرام توزیع هر یک از متغیرهای عددی مجموعه داده به صورت جداگانه نمایش داده شده است. این نمودارها به درک بهتر از چولگی^{۱۰}، نرمال یا غیرنرمال بودن توزیع^{۱۱} و نیز وجود داده‌های پرت

¹prelendays

²drylendays

³milkdays

⁴grp

⁵current_Milk305

⁶previous_Milk305

⁷firstmilk_previous


⁸SCS_305

⁹Somatic Cell Score


¹⁰Skewness

¹¹Normality


کمک می‌کنند.




شکل ۴-۵: هیستوگرام متغیر روز رکورد گیری اولین رکورد شیر




شکل ۴-۴: هیستوگرام متغیر اولین رکورد شیر




شکل ۴-۷: هیستوگرام متغیر طول دوره خشکی




شکل ۴-۶: هیستوگرام متغیر طول دوره آبستنی




شکل ۴-۹: هیستوگرام متغیر گروه




شکل ۴-۸: هیستوگرام متغیر طول دوره شیردهی




شکل ۴-۱۱: هیستوگرام متغیر شیرتجمعی ۳۰۵ روز گذشته



شکل ۴-۱۰: هیستوگرام متغیر شیرتجمعی ۳۰۵ روز



شکل ۴-۱۳: هیستوگرام متغیر سلول‌های سوماتیک ۳۰۵ روز



شکل ۴-۱۲: هیستوگرام متغیر اولین رکورد شیر دوره قبلی


تحلیل نمودارها:

- متغیر اولین رکورد شیر دارای توزیعی نسبتاً نرمال و متقارن است که ویژگی مناسبی برای متغیر هدف می‌باشد.
- روز رکورد گیری اولین رکورد شیر دارای توزیع یکنواخت در بازه ۵ تا ۴۰ روز است که نشان‌دهنده ثبت مناسب و متوازن رکوردها در این بازه است.
- طول دوره آبستنی دارای پیک بارزی در محدوده ۲۷۰ تا ۳۰۰ روز است که با طول معمول دوره آبستنی (۹ ماه) مطابقت دارد.
- توزیع طول دوره خشکی و روزهای شیردهی هر دو دارای چولگی زیاد هستند که انتخاب میانه برای جایگزینی مقادیر گم‌شده را توجیه می‌کند.
- متغیرهای شیرتجمعی ۳۰۵ روز، شیرتجمعی ۳۰۵ روز گذشته و اولین رکورد شیر دوره قبلی دارای توزیع نسبتاً نرمال هستند که برای مدل‌سازی مطلوب است.

- متغیر سلول‌های سوماتیک ۳۰۵ روز دارای توزیعی چپ‌چوله و تجمع بالا در مقادیر پایین‌تر است که نشان‌دهنده سلامت بالای گله‌ها از نظر سلول‌های سوماتیک است.

۳-۳-۴ تحلیل ماتریس همبستگی

شکل ۴-۱۴ ماتریس همبستگی بین متغیرهای عددی مجموعه داده را نشان می‌دهد. برای محاسبه این همبستگی‌ها از ضریب پیرسون استفاده شده است.



شکل ۴-۱۴: ماتریس همبستگی بین متغیرها

نکات قابل توجه:

- بالاترین همبستگی با متغیر هدف (اولین رکورد شیر) مربوط به شیر تجمعی ۳۰۵ روز با مقدار حدود ۰/۹ است. با این حال، از آنجایی که این متغیر از روی اولین رکورد شیر مشتق شده، استفاده از آن در مدل موجب نشت اطلاعات^۱ می‌شود، لذا حذف شد.
- متغیرهای اولین رکورد شیر دوره قبلی با متغیر هدف همبستگی مناسبی دارد (حدود ۰/۴).
- همبستگی‌های ضعیف بین متغیرهای دیگر نشان‌دهنده استقلال نسبی آن‌ها و عدم وجود هم‌خطی شدید

^۱Data Leakage

است.

۴-۳-۴ مدیریت داده‌های گمشده

در جدول زیر تعداد مقادیر گمشده در هر ستون از مجموعه داده آورده شده است:

جدول ۴-۴: تعداد داده‌های گمشده در ستون‌ها

نام ستون	تعداد داده گمشده
milkperiod	۰
zdate	۰
zdate_month	۰
firstmilk	۰
firstmilkdays	۰
prelendays	۰
drylendays	۲۰۵۹
milkdays	۲۰۵۹
previous_Milk ^{۳۰۵}	۰
firstmilk_previous	۰
SCS_۳۰۵	۰

برای پر کردن مقادیر گمشده در ستون‌های طول دوره خشکی و روزهای شیردهی، از مقدار میانه^۱ استفاده شد. انتخاب میانه به دلیل مقاومت آن در برابر داده‌های پرت و توزیع غیرنرمال این متغیرها انجام شد. مطابق هیستوگرام‌های این متغیرها (شکل ۴-۷ و ۴-۸) هر دو دارای توزیعی چولگی دار^۲ هستند که استفاده از میانگین را نامناسب می‌سازد. در برخی الگوریتم‌هایی که نسبت به داده‌های پرت حساس هستند، این مقادیر گمشده به جای جایگزینی حذف شدند.

۴-۳-۵ تقسیم‌بندی داده‌ها و نرمال‌سازی

پس از پاک‌سازی و تکمیل داده‌ها، مجموعه داده به سه بخش آموزش (۷۰٪)، اعتبارسنجی (۱۵٪) و آزمون (۱۵٪) تقسیم شد. برای نرمال‌سازی متغیرهای عددی از روش استانداردسازی^۳ (با استفاده از انحراف معیار و میانگین آموزش) و روش مقیاس‌بندی مقاوم^۴ (با استفاده از میانه و فاصله بین چهارک سوم و اول) استفاده شد. اگرچه جزئیات فنی‌تر این مرحله در بخش مدل‌سازی ارائه خواهد شد، اما در اینجا تأکید می‌شود که نرمال‌سازی تنها بر اساس داده‌های آموزش انجام شده تا از نشت اطلاعات جلوگیری شود.

¹Median

²Skewed Distribution

³Standardization

⁴Robust

۴-۴ مدل‌های آموزش داده‌شده

۴-۴-۱ مدل رگرسیون ريج

یکی از رویکردهای کلیدی در این پروژه، پیاده‌سازی مدل رگرسیون ريج با استفاده از الگوریتم گرادیان نزولی به صورت دستی بود. این مدل با افزودن جمله منظم‌سازی $L2$ به تابع هزینه، امکان کنترل پیچیدگی مدل و کاهش بیش‌برازش را فراهم می‌سازد. پیاده‌سازی این مدل به صورت سفارشی انجام شد تا علاوه بر انعطاف در تغییرات، امکان بررسی بهتر جزئیات یادگیری فراهم گردد.

آماده‌سازی داده‌ها

برای آموزش مدل، داده‌ها شامل مجموعه‌ای از ویژگی‌های عددی بودند که در جدول ۴-۵ آمده‌اند. متغیر هدف، مقدار اولین رکورد شیر^۱ است که بیانگر میزان شیر تولیدشده در نخستین روز از دوره شیردهی جدید دام است.

جدول ۴-۵: ویژگی‌های استفاده‌شده در مدل رگرسیون ريج

ویژگی‌های عددی مورد استفاده
prelendays, firstmilkdays, zdate_month, zdate, milkperiod, firstmilk_previous, previous_Milk ^۳ ۰۵, milkdays, drylendays, SCS ^۴ ۳۰۵

برای پر کردن داده‌های گمشده در ستون‌های طول دوره خشکی^۲ و روزهای شیردهی^۳، از میانه مقادیر آن‌ها استفاده شد (به دلایلی که در بخش قبلی توضیح داده شد). سپس، داده‌ها به سه بخش آموزش (۷۰٪)، اعتبارسنجی (۱۵٪) و آزمون (۱۵٪) تقسیم گردیدند. مجموعه آموزش و اعتبارسنجی برای فرآیند آموزش و تنظیم پارامتر استفاده شده و ارزیابی نهایی فقط بر روی مجموعه آزمون صورت گرفت.

مقیاس‌بندی ویژگی‌ها

با توجه به حساسیت الگوریتم گرادیان نزولی به مقیاس ویژگی‌ها، مقادیر عددی ویژگی‌ها به کمک روش استانداردسازی^۴ مقیاس‌بندی شدند. برای جلوگیری از نشت داده، مقیاس‌سازی فقط با استفاده از داده‌های آموزش انجام شده و سپس همان مقیاس روی داده‌های اعتبارسنجی و آزمون اعمال شد.

^۱firstmilk

^۲drylendays

^۳milkdays

^۴StandardScaler

آموزش مدل اولیه

در گام نخست، مدل با مقدار اولیه‌ای از پارامترها آموزش داده شد: نرخ یادگیری^۱ ۰/۰۱، تعداد تکرار^۲ ۱۰۰۰ و مقدار منظم‌سازی^۳ ۰/۱. آموزش مدل بر روی داده‌های آموزش انجام شد و عملکرد آن روی مجموعه آزمون ارزیابی گردید.

جدول ۴-۶: نتایج ارزیابی مدل اولیه رگرسیون ریبج بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۳۱۱۰	ضریب تعیین ^۴
۷/۰۲۷۶	میانگین قدرمطلق خطا ^۵
۹/۲۰۷۱	ریشه میانگین مربع خطا ^۶
- ۸/۰۸۵۶	درصد خطای میانگین ^۷
۱۷/۶۸۴۰	میانگین قدرمطلق درصد خطای مقایسه ^۸
۰/۵۱۶۹	انحراف استاندارد نسبی ^۹

تنظیم پارامترها با استفاده از اعتبارسنجی

جهت بهینه‌سازی عملکرد مدل، فرایند جست‌وجوی حریصانه^{۱۰} برای تعیین بهترین مقادیر نرخ یادگیری، تعداد تکرار و ضریب منظم‌سازی اجرا شد. مجموعه‌ای از ترکیب‌های زیر برای این منظور مورد بررسی قرار گرفت:

• نرخ یادگیری: ۰/۰۰۱، ۰/۰۱، ۰/۱

• تعداد تکرار: ۵۰۰، ۱۰۰۰، ۲۰۰۰

• ضریب منظم‌سازی: ۰/۰۰۱، ۰/۰۱، ۰/۱

هر ترکیب روی مجموعه آموزش آموزش داده شد و عملکرد آن روی مجموعه اعتبارسنجی بر اساس میانگین مربعات خطا^{۱۱} سنجیده شد. بهترین ترکیب به صورت زیر شناسایی شد:

• نرخ یادگیری: ۰/۱

• تعداد تکرار: ۲۰۰۰

¹Learning rate

²Epoch

³L2_lambda

¹⁰Grid Search

¹¹MSE

• ضریب منظم‌سازی: ۰/۰۰۱

آموزش مدل نهایی و ارزیابی

مدل نهایی با استفاده از مقادیر بهینه به دست آمده آموزش داده شد. سپس پیش‌بینی مدل روی داده‌های آزمون انجام شد و نتایج نهایی به صورت جدول زیر خلاصه شده‌اند:

جدول ۴-۷: نتایج ارزیابی مدل نهایی رگرسیون رنج بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۳۱۳۴	ضریب تعیین
۷/۰۰۵۷	میانگین قدرمطلق خطا
۹/۱۹۰۹	ریشه میانگین مربع خطا
- ۷/۸۷۷۹	درصد خطای میانگین
۱۷/۶۶۴۲	میانگین قدرمطلق درصد خطای متقارن
۰/۵۵۷۱	انحراف استاندارد نسبی

۴-۴-۲ مدل جنگل تصادفی

جنگل تصادفی یکی از الگوریتم‌های قدرتمند در یادگیری ماشین است که با استفاده از مجموعه‌ای از درختان تصمیم‌گیری، پایداری و دقت پیش‌بینی را افزایش می‌دهد. در این پروژه، مدل‌های مختلفی از جنگل تصادفی مورد استفاده قرار گرفتند که شامل مدل اولیه، مدل بهینه‌شده، مدل با اعتبارسنجی متقاطع، و نسخه‌های مبتنی بر ویژگی گروه^۱ بودند.

ویژگی‌های مورد استفاده

ویژگی‌هایی که برای توسعه مدل جنگل تصادفی استفاده شده‌اند، به دو دسته کلی تقسیم می‌شوند: مدل‌های بدون استفاده از متغیر گروه و مدل‌هایی که این متغیر را در نظر گرفته‌اند.

مدل‌های بدون ویژگی گروه: در این نسخه از مدل، متغیرهای زمانی و رکوردهای تاریخی مرتبط با گاو مورد استفاده قرار گرفته‌اند. جدول ۴-۸ لیست کامل ویژگی‌های استفاده‌شده در این نسخه را نشان می‌دهد.

^۱ grp

جدول ۴-۸: ویژگی‌های استفاده‌شده در مدل جنگل تصادفی بدون متغیر گروه

ویژگی‌های عددی مورد استفاده
،milkdays ،drylendays ،prelendays ،firstmilkdays ،zdate_month ،zdate ،milkperiod SCS_305 ،firstmilk_previous ،previous_Milk305

مدل‌های با ویژگی گروه: در این نسخه از مدل، ویژگی‌های زمانی حذف شده‌اند و متغیر گروه‌بندی جایگزین آن‌ها شده است. جدول ۴-۹ فهرست ویژگی‌های نهایی در این نسخه را نمایش می‌دهد.

جدول ۴-۹: ویژگی‌های استفاده‌شده در مدل جنگل تصادفی با متغیر گروه

ویژگی‌های عددی مورد استفاده
،firstmilk_previous ،previous_Milk305 ،grp ،milkdays ،drylendays ،prelendays ،firstmilkdays SCS_305

آماده‌سازی داده‌ها

برای آموزش مدل اولیه، از مجموعه‌ای از ویژگی‌های عددی استفاده شد که در مدل رگرسیون ریح نیز به کار رفته بودند. داده‌های گمشده در ستون‌های طول دوره خشکی و روزهای شیردهی با مقدار میانه پر شدند و سپس داده‌ها به نسبت ۷۰٪ آموزش، ۱۵٪ اعتبارسنجی و ۱۵٪ آزمون تقسیم شدند.

مقیاس‌بندی ویژگی‌ها

مقیاس‌بندی ویژگی‌ها با استفاده از روش استانداردسازی تنها روی داده‌های آموزش انجام گرفت و سپس همان مقیاس روی داده‌های اعتبارسنجی و آزمون اعمال شد.

آموزش مدل اولیه

مدل اولیه جنگل تصادفی با پارامترهای پیش‌فرض روی داده‌های آموزش، آموزش داده شد و نتایج آن روی مجموعه آزمون ارزیابی شد.

جدول ۴-۱۰: نتایج ارزیابی مدل اولیه جنگل تصادفی

مقدار	معیار ارزیابی
۰/۳۴۸	ضریب تعیین
۶/۸۲۹	میانگین قدرمطلق خطا
۸/۹۵۸	ریشه میانگین مربع خطا
- ۶/۹۳۶	درصد خطای میانگین
۱۷/۲۲۳	میانگین قدرمطلق درصد خطای مقارن
۰/۶۱۱	انحراف استاندارد نسبی

تنظیم پارامترها با استفاده از جست‌وجوی حریصانه

برای بهینه‌سازی مدل، از روش جست‌وجوی حریصانه با اعتبارسنجی پنج‌تایی استفاده شد. بهترین ترکیب پارامترها به شرح زیر شناسایی شد:

- تعداد درخت‌ها^۱: ۱۰۰
- عمق بیشینه درخت‌ها^۲: ۲۰
- حداقل نمونه برای تقسیم^۳: ۱۰
- حداقل نمونه در برگ^۴: ۴

آموزش مدل نهایی و ارزیابی

مدل نهایی با استفاده از مقادیر بهینه آموزش داده شد و نتایج آن بر روی مجموعه آزمون به شرح زیر است:

جدول ۴-۱۱: نتایج ارزیابی مدل نهایی جنگل تصادفی

مقدار	معیار ارزیابی
۰/۳۵۸	ضریب تعیین
۶/۷۵۹	میانگین قدرمطلق خطا
۸/۸۹۱	ریشه میانگین مربع خطا
- ۷/۳۱۶	درصد خطای میانگین
۱۷/۰۵۵	میانگین قدرمطلق درصد خطای متقارن
۰/۶۰۳	انحراف استاندارد نسبی

اعتبارسنجی متقاطع (با پارامترهای نهایی)

برای بررسی پایداری مدل و جلوگیری از بیش‌برازش، اعتبارسنجی متقاطع پنج‌تایی اجرا شد. نتایج ارزیابی مدل نهایی با اعتبارسنجی متقاطع در جدول زیر آمده است:

^۱n_estimators

^۲max_depth

^۳min_samples_split

^۴min_samples_leaf

جدول ۴-۱۲: ارزیابی نهایی مدل جنگل تصادفی با اعتبارسنجی متقاطع

مقدار	معیار ارزیابی
۰/۳۵۳	ضریب تعیین
۶/۷۸۵	میانگین قدرمطلق خطا
۸/۹۲۵	ریشه میانگین مربع خطا
- ۷/۶۱۱	درصد خطای میانگین
۱۷/۰۹۳	میانگین قدرمطلق درصد خطای متقارن
۰/۵۷۴	انحراف استاندارد نسبی

به منظور افزایش دقت ارزیابی مدل و جلوگیری از بیش‌برازش، از روش اعتبارسنجی متقاطع پنج‌تایی برای آموزش مدل جنگل تصادفی استفاده شد. در این روش، داده‌های آموزش به پنج بخش تقسیم شده و مدل در هر تکرار روی چهار بخش آموزش دیده و روی بخش پنجم اعتبارسنجی شده است. در نهایت، مدل نهایی روی کل داده‌های آموزش آموزش داده شده و بر روی مجموعه تست، که در فرآیند آموزش شرکت نداشت، ارزیابی شده است.

در جدول ۴-۱۲ نتایج ارزیابی مدل جنگل تصادفی با استفاده از اعتبارسنجی متقاطع ارائه شده است. مقایسه این نتایج با نتایج مدل نهایی بدون اعتبارسنجی (جدول ۴-۱۱) نشان می‌دهد که عملکرد مدل در هر دو حالت بسیار نزدیک است. به عنوان نمونه، مقدار ضریب تعیین در مدل بدون اعتبارسنجی برابر با ۰/۳۵۸ و در مدل اعتبارسنجی شده برابر با ۰/۳۵۳ است که تفاوت بسیار ناچیزی دارد. همچنین مقادیر معیارهای خطا مانند میانگین قدرمطلق خطا و ریشه میانگین مربع خطا نیز به طور مشابه نزدیک‌اند (۶/۷۵۹ در مقابل ۶/۷۸۵ برای میانگین قدرمطلق خطا، و ۸/۸۹۱ در مقابل ۸/۹۲۵ برای ریشه میانگین مربع خطا).

این نزدیکی نتایج نشان‌دهنده آن است که مدل دچار بیش‌برازش نشده و عملکرد آن بر روی داده‌های دیده‌نشده پایدار باقی مانده است. همچنین می‌توان نتیجه گرفت که داده‌های آموزش از تنوع و پوشش مناسبی برخوردار بوده‌اند و مدل توانسته الگوهای موجود را به خوبی یاد بگیرد.

بنابراین استفاده از اعتبارسنجی متقاطع ضمن فراهم کردن ارزیابی دقیق‌تر، اطمینان بیشتری نسبت به تعمیم‌پذیری مدل نهایی فراهم کرده است. این روند در مطالعات مشابه نیز به عنوان یک رویه استاندارد در ارزیابی مدل‌های یادگیری ماشین توصیه می‌شود.

مدل‌های مبتنی بر ویژگی گروه

برای بررسی تأثیر ویژگی گروه، مدل‌های جدیدی با جایگزینی ویژگی‌های زمانی با گروخ طراحی و ارزیابی شدند.

مدل اولیه با گروه: نتایج ارزیابی مدل اولیه با استفاده از ویژگی گروه به شرح زیر است:

جدول ۴-۱۳: نتایج مدل اولیه جنگل تصادفی با گروه

مقدار	معیار ارزیابی
۰/۳۴۰	ضریب تعیین
۶/۸۷۹	میانگین قدرمطلق خطا
۹/۰۱۱	ریشه میانگین مربع خطا
- ۶/۹۶۴	درصد خطای میانگین
۱۷/۳۴۲	میانگین قدرمطلق درصد خطای مقارن
۰/۶۱۴	انحراف استاندارد نسبی

مدل بهینه شده با گروه: نتایج حاصل از آموزش مدل بهینه شده با استفاده از پارامترهای بهینه یافته در جدول زیر

آمده است:

جدول ۴-۱۴: نتایج مدل نهایی جنگل تصادفی با گروه

مقدار	معیار ارزیابی
۰/۳۵۱	ضریب تعیین
۶/۷۹۳	میانگین قدرمطلق خطا
۸/۹۳۳	ریشه میانگین مربع خطا
- ۷/۶۰۹	درصد خطای میانگین
۱۷/۱۱۲	میانگین قدرمطلق درصد خطای مقارن
۰/۵۷۵	انحراف استاندارد نسبی

اعتبارسنجی مقاطع مدل با گروه: در نهایت، ارزیابی با اعتبارسنجی مقاطع نیز روی این مدل انجام شد و نتایج

آن در جدول زیر ارائه می گردد:

جدول ۴-۱۵: مدل نهایی جنگل تصادفی با گروه و اعتبارسنجی مقاطع

مقدار	معیار ارزیابی
۰/۳۵۱	ضریب تعیین
۶/۷۹۳	میانگین قدرمطلق خطا
۸/۹۳۳	ریشه میانگین مربع خطا
- ۷/۶۰۹	درصد خطای میانگین
۱۷/۱۱۲	میانگین قدرمطلق درصد خطای مقارن
۰/۵۷۵	انحراف استاندارد نسبی

در این بخش، عملکرد مدل جنگل تصادفی با افزودن ویژگی «گروه» (که دسته‌بندی‌های سنی یا شکم‌گاو را بازتاب می‌دهد) بررسی شد. هدف از اضافه کردن این متغیر، تقویت توان مدل در درک تفاوت‌های ساختاری میان زیرگروه‌های مختلف گاوها و ارتقای دقت پیش‌بینی بود.

نتایج حاصل از آموزش این مدل در جدول ۴-۱۴ آمده است. همان‌طور که مشاهده می‌شود، شاخص‌های ارزیابی تقریباً مشابه با مدل پایه بدون ویژگی گروه هستند. مقدار ضریب تعیین برابر با ۰/۳۵۱ است که تفاوت ناچیزی با مدل پایه دارد. همچنین معیارهای خطا نیز بسیار نزدیک به نتایج پیشین هستند.

جالب آن‌که ارزیابی مدل جنگل تصادفی با گروه، در دو حالت با و بدون اعتبارسنجی متقاطع، نتایج یکسانی داشته است (مطابق جدول ۴-۱۵). این تکرار دقیق نشان می‌دهد که افزودن ویژگی گروه نه تنها عملکرد مدل را تثبیت کرده، بلکه منجر به همگرایی نتایج در فرآیندهای اعتبارسنجی نیز شده است.

این پایداری در نتایج، حاکی از آن است که افزودن متغیر گروه تأثیر معناداری بر بهبود یا افت عملکرد مدل نداشته، اما ممکن است به درک بهتر الگوهای درون‌گروهی کمک کرده باشد. از سوی دیگر، شباهت شاخص‌های ارزیابی بین نسخه اعتبارسنجی‌شده و بدون اعتبارسنجی، بیانگر آن است که مدل از پایداری خوبی برخوردار بوده و دچار بیش‌برازش نشده است.

در مجموع می‌توان گفت که افزودن ویژگی گروه موجب پیچیدگی یا بهبود محسوسی در مدل نشده است، اما بدون ایجاد اثر منفی، می‌تواند به افزایش قابلیت تفسیرپذیری نتایج در سطوح مدیریتی کمک کند.

۴-۳-۴ مدل رگرسیون بردار پشتیبان

یکی از رویکردهای اصلی در این پروژه، توسعه مدل رگرسیون بردار پشتیبان با استفاده از هسته‌های مختلف بود. این مدل با بهره‌گیری از الگوریتم بهینه‌سازی مبتنی بر بردارهای پشتیبان، امکان پیش‌بینی مقدار شیر تولیدی را با در نظر گرفتن روابط خطی و غیرخطی بین ویژگی‌ها فراهم می‌کند.

آماده‌سازی داده‌ها

ابتدا، داده‌ها از فایل اکسل بارگذاری شدند. ویژگی‌های عددی مورد استفاده برای آموزش مدل در جدول ۴-۱۶ فهرست شده‌اند. متغیر هدف این مدل، مقدار اولین رکورد شیر (*firstmilk*) است که نشان‌دهنده تولید شیر در نخستین روز دوره شیردهی جدید دام می‌باشد.

جدول ۴-۱۶: ویژگی‌های استفاده‌شده در مدل رگرسیون بردار پشتیبان

ویژگی‌های عددی مورد استفاده
prelendays, firstmilkdays, zdate_month, zdate, milkperiod, firstmilk_previous, previous_Milk305, milkdays, drylendays SCS_305

برای مدیریت داده‌های گمشده، ابتدا ستون‌های *drylendays* و *milkdays* که حاوی مقادیر خالی بودند، شناسایی شدند. سپس، این مقادیر با استفاده از میانه همان ستون‌ها پر شدند تا از تأثیر داده‌های پرت در توزیع داده‌ها جلوگیری شود. پس از این مرحله، داده‌ها به سه مجموعه تقسیم شدند: مجموعه آموزش (۷۰٪)، مجموعه اعتبارسنجی (۱۵٪) و مجموعه آزمون (۱۵٪).

مقیاس‌بندی ویژگی‌ها

مقیاس‌بندی ویژگی‌ها با استفاده از روش استانداردسازی تنها روی داده‌های آموزش انجام گرفت و سپس همان مقیاس روی داده‌های اعتبارسنجی و آزمون اعمال شد.

آموزش مدل‌های با هسته‌های خطی، چندجمله‌ای و شعاعی

در مرحله اول، مدل رگرسیون بردار پشتیبان با هسته خطی پیاده‌سازی شد. پارامترهای اولیه شامل نرخ منظم‌سازی (C) با مقدار پیش‌فرض ۰/۱، نرخ تکرار ($epsilon$) با مقدار پیش‌فرض ۰/۱، و حداکثر تعداد تکرار (max_iter) با مقدار پیش‌فرض ۱۰۰۰ بودند. مدل روی مجموعه آموزش، آموزش داده شد. سپس، پیش‌بینی روی مجموعه آزمون انجام شد و معیارهای ارزیابی محاسبه شدند.

جدول ۴-۱۷: نتایج ارزیابی مدل اولیه رگرسیون بردار پشتیبان (هسته خطی) بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۳۰۷	ضریب تعیین
۶/۹۷۱	میانگین قدرمطلق خطا
۹/۲۳۳	ریشه میانگین مربع خطا
- ۹/۷۳۱	درصد خطای میانگین
۱۷/۵۸۴	میانگین قدرمطلق درصد خطای مقارن
۰/۵۸۵	انحراف استاندارد نسبی

سپس، مدل با هسته چندجمله‌ای و هسته شعاعی با همان پارامترهای پیش‌فرض آموزش داده شد. پیش‌بینی و محاسبه معیارها به‌صورت مشابه انجام شد.

جدول ۴-۱۸: نتایج ارزیابی مدل اولیه رگرسیون بردار پشتیبان (هسته چندجمله‌ای) بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۲۶۵	ضریب تعیین
۷/۲۱۶	میانگین قدرمطلق خطا
۹/۵۱۱	ریشه میانگین مربع خطا
- ۹/۸۲۱	درصد خطای میانگین
۱۸/۱۷۶	میانگین قدرمطلق درصد خطای مقارن
۰/۵۵۵	انحراف استاندارد نسبی

جدول ۴-۱۹: نتایج ارزیابی مدل اولیه رگرسیون بردار پشتیبان (هسته شعاعی) بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۳۶۴	ضریب تعیین
۶/۶۳۸	میانگین قدرمطلق خطا
۸/۸۴۴	ریشه میانگین مربع خطا
- ۹/۲۳۸	درصد خطای میانگین
۱۶/۷۵۹	میانگین قدرمطلق درصد خطای مقارن
۰/۶۱۶	انحراف استاندارد نسبی

توسعه مدل با هسته شعاعی و مقیاس‌دهی مقاوم^۱

برای بررسی تأثیر روش‌های مختلف مقیاس‌بندی و مدیریت داده‌های گمشده، مدل رگرسیون بردار پشتیبان با هسته شعاعی و استفاده از مقیاس‌بندی مقاوم توسعه یافت. در این بخش، فرآیند آماده‌سازی، مقیاس‌بندی، و ارزیابی این مدل به صورت گام‌به‌گام توضیح داده می‌شود.

آماده‌سازی داده‌ها: داده‌ها از فایل اکسل بارگذاری شدند. برخلاف مدل‌های قبلی که داده‌های گمشده با میانه پر می‌شدند، در این مدل، داده‌های حاوی مقادیر گمشده حذف شدند تا مجموعه‌ای بدون داده‌های ناقص ایجاد شود. سپس، ویژگی‌ها و متغیر هدف جدا شدند. داده‌ها به سه مجموعه تقسیم شدند: مجموعه آموزش (۷۰٪)، مجموعه اعتبارسنجی (۱۵٪)، و مجموعه آزمون (۱۵٪).

مقیاس‌بندی ویژگی‌ها: به دلیل حساسیت رگرسیون بردار پشتیبان به مقیاس ویژگی‌ها، از روش مقیاس‌دهی مقاوم استفاده شد که نسبت به داده‌های پرت مقاوم‌تر است.

^۱ RobustScaler

آموزش و ارزیابی مدل: مدل رگرسیون بردار پشتیبان با هسته شعاعی و پارامترهای پیش فرض روی مجموعه آموزش مقیاس شده آموزش داده شد. پیش بینی روی مجموعه آزمون انجام شد و معیارهای ارزیابی با توابع سفارشی و آماده محاسبه شدند.

جدول ۴-۲۰: نتایج ارزیابی مدل رگرسیون بردار پشتیبان (با هسته شعاعی و مقیاس بندی مقاوم) بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۳۶۰	ضریب تعیین
۶/۶۴۴	میانگین قدرمطلق خطا
۸/۸۶۱	ریشه میانگین مربع خطا
- ۹/۲۴۰	درصد خطای میانگین
۱۶/۷۷۶	میانگین قدرمطلق درصد خطای متقارن
۰/۶۱۷	انحراف استاندارد نسبی

۴-۴-۴ مدل افزایش گرادیان افراطی

یکی از رویکردهای کلیدی در این پژوهش، استفاده از مدل افزایش گرادیان افراطی برای پیش بینی مقدار شیر تولیدی بود. این مدل با ترکیب چندین درخت تصمیم به صورت ترتیبی، امکان یادگیری دقیق تر روابط پیچیده بین ویژگی ها را فراهم می کند.

آماده سازی داده ها

داده ها از فایل اکسل بارگذاری شدند. ویژگی های عددی مورد استفاده برای آموزش مدل در جدول ۴-۲۱ فهرست شده اند. متغیر هدف این مدل، مقدار اولین رکورد شیر (*firstmilk*) است که نشان دهنده تولید شیر در نخستین روز دوره شیردهی جدید دام می باشد.

جدول ۴-۲۱: ویژگی های استفاده شده در مدل افزایش گرادیان افراطی

ویژگی های عددی مورد استفاده
,prelendays, firstmilkdays, zdate_month, zdate, milkperiod, firstmilk_previous, previous_Milk305, milkdays, drylendays, SCS_305

برای مدیریت داده های گمشده، ستون های *milkdays* و *drylendays* که حاوی مقادیر خالی بودند، با استفاده از میانه همان ستون ها پر شدند. سپس، داده ها به سه مجموعه تقسیم شدند: مجموعه آموزش (۷۰٪)، مجموعه اعتبارسنجی (۱۵٪) و مجموعه آزمون (۱۵٪).

مقیاس‌بندی ویژگی‌ها

مقیاس‌بندی ویژگی‌ها با استفاده از روش استانداردسازی تنها روی داده‌های آموزش انجام گرفت و سپس همان مقیاس روی داده‌های اعتبارسنجی و آزمون اعمال شد.

آموزش مدل اولیه

در مرحله اول، مدل افزایش گرادیان افراطی با پارامترهای پیش‌فرض روی مجموعه آموزش آموزش داده شد. سپس، پیش‌بینی روی مجموعه آزمون انجام شد و معیارهای ارزیابی محاسبه شدند.

جدول ۴-۲۲: نتایج ارزیابی مدل اولیه افزایش گرادیان افراطی بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۳۶۷	ضریب تعیین
۶/۶۹۱	میانگین قدرمطلق خطا
۸/۸۲۷	ریشه میانگین مربع خطا
- ۷/۲۹۰	درصد خطای میانگین
۱۶/۹۰۶	میانگین قدرمطلق درصد خطای مقارن
۰/۶۱۸	انحراف استاندارد نسبی

تحلیل بیش‌برازش نشان داد که اختلاف ضریب تعیین بین مجموعه‌های آموزش و اعتبارسنجی (۰/۰۶۰۲) از آستانه ۰/۰۵ بیشتر است، که می‌تواند نشانه‌ای از بیش‌برازش باشد.

آموزش مدل بهینه‌شده

برای بهبود عملکرد مدل، پارامترهای مدل با استفاده از جست‌وجوی حریصانه تنظیم شدند. پارامترهای بهینه‌شده شامل تعداد برآوردگرها ($n_estimators = 200$)، عمق حداکثر ($max_depth = 5$)، نرخ یادگیری ($learning_rate = 0/1$)، وزن حداقل فرزند ($min_child_weight = 5$)، نمونه‌برداری ($subsample = 0/8$)، و نمونه‌برداری از ستون‌ها ($colsample_bytree = 0/7$) بودند. مدل با این پارامترها روی مجموعه آموزش آموزش داده شد و پیش‌بینی روی مجموعه آزمون انجام شد.

جدول ۴-۲۳: نتایج ارزیابی مدل بهینه‌شده افزایش گرا دیان افراطی بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۳۷۳	ضریب تعیین
۶/۶۶۰	میانگین قدرمطلق خطا
۸/۷۸۳	ریشه میانگین مربع خطا
- ۷/۳۱۹	درصد خطای میانگین
۱۶/۸۲۲	میانگین قدرمطلق درصد خطای متقارن
۰/۶۰۷	انحراف استاندارد نسبی

تحلیل بیش‌برازش نشان داد که اختلاف ضریب تعیین بین مجموعه‌های آموزش و اعتبارسنجی (۰/۰۲۵۸) کمتر از آستانه ۰/۰۵ است، که نشان‌دهنده عدم وجود بیش‌برازش قابل توجه است. تیون کردن مدل با پارامترهای بهینه‌شده باعث شد تا مدل از وضعیت بیش‌برازش خارج شده و پایداری بیشتری پیدا کند. این بهبود با کاهش اختلاف ضریب تعیین از ۰/۰۶۰۲ در مدل اولیه به ۰/۰۲۵۸ (texttt) در مدل بهینه‌شده تأیید می‌شود، که نشان‌دهنده تعادل بهتر بین دقت و تعمیم‌پذیری است.

۴-۵ مدل تقویت دسته‌ای

یکی از رویکردهای کلیدی در این پژوهش، استفاده از مدل تقویت دسته‌ای برای پیش‌بینی مقدار شیر تولیدی بود. این مدل با بهره‌گیری از الگوریتم‌های مبتنی بر درخت تصمیم و بهینه‌سازی برای مدیریت داده‌های دسته‌ای، دقت بالایی در پیش‌بینی ارائه می‌دهد.

آماده‌سازی داده‌ها

داده‌ها از فایل اکسل بارگذاری شدند. ویژگی‌های عددی و دسته‌ای مورد استفاده برای آموزش مدل در جدول ۴-۲۴ فهرست شده‌اند. متغیر هدف این مدل، مقدار اولین رکورد شیر (*firstmilk*) است که نشان‌دهنده تولید شیر در نخستین روز دوره شیردهی جدید دام می‌باشد.

جدول ۴-۲۴: ویژگی‌های استفاده‌شده در مدل تقویت دسته‌ای

ویژگی‌های عددی و دسته‌ای مورد استفاده
prelendays, firstmilkdays, zdate_month, zdate, milkperiod, Hrd, firstmilk_previous, previous_Milk305, grp, milkdays, drylendays, SCS_305

برای مدیریت داده‌های گمشده، ردیف‌هایی که مقادیر خالی در ستون‌های *milkdays* و *drylendays* داشتند

حذف شدند. همچنین، داده‌های نامعتبر (مثبت نبودن مقادیر) فیلتر شدند. پس از آن، یک ویژگی جدید *is_abortion* با استفاده از شرط $prelendsays < 260$ ایجاد شد تا نشان‌دهنده وقوع سقط در دام باشد. این ویژگی به این منظور اضافه شد که طول دوره آبستنی کمتر از ۲۶۰ روز را به عنوان نشانه‌ای از سقط جنین در نظر بگیرد، که در این صورت مقدار آن به صورت باینری (۱ برای سقط و ۰ برای عدم سقط) تنظیم می‌شود. ستون دسته‌ای *grp* به صورت باینری رمزگذاری شد. داده‌ها به سه مجموعه تقسیم شدند: مجموعه آموزش (۷۰٪)، مجموعه اعتبارسنجی (۱۵٪) و مجموعه آزمون (۱۵٪).

مقیاس‌بندی ویژگی‌ها

مقیاس‌بندی ویژگی‌ها با استفاده از روش مقیاس‌دهی مقاوم تنها روی داده‌های آموزش انجام گرفت و سپس همان مقیاس روی داده‌های اعتبارسنجی و آزمون اعمال شد.

آموزش مدل اولیه

در مرحله اول، مدل تقویت دسته‌ای با پارامترهای پیش‌فرض روی مجموعه آموزش آموزش داده شد. سپس، پیش‌بینی روی مجموعه آزمون انجام شد و معیارهای ارزیابی محاسبه شدند.

جدول ۴-۲۵: نتایج ارزیابی مدل اولیه تقویت دسته‌ای بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۴۰۲	ضریب تعیین
۶/۴۳۹	میانگین قدرمطلق خطا
۸/۵۰۴	ریشه میانگین مربع خطا
- ۶/۶۶۷	درصد خطای میانگین
۱۶/۲۱۶	میانگین قدرمطلق درصد خطای متقارن
۰/۶۲۹	انحراف استاندارد نسبی

تحلیل بیش‌برازش نشان داد که اختلاف ضریب تعیین بین مجموعه‌های آموزش و اعتبارسنجی (۰/۰۳۰۹) کمتر از آستانه ۰/۰۵ است، که نشان‌دهنده عدم وجود بیش‌برازش قابل توجه است.

آموزش مدل بهینه‌شده

برای بهبود عملکرد مدل، پارامترهای مدل با استفاده از جست‌وجوی حریصانه تنظیم شدند. پارامترهای بهینه‌شده شامل تعداد تکرارها (*iterations*)، نرخ یادگیری (*learning_rate*)، عمق (*depth*)، و تنظیم‌کننده L_2 (*l2_leaf_reg*) بودند. مدل با این پارامترها روی مجموعه آموزش آموزش داده شد و پیش‌بینی روی مجموعه

آزمون انجام شد.

جدول ۴-۲۶: نتایج ارزیابی مدل بهینه‌شده تقویت دسته‌ای بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۳۸۶	ضریب تعیین
۶/۵۳۹	میانگین قدرمطلق خطا
۸/۶۱۵	ریشه میانگین مربع خطا
- ۶/۸۵۷	درصد خطای میانگین
۱۶/۴۵۰	میانگین قدرمطلق درصد خطای مقارن
۰/۶۰۸	انحراف استاندارد نسبی

مدل با پر کردن داده‌های ناقص و مقیاس‌دهی استاندارد

برای مقایسه، مدلی با پر کردن داده‌های ناقص با میانه و استفاده از مقیاس‌دهی استاندارد توسعه یافت. در این مدل، داده‌های گمشده در ستون‌های *drylendays* و *milkdays* با میانه پر شدند. سپس، داده‌ها به سه مجموعه تقسیم شدند و مقیاس‌بندی با روش استاندارد روی داده‌های آموزش انجام شد و به داده‌های دیگر اعمال شد. مدل با پارامترهای مشخص روی مجموعه آموزش آموزش داده شد و پیش‌بینی روی مجموعه آزمون انجام شد.

جدول ۴-۲۷: نتایج ارزیابی مدل تقویت دسته‌ای (با پر کردن داده‌های ناقص و مقیاس‌دهی استاندارد) بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۳۷۳	ضریب تعیین
۶/۶۵۹	میانگین قدرمطلق خطا
۸/۷۸۵	ریشه میانگین مربع خطا
- ۷/۳۴۴	درصد خطای میانگین
۱۶/۸۱۶	میانگین قدرمطلق درصد خطای مقارن
۰/۶۰۴	انحراف استاندارد نسبی

۴-۴-۶ مدل شبکه عصبی چندلایه

یکی از رویکردهای پیشرفته در این پژوهش، استفاده از مدل شبکه عصبی چندلایه برای پیش‌بینی مقدار شیر تولیدی بود. این مدل با بهره‌گیری از لایه‌های مخفی و تابع فعال‌سازی، قادر به یادگیری الگوهای پیچیده در داده‌ها است.

آماده‌سازی داده‌ها

داده‌ها از فایل اکسل بارگذاری شدند. ویژگی‌های عددی مورد استفاده برای آموزش مدل در جدول ۴-۲۸ فهرست شده‌اند. متغیر هدف این مدل، مقدار اولین رکورد شیر (*firstmilk*) است که نشان‌دهنده تولید شیر در نخستین روز دوره شیردهی جدید دام می‌باشد.

جدول ۴-۲۸: ویژگی‌های استفاده‌شده در مدل شبکه عصبی چندلایه

ویژگی‌های عددی مورد استفاده
prelendays, firstmilkdays, zdate_month, zdate, milkperiod, Hrd, firstmilk_previous, previous_Milk305, milkdays, drylendays, SCS_305

برای مدیریت داده‌های گمشده، ستون‌های *drylendays* و *milkdays* که حاوی مقادیر خالی بودند، با استفاده از میانه همان ستون‌ها پر شدند. سپس، داده‌ها به سه مجموعه تقسیم شدند: مجموعه آموزش (۷۰٪)، مجموعه اعتبارسنجی (۱۵٪) و مجموعه آزمون (۱۵٪).

مقیاس‌بندی ویژگی‌ها

مقیاس‌بندی ویژگی‌ها با استفاده از روش استانداردسازی تنها روی داده‌های آموزش انجام گرفت و سپس همان مقیاس روی داده‌های اعتبارسنجی و آزمون اعمال شد.

آموزش مدل اولیه

در مرحله اول، مدل شبکه عصبی چندلایه با یک معماری ساده و پارامترهای پیش‌فرض روی مجموعه آموزش آموزش داده شد. سپس، پیش‌بینی روی مجموعه آزمون انجام شد و معیارهای ارزیابی محاسبه شدند.

جدول ۴-۲۹: نتایج ارزیابی مدل اولیه شبکه عصبی چندلایه بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۳۷۰	ضریب تعیین
۶/۶۵۴	میانگین قدرمطلق خطا
۸/۸۰۳	ریشه میانگین مربع خطا
- ۷/۶۴۶	درصد خطای میانگین
۱۶/۸۰۸	میانگین قدرمطلق درصد خطای متقارن
۰/۶۲۱	انحراف استاندارد نسبی

۷-۴-۴ مدل شبکه عصبی عمیق

یکی از رویکردهای پیشرفته در این پژوهش، استفاده از مدل شبکه عصبی عمیق برای پیش‌بینی مقدار شیر تولیدی بود. این مدل با بهره‌گیری از چندین لایه مخفی و تابع فعال‌سازی، توانایی یادگیری الگوهای پیچیده و غیرخطی در داده‌ها را داراست.

آماده‌سازی داده‌ها

داده‌ها از فایل اکسل بارگذاری شدند. ویژگی‌های عددی مورد استفاده برای آموزش مدل در جدول ۴-۳۰ فهرست شده‌اند. متغیر هدف این مدل، مقدار اولین رکورد شیر (*firstmilk*) است که نشان‌دهنده تولید شیر در نخستین روز دوره شیردهی جدید دام می‌باشد.

جدول ۴-۳۰: ویژگی‌های استفاده‌شده در مدل شبکه عصبی عمیق

ویژگی‌های عددی مورد استفاده
,prelendays ,firstmilkdays ,zdate_month ,zdate ,milkperiod ,Hrd ,firstmilk_previous ,previous_Milk305 ,milkdays ,drylendays SCS_305

برای مدیریت داده‌های گمشده، ستون‌های *milkdays* و *drylendays* که حاوی مقادیر خالی بودند، با استفاده از میانه همان ستون‌ها پر شدند. سپس، داده‌ها به سه مجموعه تقسیم شدند: مجموعه آموزش (۷۰٪)، مجموعه اعتبارسنجی (۱۵٪) و مجموعه آزمون (۱۵٪).

مقیاس‌بندی ویژگی‌ها

مقیاس‌بندی ویژگی‌ها با استفاده از روش استانداردسازی تنها روی داده‌های آموزش انجام گرفت و سپس همان مقیاس روی داده‌های اعتبارسنجی و آزمون اعمال شد.

آموزش مدل اولیه

در مرحله اول، مدل شبکه عصبی عمیق با یک معماری چندلایه‌ای و پارامترهای پیش‌فرض روی مجموعه آموزش، آموزش داده شد. سپس، پیش‌بینی روی مجموعه آزمون انجام شد و معیارهای ارزیابی محاسبه شدند.

جدول ۴-۳۱: نتایج ارزیابی مدل اولیه شبکه عصبی عمیق بر روی مجموعه آزمون

مقدار	معیار ارزیابی
۰/۳۶۹	ضریب تعیین
۶/۶۹۳	میانگین قدرمطلق خطا
۸/۸۱۳	ریشه میانگین مربع خطا
- ۶/۸۸۹	درصد خطای میانگین
۱۶/۸۹۹	میانگین قدرمطلق درصد خطای متقارن
۰/۶۰۸	انحراف استاندارد نسبی

۵-۴ جمع‌بندی و نتیجه‌گیری

در این فصل، فرآیند توسعه و ارزیابی مدل‌های پیش‌بینی برای تخمین مقدار شیر تولیدی در اولین رکورد دوره شیردهی بعدی گاوهای شیری تشریح شد. این مدل‌ها با استفاده از داده‌های گسترده‌ای از ۹۹ دامداری در سراسر کشور توسعه یافتند و شامل الگوریتم‌های مختلفی از جمله رگرسیون ریب، جنگل تصادفی، رگرسیون بردار پشتیبان، افزایش گرادیان افراطی، تقویت دسته‌ای، شبکه عصبی چندلایه و شبکه عصبی عمیق بودند. هر یک از این مدل‌ها با استفاده از معیارهای ارزیابی مانند ضریب تعیین، میانگین قدرمطلق خطا، ریشه میانگین مربع خطا، درصد خطای میانگین، میانگین قدرمطلق درصد خطای متقارن و انحراف استاندارد نسبی مورد ارزیابی قرار گرفتند.

نتایج نشان داد که مدل تقویت دسته‌ای اولیه با ضریب تعیین ۰/۴۰۱۵ و میانگین قدرمطلق خطا ۶/۴۳۸۲ بهترین عملکرد را در میان تمامی مدل‌های بررسی‌شده ارائه داد. این مدل نسبت به مدل فعلی مورد استفاده در تعاونی وحدت اصفهان، که ضریب تعیین حدود ۰/۳۰ دارد، تقریباً ۱۰ درصد بهبود در دقت پیش‌بینی را نشان می‌دهد. در مقایسه با سایر مدل‌های توسعه‌یافته، این مدل نسبت به شبکه عصبی چندلایه حدود ۳/۱۴ درصد، نسبت به جنگل تصادفی بهینه‌شده حدود ۴/۴۰ درصد، نسبت به رگرسیون بردار پشتیبان با هسته شعاعی حدود ۳/۷۲ درصد، و نسبت به افزایش گرادیان افراطی بهینه‌شده حدود ۲/۸۵ درصد بهبود در ضریب تعیین داشته است.

تحلیل داده‌های دامداری رحمت‌آباد نشان داد که شاخص دوره انتقال در ماه‌های مختلف سال نوسانات قابل‌توجهی دارد، با بالاترین مقدار در فروردین (۷/۶) و پایین‌ترین مقادیر در دی (۲/۶) و شهریور (۳/۰). این الگوها می‌توانند به شناسایی عوامل محیطی یا مدیریتی مؤثر بر عملکرد گله کمک کنند. همچنین، بررسی

نسبت چربی به پروتئین نشان‌دهنده افزایش خطر کتوز در ماه‌های گرم سال (خرداد و تیر) بود که نیاز به مدیریت پیشگیرانه را برجسته می‌کند. تحلیل داده‌های گمشده نیز نشان داد که کیفیت داده‌ها به‌طور کلی مناسب است، اما ثبت دقیق‌تر اطلاعات آبستنی و شیر می‌تواند دقت مدل‌ها را بهبود بخشد.

در میان مدل‌های توسعه‌یافته، استفاده از ویژگی گروه‌بندی در مدل‌های جنگل تصادفی تأثیر قابل‌توجهی بر بهبود عملکرد نداشت، اما پایداری نتایج را افزایش داد. همچنین، مدل‌های مبتنی بر مقیاس‌بندی مقاوم و استانداردسازی نشان‌دهنده تفاوت‌های جزئی در عملکرد بودند که اهمیت انتخاب روش مناسب پیش‌پردازش را نشان می‌دهد. مدل‌های شبکه عصبی، اگرچه توانایی یادگیری الگوهای پیچیده را دارند، عملکردی مشابه مدل‌های مبتنی بر درخت مانند تقویت دسته‌ای ارائه دادند، که نشان‌دهنده برتری نسبی الگوریتم‌های مبتنی بر درخت در این کاربرد خاص است.

در مجموع، مدل تقویت دسته‌ای اولیه به دلیل دقت بالا، پایداری و تعمیم‌پذیری مناسب، به‌عنوان بهترین مدل برای پیش‌بینی مقدار شیر تولیدی در اولین رکورد شیردهی توصیه می‌شود. این مدل نه تنها نسبت به مدل فعلی تعاونی وحدت استان اصفهان بهبود قابل‌توجهی دارد، بلکه با توجه به معیارهای ارزیابی، عملکرد بهتری نسبت به سایر مدل‌های پیشرفته ارائه می‌دهد. با این حال، برای بهبود بیشتر، پیشنهاد می‌شود داده‌های دقیق‌تری از متغیرهای محیطی و مدیریتی جمع‌آوری شود و مدل‌های ترکیبی یا رویکردهای پیشرفته‌تر مانند یادگیری عمیق با معماری‌های پیچیده‌تر در تحقیقات آینده بررسی شوند.

فصل پنجم

ارزیابی و نتایج

۵-۱ مقدمه

این فصل به ارائه نتایج حاصل از اجرای مدل‌های پیش‌بینی طراحی شده برای تخمین اولین رکورد شیردهی گاوهای شیری اختصاص دارد. همان‌طور که در فصل‌های پیشین اشاره شد، هدف اصلی این پژوهش توسعه الگوریتم‌هایی مبتنی بر یادگیری ماشین برای تحلیل داده‌های تاریخی و پیش‌بینی عملکرد شیر در دوره انتقال است. در این راستا، مجموعه‌ای از مدل‌ها شامل رگرسیون ريج، جنگل‌های تصادفی، رگرسیون بردار پشتیبانی، افزایش گرادیان افراطی، تقویت دسته‌ای، و شبکه‌های عصبی چندلایه و عمیق مورد ارزیابی قرار گرفته‌اند. این مدل‌ها با استفاده از داده‌های جمع‌آوری شده از ۳۴۵۶۷۶ رأس گاو در ۹۹ گله طی سال‌های ۱۳۹۰ تا ۱۴۰۱، که به سه بخش آموزشی، آزمایشی، و اعتبارسنجی تقسیم شده‌اند، آموزش داده شده‌اند.

در این فصل، ابتدا نتایج کمی حاصل از اجرای مدل‌ها با استفاده از شش معیار ارزیابی شامل ضریب تعیین، میانگین قدرمطلق خطا، ریشه میانگین مربع خطا، درصد خطای میانگین، میانگین قدرمطلق درصد خطای متقارن، و انحراف استاندارد نسبی ارائه می‌شود. سپس، با تحلیل این نتایج، مدل بهینه انتخاب شده و به صورت تفصیلی مورد بررسی قرار می‌گیرد. هدف از این تحلیل، نه تنها شناسایی بهترین عملکرد پیش‌بینی، بلکه ارائه بینش‌هایی برای بهبود مدیریت دوره انتقال و تصمیم‌گیری‌های مبتنی بر داده در صنعت دامداری است. در نهایت،

نتایج این فصل به عنوان پایه‌ای برای بحث‌های آینده در پژوهش‌های آتی، به‌ویژه در توسعه و بهینه‌سازی مدل‌ها، مورد استفاده قرار خواهد گرفت.

۲-۵ تحلیل داده‌ها و نتایج مدل‌ها

۱. ضریب تعیین^۱: نشان‌دهنده درصد واریانس توضیح داده‌شده توسط مدل است و مقداری بین ۰ تا ۱ دارد. مقادیر بالاتر نشان‌دهنده برازش بهتر مدل هستند.

۲. میانگین قدرمطلق خطا^۲: میانگین اختلاف مطلق بین مقادیر پیش‌بینی‌شده و واقعی را نشان می‌دهد و واحد آن کیلوگرم است.

۳. ریشه میانگین مربع خطا^۳: حساس به خطاهای بزرگ است و نشان‌دهنده پراکندگی خطاها به صورت ریشه دوم است.

۴. درصد خطای میانگین^۴: جهت کلی خطاها را نشان می‌دهد و به صورت درصدی بیان می‌شود.

۵. میانگین قدرمطلق درصد خطای متقارن^۵: برای مقایسه نسبی خطاها در مقیاس درصد استفاده می‌شود.

۶. انحراف استاندارد نسبی^۶: نسبت ریشه میانگین مربع خطا به انحراف معیار مشاهدات واقعی است و نشان‌دهنده میزان پراکندگی خطا نسبت به داده‌ها است.

نتایج حاصل از اجرای مدل‌ها در جدول زیر ارائه شده است:

^۱ R^2

^۲ MAE

^۳ RMSE

^۴ MPE

^۵ sMAPE

^۶ SDR

جدول ۵-۱: مقایسه عملکرد مدل‌ها بر اساس معیارهای ارزیابی

مدل	ضریب تعیین	میانگین قدرمطلق خطا	ریشه میانگین مربع خطا	درصد خطای میانگین	میانگین قدرمطلق درصد خطای متقارن	انحراف استاندارد نسبی
Ridge Initial	۰/۳۱۱	۷/۰۲۸	۹/۲۰۷	-۸/۰۸۵	۱۷/۶۸۴	۰/۵۱۷
Ridge Tuned	۰/۳۱۳	۷/۰۰۶	۹/۱۹۱	-۷/۸۷۸	۱۷/۶۶۴	۰/۵۵۷
Random Forest Initial	۰/۳۴۸	۶/۸۲۹	۸/۹۵۸	-۶/۹۳۶	۱۷/۲۲۳	۰/۶۱۱
Random Forest Tuned	۰/۳۵۸	۶/۷۵۹	۸/۸۹۱	-۷/۳۱۶	۱۷/۰۵۵	۰/۶۰۳
Random Forest with Final Cross-Validation	۰/۳۵۳	۶/۷۸۵	۸/۹۲۵	-۷/۶۱۱	۱۷/۰۹۳	۰/۵۷۴
Random Forest Initial with grp	۰/۳۴۰	۶/۸۷۹	۹/۰۱۱	-۶/۹۶۴	۱۷/۳۴۲	۰/۶۱۴
Random Forest Tuned with grp	۰/۳۵۱	۶/۷۹۳	۸/۹۳۳	-۷/۶۰۹	۱۷/۱۱۲	۰/۵۷۵
Random Forest with Final Cross-Validation grp	۰/۳۵۱	۶/۷۹۳	۸/۹۳۳	-۷/۶۰۹	۱۷/۱۱۲	۰/۵۷۵
SVR Linear	۰/۳۰۷	۶/۹۷۱	۹/۲۳۳	-۹/۷۳۱	۱۷/۵۸۴	۰/۵۸۵
SVR Polynomial	۰/۲۶۵	۷/۲۱۶	۹/۵۱۱	-۹/۸۲۱	۱۸/۱۷۶	۰/۵۵۵
SVR RBF	۰/۳۶۴	۶/۶۳۸	۸/۸۴۴	-۹/۲۳۸	۱۶/۷۵۹	۰/۶۱۶
SVR RBF Robust	۰/۳۶۰	۶/۶۴۴	۸/۸۶۱	-۹/۲۴۰	۱۶/۷۷۶	۰/۶۱۷
XGBoost	۰/۳۶۷	۶/۶۶۱	۸/۸۲۷	-۷/۲۹۰	۱۶/۹۰۶	۰/۶۱۸
XGBoost Tuned	۰/۳۷۳	۶/۶۶۰	۸/۷۸۳	-۷/۳۱۹	۱۶/۸۲۲	۰/۶۰۶
CatBoost Initial	۰/۴۰۲	۶/۴۳۸	۸/۵۰۴	-۶/۶۶۷	۱۶/۲۱۵	۰/۶۲۹
CatBoost Tuned	۰/۳۸۶	۶/۵۳۹	۸/۶۱۵	-۶/۸۵۷	۱۶/۴۵۰	۰/۶۰۸
CatBoost Initial Standard	۰/۳۷۳	۶/۶۵۹	۸/۷۸۵	-۷/۳۴۴	۱۶/۸۱۶	۰/۶۰۴
MLP	۰/۳۷۰	۶/۶۵۴	۸/۸۰۳	-۷/۶۴۶	۱۶/۸۰۸	۰/۶۲۰
DNN	۰/۳۶۹	۶/۶۹۳	۸/۸۱۳	-۶/۸۸۹	۱۶/۸۹۹	۰/۶۰۸

بر اساس جدول فوق، مدل‌های مختلف عملکرد متفاوتی از خود نشان داده‌اند. به‌طور کلی، مدل تقویت دسته‌ای اولیه با ضریب تعیین ۰/۴۰۲ بالاترین برآزش را داشته و میانگین قدرمطلق خطای آن (۶/۴۳۸ کیلوگرم) کمترین مقدار را در بین مدل‌ها داراست. این نشان‌دهنده توانایی این مدل در پیش‌بینی دقیق‌تر مقادیر واقعی است. از سوی دیگر، مدل رگرسیون بردار پشتیبانی با هسته چندجمله‌ای با ضریب تعیین ۰/۲۶۵ کمترین عملکرد را داشته و خطاهای بالاتری (ریشه میانگین مربع خطا ۹/۵۱۱ و میانگین قدرمطلق خطا ۷/۲۱۶) را نشان می‌دهد، که می‌تواند ناشی از پیچیدگی بیش‌ازحد یا ناسازگاری هسته با داده‌های موجود باشد.

۵-۳ مقایسه و انتخاب مدل بهینه

برای انتخاب مدل بهینه، معیارهای مختلف به‌صورت ترکیبی بررسی شده‌اند. ضریب تعیین به‌عنوان شاخص اصلی برآزش، میانگین قدرمطلق خطا به‌عنوان معیاری از دقت پیش‌بینی، و ریشه میانگین مربع خطا به‌عنوان حساسیت به خطاهای بزرگ، در اولویت قرار گرفته‌اند. همچنین، انحراف استاندارد نسبی، درصد خطای میانگین، و میانگین قدرمطلق درصد خطای متقارن برای ارزیابی تعادل و ثبات مدل‌ها مورد توجه بوده‌اند.

برای نشان دادن برتری مدل بهینه (تقویت دسته‌ای اولیه)، جدول زیر درصد بهبود یا اختلاف این مدل نسبت به سایر مدل‌ها بر اساس تمامی معیارهای ارزیابی ارائه شده است. مقادیر مثبت در ضریب تعیین نشان‌دهنده برآزش بهتر و در معیارهای خطا نشان‌دهنده کاهش خطا یا بهبود عملکرد هستند.

جدول ۵-۲: درصد بهبود مدل بهینه (تقویت دسته‌ای اولیه) نسبت به سایر مدل‌ها

مدل	بهبود ضریب تعیین (%)	کاهش MAE (%)	کاهش RMSE (%)	کاهش MPE (%)	کاهش sMAPE (%)	کاهش SDR (%)
Ridge Initial	۲۹/۱۶۰	۸/۳۸۰	۷/۶۵۰	۱۷/۵۲۰	۸/۳۳۰	- ۲۱/۶۷۰
Ridge Tuned	۲۸/۱۴۰	۸/۱۲۰	۷/۴۷۰	۱۵/۳۷۰	۸/۲۶۰	- ۰/۱۱۰
Random Forest Initial	۱۵/۴۷۰	۵/۷۱۰	۵/۰۵۰	۳/۸۹۰	۵/۸۷۰	- ۲/۹۸۰
Random Forest Tuned	۱۲/۳۱۰	۴/۷۴۰	۴/۳۲۰	۸/۸۶۰	۵/۱۴۰	- ۰/۴۲۰
Random Forest with Final Cross-Validation	۱۳/۹۱۰	۵/۱۱۰	۴/۶۸۰	۱۲/۴۰۰	۵/۱۰۰	- ۹/۴۷۰
Random Forest Initial with grp	۱۸/۱۲۰	۶/۴۰۰	۵/۶۱۰	۴/۲۳۰	۶/۴۹۰	- ۱/۲۵۰
Random Forest Tuned with grp	۱۴/۳۱۰	۵/۲۳۰	۴/۷۵۰	۱۲/۳۷۰	۵/۲۵۰	- ۹/۵۹۰
Random Forest with Final Cross-Validation grp	۱۴/۳۱۰	۵/۲۳۰	۴/۷۵۰	۱۲/۳۷۰	۵/۲۵۰	- ۹/۵۹۰
SVR Linear	۳۰/۷۷۰	۷/۶۶۰	۷/۹۰۰	۳۱/۴۹۰	۷/۷۹۰	- ۷/۵۲۰
SVR Polynomial	۵۱/۷۱۰	۱۰/۸۰۰	۱۰/۵۸۰	۳۲/۱۲۰	۱۰/۸۰۰	- ۱۳/۳۴۰
SVR RBF	۱۰/۲۸۰	۳/۰۲۰	۳/۸۳۰	۲۷/۸۵۰	۳/۲۴۰	۲/۱۴۰
SVR RBF Robust	۱۱/۶۱۰	۳/۱۰۰	۴/۰۰۰	۲۷/۸۹۰	۳/۳۲۰	۱/۹۵۰
XGBoost	۹/۵۰۰	۳/۷۷۰	۳/۶۲۰	۸/۵۱۰	۴/۱۰۰	۱/۷۶۰
XGBoost Tuned	۷/۶۸۰	۳/۳۳۰	۳/۱۴۰	۸/۸۹۰	۳/۶۳۰	- ۳/۶۷۰
CatBoost Tuned	۴/۱۲۰	۱/۵۴۰	۱/۲۸۰	۲/۷۷۰	۱/۴۳۰	- ۳/۴۲۰
CatBoost Initial Standard	۷/۷۹۰	۳/۳۲۰	۳/۱۹۰	۹/۲۴۰	۳/۵۴۰	- ۴/۰۲۰
MLP	۸/۴۷۰	۳/۲۸۰	۳/۳۴۰	۱۲/۸۲۰	۳/۵۲۰	۱/۲۸۰
DNN	۸/۹۱۰	۳/۸۱۰	۳/۴۷۰	۳/۲۳۰	۴/۰۷۰	- ۳/۴۸۰

بررسی جدول نشان می‌دهد که مدل تقویت دسته‌ای اولیه با بالاترین ضریب تعیین (۰/۴۰۲) و کمترین میانگین قدرمطلق خطا (۶/۴۳۸) بهترین عملکرد را دارد. این مدل نسبت به سایر مدل‌ها، از جمله نسخه‌های بهینه‌شده خود (مانند تقویت دسته‌ای بهینه‌شده با ضریب تعیین ۰/۳۸۶)، ثبات و دقت بیشتری نشان می‌دهد. همچنین، ریشه میانگین مربع خطا این مدل (۸/۵۰۴) نسبت به میانگین ریشه میانگین مربع خطا سایر مدل‌ها (حدود ۸/۹۰۰) پایین‌تر است، که نشان‌دهنده کاهش خطاهای بزرگ در پیش‌بینی‌هاست. با این حال، انحراف استاندارد نسبی این مدل (۰/۶۲۹) کمی بالاتر از برخی مدل‌های دیگر (مانند رگرسیون ریبج اولیه با ۰/۵۱۷) است، که می‌تواند به پراکندگی بیشتر داده‌ها یا حساسیت مدل به نویز نسبت داده شود.

مدل‌های شبکه عصبی (شبکه عصبی چندلایه و عمیق) با ضریب تعیین حدود ۰/۳۷۰ و میانگین قدرمطلق خطا بین ۶/۶۵۰ و ۶/۶۹۰ عملکرد متوسطی داشته‌اند، اما به دلیل پیچیدگی بالاتر و نیاز به تنظیم دقیق‌تر پارامترها، در مقایسه با تقویت دسته‌ای اولیه کمتر بهینه به نظر می‌رسند. از سوی دیگر، مدل‌های رگرسیون بردار پشتیبانی، به‌ویژه با هسته‌های غیرخطی (چندجمله‌ای و شعاعی)، به دلیل ضریب تعیین پایین و خطاهای بالاتر، برای این داده‌ها مناسب تشخیص داده نشده‌اند.

بنابراین، با توجه به معیارهای فوق و تعادل بین دقت، برازش، و سادگی، مدل تقویت دسته‌ای اولیه به‌عنوان مدل بهینه انتخاب می‌شود. این انتخاب با در نظر گرفتن کاربرد عملی مدل در صنعت دامداری، که نیاز به دقت بالا و تعمیم‌پذیری مناسب دارد، انجام شده است.

۴-۵ تحلیل تفصیلی مدل بهینه

مدل تقویت دسته‌ای اولیه، که بر پایه الگوریتم تقویت گرادیانی^۱ طراحی شده است، با استفاده از داده‌های آموزشی و پارامترهای پیش فرض خود اجرا شده است. این مدل به صورت خودکار متغیرهای دسته‌ای را پردازش کرده و با بهره‌گیری از روش آمار هدف، نیازی به کدگذاری دستی ندارد. ساختار این مدل شامل مجموعه‌ای از درخت‌های تصمیم است که به صورت ترتیبی ساخته شده و هر درخت خطاهای مدل قبلی را اصلاح می‌کند.

۱-۴-۵ عملکرد کمی مدل

بر اساس نتایج جدول، این مدل ضریب تعیین 0.402 را به دست آورده است، به این معنا که حدود ۴۰ درصد از واریانس داده‌های واقعی توسط این مدل توضیح داده شده است. این مقدار، اگرچه بهینه‌ترین مقدار ممکن نیست، اما در مقایسه با سایر مدل‌ها نشان‌دهنده برازش قابل قبولی است. میانگین قدرمطلق خطا ($6/438$ کیلوگرم) نشان می‌دهد که پیش‌بینی‌های این مدل به طور متوسط کمتر از $6/500$ کیلوگرم با مقادیر واقعی اختلاف دارند، که برای پیش‌بینی تولید روزانه شیر در بازه‌ای که معمولاً بین ۲۰ تا ۴۰ کیلوگرم متغیر است، قابل قبول است. ریشه میانگین مربع خطا ($1/504$) نیز تأییدکننده این است که خطاهای بزرگ در پیش‌بینی‌ها به حداقل رسیده‌اند.

درصد خطای میانگین ($6/667$ - درصد) نشان‌دهنده تمایل مدل به پیش‌بینی مقادیری کمی بالاتر از مقادیر واقعی است، که می‌تواند ناشی از نویز موجود در داده‌ها یا ویژگی‌های نادیده گرفته شده باشد. میانگین قدرمطلق درصد خطای متقارن ($16/215$ درصد) نیز بیانگر ثبات نسبی مدل در پیش‌بینی‌های نسبی است. انحراف استاندارد نسبی ($0/629$) نشان می‌دهد که پراکندگی خطاها نسبت به انحراف معیار داده‌ها در سطح متوسطی قرار دارد.

۲-۴-۵ تحلیل کیفی و ویژگی‌های مؤثر

برای درک بهتر عملکرد مدل، اهمیت ویژگی‌ها در پیش‌بینی‌ها بررسی شده است. داده‌های تاریخی تولید شیر، به‌ویژه تولید ۳۰۵ روزه شیردهی قبلی و روزهای شیردهی در اولین تست، بیشترین تأثیر را بر نتایج داشته‌اند. این یافته با مطالعات پیشین (مانند [۸]) هم‌راستا است و نشان می‌دهد که سابقه تولید دام نقش کلیدی در پیش‌بینی عملکرد آتی دارد. همچنین، متغیرهایی مانند فصل زایش و میانگین عملکرد گله به عنوان عوامل محیطی، در کاهش خطاها مؤثر بوده‌اند.

^۱ Gradient Boosting

۵-۴-۳ محدودیت‌ها و نقاط قوت مدل

نقطه قوت اصلی این مدل، سادگی نسبی و توانایی آن در پردازش داده‌های دسته‌ای بدون نیاز به پیش‌پردازش پیچیده است. با این حال، انحراف استاندارد نسبی بالاتر نسبت به برخی مدل‌ها (مانند رگرسیون ریبج) می‌تواند نشان‌دهنده حساسیت مدل به نویز یا نیاز به تنظیم بیشتر پارامترها باشد. این موضوع در پژوهش‌های آینده باید مورد بررسی قرار بگیرد.

۵-۵ چالش‌ها و محدودیت‌ها

این پژوهش به دلیل ماهیت صنعتی و غیرآکادمیک خود با چالش‌های متعددی همراه بود. یکی از اصلی‌ترین مشکلات، فرآیند جمع‌آوری دیتاست بود که نیازمند هماهنگی‌های گسترده، برگزاری جلسات متعدد و پیگیری‌های مستمر بود. دیتاست شامل اطلاعات حساس و مهم از دامداری‌های سراسر کشور بود، که این موضوع همکاری با نهادهای مربوطه را پیچیده می‌کرد. علاوه بر این، فهم دقیق مسئله نیز چالش برانگیز بود؛ به عنوان دانشجویان مهندسی کامپیوتر، هیچ‌گونه آشنایی اولیه با مفاهیم دامداری، اصطلاحات مرتبط یا حوزه‌های تخصصی این صنعت نداشتیم. حتی در جلسات توضیحی که برگزار می‌شد، مواجهه با اصطلاحات ناآشنا و عدم درک کامل موضوع، فرآیند درک مسئله را دشوارتر می‌کرد.

یکی دیگر از موانع، دسترسی به داده‌ها بود. نهادهای مسئول به دلیل نگرانی از افشای اطلاعات یا تصور اینکه ممکن است جای آن‌ها را بگیریم، با اکراه اطلاعات را در اختیار ما قرار می‌دادند، که این امر زمان و انرژی زیادی را صرف مذاکره و جلب اعتماد کرد. در اواسط پروژه نیز با مشکلی اساسی مواجه شدیم؛ متوجه شدیم که ویژگی "شیر تجمعی ۳۰۵ روز" که در دیتاست ارائه شده بود، خود از متغیر هدف مشتق شده و نباید در مدل استفاده می‌شد. این کشف منجر به ابطال تلاش‌های قبلی برای آموزش مدل‌ها شد و ما را مجبور کرد کل فرآیند را از ابتدا بازطراحی و اجرا کنیم.

کیفیت دیتاست نیز از دیگر محدودیت‌های این پژوهش بود. بر اساس مطالعات مشابه که در مراجع ذکر شده‌اند، ویژگی‌های اضافی (مانند داده‌های سلامتی یا شرایط محیطی خاص) معمولاً برای پیش‌بینی شیر استفاده می‌شوند، اما این ویژگی‌ها در دیتاست ما موجود نبودند. همچنین، دیتاست از استانداردهای یک دیتاست آکادمیک تر و تمیز برخوردار نبود و شامل نویز و ناقص‌بودن‌هایی بود که تحلیل را پیچیده‌تر کرد. با وجود این چالش‌ها، نتایج به دست آمده نشان‌دهنده پتانسیل مدل پیشنهادی در شرایط واقعی است، اما برای بهبود بیشتر، نیاز به دیتای جامع‌تر و باکیفیت‌تر احساس می‌شود.

۵-۶ نتیجه‌گیری

در این فصل، نتایج حاصل از اجرای ۱۹ مدل مختلف برای پیش‌بینی اولین رکورد شیردهی گاوهای شیری ارائه شد. تحلیل‌ها نشان داد که مدل تقویت دسته‌ای اولیه با ضریب تعیین $0/402$ و میانگین قدرمطلق خطا $6/438$ کیلوگرم، بهترین عملکرد را در بین مدل‌ها دارد و به‌عنوان مدل بهینه انتخاب شده است. این مدل با استفاده از داده‌های تاریخی و متغیرهای کلیدی، توانسته است تعادلی مناسب بین دقت و تعمیم‌پذیری ایجاد کند. تحلیل تفصیلی این مدل نشان داد که داده‌های تولید قبلی و شرایط محیطی نقش مهمی در پیش‌بینی‌ها ایفا می‌کنند.

نتایج این فصل، نه‌تنها پایه‌ای برای ارزیابی مدیریت دوره انتقال فراهم می‌کند، بلکه مسیر را برای توسعه بیشتر مدل‌ها در فصل‌های بعدی هموار می‌سازد. مدل بهینه نسبت به مدل آماری فعلی مورد استفاده در تعاونی دامداران استان اصفهان، که ضریب تعیین آن حدود $0/300$ است، حدود ۱۰ درصد بهبود در برازش (ضریب تعیین) نشان می‌دهد. این برتری، ناشی از توانایی مدل پیشنهادی در پردازش داده‌های پیچیده و استخراج الگوهای پنهان از داده‌های تاریخی است، در حالی که مدل آماری فعلی به دلیل محدودیت‌های روش‌های کلاسیک، دقت کمتری در پیش‌بینی‌های دقیق دارد. در ادامه، با تمرکز بر بهینه‌سازی پارامترها و گنجاندن داده‌های سلامتی، انتظار می‌رود دقت پیش‌بینی‌ها بهبود یابد. این یافته‌ها می‌توانند به دامداران در اتخاذ تصمیمات بهینه برای افزایش بهره‌وری و سلامت گله کمک کنند.

مراجع

- [1] Drackley, J. K., "Biology of dairy cows during the transition period: The final frontier?," *Journal of Dairy Science*, Vol. 82, No. 11, pp. 2259-2273, 1999.
- [2] LeBlanc, S. J., "Monitoring metabolic health of dairy cattle in the transition period," *Journal of Reproduction and Development*, Vol. 56, Suppl., pp. S29-S35, 2010.
- [3] Nordlund, K. V., "Transition cow index: Its use to assess management of the transition period," *Advances in Dairy Technology*, Vol. 18, pp. 237-247, 2006.
- [4] De Koster, J., et al., "Blood and milk biomarkers in the transition period," *Veterinary Clinics: Food Animal Practice*, Vol. 35, No. 2, pp. 285-301, 2019.
- [5] Adriaens, I., et al., "Milk yield monitoring using machine learning," *Journal of Dairy Research*, Vol. 88, No. 3, pp. 321-329, 2021.
- [6] Guevara-Escobar, A., et al., "Early prediction of lactation milk yield of Holstein-Friesian cows in Querétaro, Mexico," *Journal of Animal Production*, Vol. 14, No. 1, pp. 17-26, 2022.
- [7] Dematawewa, C. M., et al., "Genetic parameters for milk yield in dairy cattle," *Journal of Animal Science*, Vol. 85, No. 5, pp. 1234-1242, 2007.
- [8] Salamone, M., et al., "Prediction of first test day milk yield using historical records in dairy cows," *Journal of Dairy Science*, Vol. 105, No. 7, pp. 6133-6147, 2022.

- [9] Dallago, G. M., et al., "Predicting first test day milk yield of dairy heifers," *Journal of Dairy Science*, Vol. 102, No. 12, pp. 11579-11590, 2019.
- [10] Liseune, A., et al., "Predicting the milk yield curve of dairy cows in the subsequent lactation period using deep learning," *Journal of Dairy Science*, Vol. 106, No. 9, pp. 6123-6136, 2023.
- [11] Wood, P. D. P., "Algebraic model of the lactation curve in cattle," *Nature*, Vol. 216, pp. 164-165, 1967.
- [12] Ali, T. E., and Schaeffer, L. R., "Accounting for covariances among test day milk yields in dairy cows," *Canadian Journal of Animal Science*, Vol. 67, No. 3, pp. 637-644, 1987.
- [13] La Croix, R., and Nordlund, K., "Transition cow index™ in progress," in: *Proceedings of the 42nd Annual Conference of the American Association of Bovine Practitioners (AABP)*, Omaha, Nebraska, 2009.
- [14] Grzesiak, W., Wojcik, J., and Binerowska, B., "Prediction of 305-day first lactation milk yield in cows with selected regression models," *Department of Ruminants Science, Agricultural University of Szczecin, Poland*, 2006.
- [15] Zhang, F., Weigel, K. A., and Cabrera, V. E., "Predicting daily milk yield for primiparous cows using data of within-herd relatives to capture genotype-by-environment interactions," *Department of Animal and Dairy Sciences, University of Wisconsin-Madison, Madison*, Vol. 53706, 2018.
- [16] Hannon, F. P., Green, M. J., O'Grady, L., Hudson, C., and Gouw, A., "Predictive models for the implementation of targeted reproductive management in multiparous cows on automatic milking systems," 2023.
- [17] Kumar, V., et al., and Shivahre, P., "Comparative study of ANN and conventional methods in forecasting first lactation milk yield in Murrah buffalo," *Indian Journal of Animal Sciences*, 2019.
- [18] Salamone, M., et al., and Aernouts, B., "Milk yield residuals and their link with the metabolic status of dairy cows in the transition period," *Journal of Dairy Science*, 2023.
- [19] Ramani, A. L., "Prediction of First Lactation Milk Yield on The Basis of Test Day Yield Using Multiple Linear Regression in Gir Cows," *Indian Journal of Pure , Applied Biosciences*, 30 Jun 2024.

- [20] Ramani, A. L., "Prediction of first lactation milk yield on the basis of test day yield using artificial neural network versus multiple linear regression in Gir cows," *Indian Journal of Dairy Science*, 1 Jan 2024.
- [21] Sharma, N., Narang, R., Ratwan, P., et al., "Prediction of first lactation 305-days lactation milk yield from peak yield and test day milk yields in crossbred cattle," *Indian Journal of Animal Sciences*, 27 Feb 2019.
- [22] Moawed, S. A., Mahrous, E., Elawad, A., et al., "The Application of Ordinal Logistic Regression Model as a Robust Tool for Enhanced Prediction of Milk Yield in Dairy Cows," *Suez Canal Veterinary Medical Journal. SCVMJ*, 30 Jun 2024.